

CAS4133 LLM · 기말 대비 · CHEAT SHEET

## 치트시트 — 시험 직전 전범위 압축

#7 Decoding → #14 AI Text Detection · 챗터 핵심 + 교차 비교 + 수식 전부 + 논문 매핑 + 마지막 점검

### 🕒 시험 전략 리마인드

#### TRUE / FALSE (10문항)

정답 **3점** · 오답 **0점** · 무응답 **1점**.확신이 정답 확률 1/3 미만이면 **빈칸이 기댓값상 이득**. 애매하면 비워라.

#### PICK ALL THAT ARE CORRECT

"any wrong answer will lead to 0 points" — **틀린 보기 하나라도 고르면 0점**. 확실한 것만 체크, 욕심내지 말 것.

#### 문제는 영어 출제

함정은 늘 디테일: *before/after softmax*, *premise/hypothesis 방향*, *min/max·upper/lower bound*,  $L^- - L^+$  부호 같은 방향성을 마지막에 재확인.

📢 **마지막 수업 확정 공지**: 객관식(Pick-all) Problem은 **3~4개**이며 그중 **1개**는 **특강 통합(#13 Jailbreak + #14 AI Text Detection)** 문제. 교수 recap 강조: RAG는 *inference(REPLUG·IRCoT·RetRobust)* vs *training(Self-RAG·Search-R1)*, Tool은 *Toolformer(self-supervised)* vs *ToolLLM(SFT)*, Agents는 *planning(ReAct·Reflexion·ToT)+memory(MemGPT·A-Mem)*, RL은 *RLHF+PPO·GRPO*. 특강 recap은 *Jailbroken·AutoDAN·SafeDecoding·Gradient Cuff / DetectGPT 계열·watermarking* 중심(GCG·COLD-Attack은 recap 미언급). 성적: 기말 **30%+**프로젝트 20%가 남은 절반 · 절대평가 · A+만 엄격.

## 📦 챕터별 핵심 카드 (#7 ~ #14)

### #7 Decoding · COLD

기출 P5 재출제 대비

- **AR decoding**: sequential(병렬 불가), EOS/max-len까지, softmax 분포에서 샘플
- **Temperature**: softmax **이전** 로짓 rescale;  $\tau \downarrow$ =deterministic,  $\tau \rightarrow 0$ =greedy
- **Top-k**=고정 k개 / **Top-p**=누적확률 동적 후보(분포 모양 따라 변함)
- **Speculative**: draft는 여전히 AR, 큰 모델은 병렬 verify, 출력 분포 보존
- **Test-time compute**: 추론 전략(파라미터 고정), fine-tuning 아님
- **COLD**(Qin, NeurIPS 2022): 제약→에너지 함수, 이산  $\mathbf{y}$ →연속 로짓  $\tilde{\mathbf{y}}$  완화, Langevin으로 업데이트, training-free
- 알고리즘 4단계: 초기화→에너지 정식화→N회 Langevin→**discretization**
- Lexical 제약  $E_1$ : fluency 항들이 키워드 막삽입(reward hacking) 방지, ~95% coverage

$$E(\mathbf{y}) = -\sum_i \lambda_i f_i(\mathbf{y}), p \propto e^{-E} \cdot \tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla E + \epsilon^{(n)}$$

- ✗ "Decoding can be parallelized across all tokens at inference." → **False** (sequential)
- ✗ "Temperature is applied after the softmax." → **False** (before, on logits)
- ✗ "Top-p is a special case of beam search with p=1." → **False** (sampling ≠ search)

프롬프팅=implicit·무보장 ⇔ COLD=explicit 에너지 최적화 / 제약 만족↑ = 에너지↓ = 확률↑

- **G-Eval**(EMNLP 2023): 사람은 task info+criteria만, **eval steps**는 **LLM이 자동 생성**, instance-wise 채점; GPT-4일 때만 전통 지표(ROUGE/BERTScore) 능가
- **LLM-as-a-Judge**(MT-Bench, NeurIPS 2023): **pairwise**; 80 multi-turn Q·8 categories; GPT-4↔human **85%** > human↔human **81%**
- **3대 bias**: Position(swap 2회→불일치=Tie, 2× cost; proxy=random shuffle) / Verbosity(중복 정보여도 긴 답 선호) / Self-preference(**open problem**)
- **LC win rate**(COLM 2024): 회귀로 length 효과 제거; Chatbot Arena 상관 **0.98**
- **RLHF 한계 3**: implicit goodness / OOD·adversarial query / 모델↑일수록 레이블 곤란
- **H vs H**: helpfulness·harmlessness는 competing objectives → jointly maximize; PMP=community votes 사전학습
- **Constitutional AI**(Anthropic 22.12): 사람은 헌법만 작성; **SL-CAI**=critique→revision→SFT / **RL-CAI**=principle-conditioned RM→RL(=**RLAIF**)
- **Self-Rewarding LM**(ICML 2024): generator 겸 judge로 반복 자기학습

수식 없음 — instance-wise/pairwise, SL/RL 단계, bias↔해법 매칭이 전부

- ✗ "Human-human agreement is higher than GPT-4-human on MT-Bench." → **False** (81% < 85%)
- ✗ "SL-CAI trains a principle-conditioned reward model." → **False** (that is RL-CAI)
- ✗ "Swapped-position evaluation removes position bias at no extra cost." → **False** (2× cost)

G-Eval=instance-wise 점수 ↔ Judge=pairwise 비교 / SL-CAI=SFT 데이터 생성 ↔ RL-CAI=AI 선호 레이블(RLAIF)

- 동기: 정적 데이터셋 → **knowledge cutoff**(GPT-4o 2023-10, LLaMA3 2023-12)·hallucination; 새 지식 fine-tuning은 기존 능력 손상
- RAG = retrieve-and-read에서 **generator만 LLM 교체**; inference-based vs training-based
- **PageRank**:  $1 - d$ =random jump 확률; 의미 정보 안 씬 / **BM25**: sparse, 무학습, IDF는 corpus 전체 기준
- **DPR**: 인코더 2개+dot product+contrastive loss(labeled  $p^+$ +in-batch negatives), OOD 약함 / **Contriever**: 같은 문서 crop=positive(자기지도), loss는 DPR과 동일, OOD 강건
- **REPLUG**: LM frozen(black-box), 문서별 독립 prepend→확률 가중 앙상블; **LSR**=retrieval↔LM likelihood **KL 최소화**로 검색기만 학습
- **IRCoT**: CoT 1스텝↔검색 교차; **마지막 스텝만 질의**, 구절은 누적; multi-hop QA
- **RetRobust**: NLI 필터(passage=**premise**, Q+A=**hypothesis**; not-entailed→direct answering) + 소량 학습
- **Self-RAG**(ICLR 2024 Oral): **SFT**로 4 reflection 토큰(Retrieve/IsREL/IsSUP/IsUSE); GPT-4→critic(90% agree)→generator; 검색 체크 loss 제외
- **Search-R1**(25.03): **RL, outcome reward만**; <think>/<search>/<information>/<answer>; retrieved token masking; interleaved 검색 자동 창발
- 지표: **EM**=완전일치 0/1 / **F1**=단어 수준 / **Recall@K**=검색기 지표

$$\text{sim}(q, p) = E_Q(q)^\top E_P(p) \cdot \text{REPLUG: } p(y|x, \mathcal{D}') = \sum_d p(y|d \circ x) \lambda(d, x)$$

- ✗ "Dense retrievers always outperform BM25." → **False** (OOD에선 BM25가 이기기도)
- ✗ "LSR maximizes the KL divergence." → **False** (minimize — 두 분포 일치)
- ✗ "IRCoT uses the full accumulated CoT as query." → **False** (last step only)

BM25=lexical·무학습 / DPR=supervised dense / Contriever=self-supervised dense · Self-RAG=SFT ↔ Search-R1=RL

- 동기: 정확한 계산·실시간 정보·외부 행동은 LLM 단독 불가; **retrieval(RAG) ⊂ tool use**; agent 3요소=tool use/memory/planning&action
- **Function calling**(prompting): 모델은 **이름+인자만 반환**, 실행은 개발자 측; 이름 일관성+상세 설명 둘 다 중요; large LLM에서만 신뢰
- **Toolformer**(NeurIPS 2023 Oral): self-supervised — "useful tool = next-token loss를 낮추는 호출"; in-context로 후보 샘플→실행→**loss filtering**→표준 LM loss로 FT
- GPT-J 6B+**5 tools**가 GPT-3 능가(이득은 tool call 자체에서); 비용이 도구 수에 비례→확장 불가
- **ToolLLM**(ICLR 2024): RapidAPI **3,451 tools / 16,464 APIs**(tool 1개=API 여러 개); N개 subsample로 instruction 생성; **DFSDT**로 solution path 주석, "Finish" 도달분만 golden
- 추론=RAG 유사 2단계(API retrieval→generation); 자체 **BERT dense retriever** > Ada-BM25; **Pass**=완수율 / **Win**=ChatGPT 대비 품질; retrieved top-5 > ground-truth(diversity)

filtering:  $L_i^- - L_i^+ \geq \tau \Rightarrow \text{keep}, L_i^- = \min(L_i(\varepsilon), L_i(e(c_i, \varepsilon)))$

- ✗ "Toolformer keeps a call when  $L_i^+ - L_i^- \geq \tau$ ." → **False** (부호 반대)
- ✗ "Toolformer checks whether the API answer is factually correct." → **False** (loss 감소만 봄)
- ✗ "ToolLLM filters data by loss reduction like Toolformer." → **False** (ChatGPT가 실제로 풀어 Finish 도달분만)

Toolformer=loss로 거르는 self-supervised 5-tool ↔ ToolLLM=ChatGPT가 풀어 거르는 16K-API SFT+DFSDT

- **Agent** = LLM(brain) + Planning&Action + Tools + Memory; **"not simply improved by scaling-up"**
- **LLaVA**: vision encoder  $\rightarrow \mathbf{Z}_v \rightarrow \text{projector } \mathbf{W} \rightarrow \mathbf{H}_v$ ; Stage1=projector만 / Stage2=projector+LLM, **encoder는 항상 frozen**; 데이터는 GPT-4 생성
- **ReAct**(ICLR 2023): reasoning+acting interleave, **few-shot prompting**(학습 아님); CoT-SC  $\rightarrow$  ReAct는 득표 < n/2 일 때 backoff
- **Reflexion**(NeurIPS 2023): **verbal RL** — Actor  $\rightarrow$  Evaluator(ALFWorld에선 heuristic > GPT)  $\rightarrow$  Self-reflection  $\rightarrow$  Memory, **weight update 없음**
- **Plan-and-Solve**: zero-shot "plan 먼저" 프롬프트 / **ToT**(NeurIPS 2023 Oral): 분해  $\rightarrow$  생성  $\rightarrow$  평가(value/vote, LLM 프롬프팅)  $\rightarrow$  탐색(BFS/DFS); Game of 24 압승, 비용 ~100x
- **MemGPT**: OS 비유(RAM=in-context  $\leftrightarrow$  disk=external); **70%  $\rightarrow$  경고만, 100%  $\rightarrow$  50% evict+recursive summary**; 관리는 LLM function call
- **A-Mem**(NeurIPS 2025): note  $m_i = \{c, t, K, G, X, e, L\}$ ; cosine top-k는 후보만, **링크는 LLM이 생성**; evolution은 이웃만 갱신
- **Multi-agent**: persona만 달라도 다른 agent; **MDAgents**=complexity check  $\rightarrow$  solo/group/teams; orchestration=강한 lead(Opus)+싼 sub(Haiku); routing=비용 최적화

LLaVA projector:  $\mathbf{Z}_v \in \mathbb{R}^{L \times D'} \xrightarrow{\mathbf{W}} \mathbf{H}_v \in \mathbb{R}^{L \times D}$  (vision token은 벡터, vocabulary 없음)

- ✗ "LLaVA stage 2 fine-tunes the vision encoder."  $\rightarrow$  **False** (always frozen)
- ✗ "Reflexion updates the LLM's weights from feedback."  $\rightarrow$  **False** (verbal memory only)
- ✗ "MemGPT evicts at 70% usage."  $\rightarrow$  **False** (70%=warning, 100%=evict 50%+summary)

**ReAct=interleave 프롬프팅 / Reflexion=언어 피드백 메모리 / PS=zero-shot 계획 / ToT=트리 탐색(+고비용)**

- **매핑**: policy=LLM / state=input tokens / action=next-token generation; 목표=return(누적 보상) 최대화
- $V^\pi$ =state 조건부,  $Q^\pi$ =state+action 조건부,  $V^\pi(s) = \mathbb{E}_{a \sim \pi}[Q^\pi(s, a)]$ ;  $\gamma$ 는 infinite-horizon 발산 방지용
- **PG 유도 3요소**: log-derivative trick / 환경항( $\rho_0$ , transition) gradient=0 / Monte Carlo 표본평균(on-policy)
- **분산 감소 3종**: reward-to-go(t 이후만) / baseline  $b(s_t)$ (state만 의존, 기댓값 불변·분산↓) / advantage  $A = Q - V$
- **PPO-Clip**: ratio를  $[1 - \epsilon, 1 + \epsilon]$ 로 clip;  **$A > 0 \rightarrow$ 상한(ceiling),  $A < 0 \rightarrow$ 하한**; value model 필요; 멀어짐 완전 보장은 안 됨 (수업 표기 "Proximal Point Optimization"도 동일물)
- **TRL**: rollout은 `torch.no_grad` (샘플링만); 별도 value 모델 대신 **value head**(LM head=vocab 분포, value head=스칼라)
- **GRPO**: value model 제거 — 그룹 G개 rollout의 mean/std로 advantage; **clip은 PPO 그대로**+KL(ref, 다른 estimator); 동기=value 의존 제거(stability 아님); 생성 비용↑
- 변형: Dr.GRPO=std 제거 / REINFORCE++=query-wise; **GLM-5**: SFT→Reasoning RL→Agentic RL→General RL(**alignment 마지막**), 여전히 GRPO; **On-policy distillation**: student가 생성한 데이터에 teacher가 supervision→forgetting 강건

$$\nabla J = \mathbb{E}[\sum_t \nabla \log \pi_\theta(a_t | s_t) A^\pi] \cdot \hat{A}_i = \frac{r_i - \text{mean}(\{r\})}{\text{std}(\{r\})}$$

- ✗ "A baseline may depend on the action." → **False** (state-only, else biased)
- ✗ "When  $A > 0$  the clip term is a lower bound." → **False** (upper bound; lower는  $A < 0$ )
- ✗ "GRPO's motivation is preventing abrupt updates like PPO." → **False** (value 제거가 동기)

REINFORCE=R( $\tau$ ) 그대로 / PPO=clip+value model / GRPO=group 정규화+value 없음(clip·KL은 유지)

- **Training-level 방어**: Red Teaming(전문가→학습 데이터, 비용↑) / **RBRM**=rule-based reward로 RLHF **보강**(대체 아님, 선호 학습 아님)
- **DAN**=수작업 역할부여(refusal suppression류); good bot=**refuse**, bad bot=on-topic 응답
- **Failure mode 2**(Jailbroken, NeurIPS 2023 Oral): ① Competing objectives — prefix injection(next-token vs safety)·refusal suppression(instruction following vs safety) ② Mismatched generalization — Base64; **Comb\_3가 SOTA ASR**
- **GCG**(Zou 2023): gradient 기반 suffix — 의미 없음 → **perplexity filter에 쉽게 탐지**
- **AutoDAN**(ICLR 2024): hierarchical **genetic algorithm**; 초기화=handcrafted DAN(중요!), fitness=proxy target likelihood, crossover=문장 교환/word scoring mutation; fluent→perplexity 방어 생존, 전이성↑; ASR=keyword 기반(GPT 판정은 Recheck)
- **COLD-Attack**(ICML 2024): COLD와 알고리즘 **exactly the same**(energy+Langevin on logits), 제약만 attack/fluency/similarity/lexical로 교체; GCG·AutoDAN보다 빠름
- **SafeDecoding**(ACL 2024): LoRA expert와 contrastive decoding으로 refusal 토큰↑; **first m tokens만**; benign에선 보정항 cancel; inference-level
- **Gradient Cuff**(NeurIPS 2024): refusal loss  $f < 0.5$  + **zeroth-order** gradient norm>t 2단계; benign=flat / malicious=steep; SafeDecoding과 trade-off(우열 없음)

SafeDecoding:  $P_n(x) = p_\theta + \alpha(p_{\theta'} - p_\theta) \cdot$  refusal loss:  $\phi_\theta(x) = 1 - \mathbb{E}_y[JB(y)]$ ,  $JB(y) = 1$ =refusal

- ✗ "Base64 attack exploits competing objectives." → **False** (mismatched generalization)
- ✗ "GCG evades perplexity-based detectors." → **False** (정반대 — 쉽게 탐지됨)
- ✗ " $JB(y) = 1$  when jailbreak succeeds." → **False** (1=refusal; "Sure, here is..."=0)

**GCG=gradient·탐지됨 / AutoDAN=GA·fluent / COLD-Attack=Langevin·최고속 · 방어: SafeDecoding(디코딩 보정) vs Gradient Cuff(탐지·거부)**



- **3갈래:** ① Zero-shot(DetectGPT/Fast-DetectGPT) ② Training-based(RoBERTa, ReMoDetect) ③ Watermarking(생성 시점에 패턴 삽입)
- **DetectGPT**(ICML 2023): LLM 텍스트는  $\log p_\theta$ 의 **local maxima(negative curvature)**; perturbation은 **별도 mask-fill LM(T5)**, 의미 보존; **black-box 아님**( $\log p_\theta$  필요); ~100 perturbations에서 포화; OOD에서 supervised보다 우수(in-dist는 on-par); AUROC=전 threshold 적분
- **Curvature 해석:** Taylor + Hutchinson(조건:  $\mathbb{E}[z] = 0, \text{Var} = 1$ ; 대칭성은 추가 가정)  $\rightarrow \text{score} = -\frac{1}{2}\text{tr}(H_f)$ , full Hessian 불필요
- **Fast-DetectGPT**(ICLR 2024):  $p_\theta(\tilde{x}) \rightarrow p_\theta(\tilde{x}|x)$ , conditional **independent** sampling(원본 prefix 조건)으로  $N \times L \rightarrow L$  inferences; **x340**(22h→4min), 성능 유지~상회
- **ReMoDetect**(NeurIPS 2024): reward model은 LLM 생성문(LGT)에 biased→탐지기로; continual preference tuning은 **LGT를 preferred로**(직관 반대!)+replay buffer; Mixed responses(LLM>Mixed>Human); DPO 모델에도 적용 가능
- **Watermark**(Kirchenbauer, ICML 2023): 이전 토큰 hash→green/red **매 위치 재분할**; hard=red 금지 / **soft=green logit+δ**; 사람에겐 imperceptible; **탐지에 모델 접근 불필요**(z-test만);  $\tau=4 \rightarrow \text{FP} \approx 3 \times 10^{-5}$ , 16+ 토큰; SynthID 채택

$$\mathbf{d} = \log p_\theta(x) - \mathbb{E}_{\tilde{x}}[\log p_\theta(\tilde{x})] \cdot z = \frac{2(|s|_G - T/2)}{\sqrt{T}}$$

- ✗ "DetectGPT works fully black-box."  $\rightarrow$  **False** (needs  $\log p_\theta$ ; watermark 탐지는 모델 불필요)
- ✗ "Fast-DetectGPT is faster because it uses fewer samples."  $\rightarrow$  **False** (conditional independent sampling 덕분)
- ✗ "In continual preference tuning, human text is preferred."  $\rightarrow$  **False** (LGT가 preferred)

Zero-shot=곡률(모델 logprob 필요) / Trained=reward model 활용 / Watermark=생성에 개입·탐지는 통계 검정만

## 교차 비교 — 챕터를 넘나드는 헛갈림 정리

**COLD(#7) vs COLD-Attack(#13)** — 알고리즘은 **완전히 동일**(에너지 함수 + 로짓 공간 Langevin dynamics + discretization). COLD-Attack은 제약(에너지 항)만 attack·fluency·similarity·lexical로 바꿔 jailbreak에 적용. "COLD-Attack proposes a new sampling algorithm" → **False**.

**Langevin dynamics 등장 위치** — #7 COLD와 #13 COLD-Attack 둘뿐. 원 논문은 Welling (ICML 2011).  $\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla E + \epsilon$ , 노이즈  $\epsilon \sim \mathcal{N}(0, \sigma)$ 이 있어 단순 gradient descent가 아니라 **샘플링**.

**학습 방식 3종: Self-RAG vs Search-R1 vs ToolLLM** — Self-RAG=**SFT**(GPT-4 주석→critic→generator, reflection 토큰) / Search-R1=**RL**(outcome reward만, 주석 불필요, interleaved 검색 창발) / ToolLLM=**SFT(instruction tuning)**(ChatGPT가 DFSDT로 푼 golden path). 공통점: Self-RAG·Search-R1 모두 검색된 토큰은 **loss에서 제외(masking)**.

**DetectGPT curvature(#14) vs COLD energy(#7)** — 둘 다 "함수의 모양"을 보지만 정반대 용도: DetectGPT는  $\log p_\theta$ 의 **local maxima 여부(음의 곡률)**를 측정해 탐지, COLD는 에너지  $E$ 를 **내려가며(gradient) 텍스트를 생성**. 측정 vs 최적화.

**RLHF · RLAIF · Constitutional AI 관계** — RLHF=사람 선호 레이블(응답은 AI 생성, 레이블만 사람). RLAIF=선호 레이블도 AI. Constitutional AI = SL-CAI(critique→revision SFT) + **RL-CAI(=RLAIF의 구체화, principle-conditioned RM)**. 사람의 역할은 헌법 작성뿐. RL-CAI의 시작점은 helpfulness-only RLHF 모델(베이스 LM 아님).

**PPO가 등장하는 모든 맥락** — ① RLHF/InstructGPT(#8·#12, Ouyang NeurIPS 2022)의 학습 알고리즘 ② TRL 구현(#12, value head·no\_grad rollout) ③ Search-R1(#9)의 목적함수(PPO/GRPO 호환, KL 포함) ④ GRPO(#12)가 clip 구조를 상속 ⑤ GLM-5(#12)도 결국 GRPO 계열. "GRPO is not policy gradient" → **False** (둘 다 policy optimization).

**Reward model의 4가지 얼굴** — ① Test-time compute의 Best-of-N(#7) ② RLHF 선호 학습(#8·#12) ③ **RBRM(#13)은 예외: rule-based, 선호 학습 아님** ④ ReMoDetect(#14)는 reward model의 LGT bias를 탐지기로 역이용.

**"Contrastive"의 두 의미** — #9 DPR/Contriever의 contrastive **loss**(positive 가깝게, negative 멀게)와 #13 SafeDecoding의 contrastive **decoding**(expert-base 확률 차로 보정)은 전혀 다른 개념.

**Training-free 계열 총정리** — BM25(#9), COLD(#7), prompting 기반 tool use(#10), ReAct/ToT(#11, 프롬프팅), DetectGPT·Fast-DetectGPT(#14), inference-based RAG(REPLUG의 LM·IRCoT). 반대편(학습): DPR·Contriever·Self-RAG·Search-R1·Toolformer·ToolLLM·ReMoDetect·SafeDecoding expert.

**자동 공격 3종 최적화 방식** — GCG=**greedy gradient search**(이산) / AutoDAN=**genetic algorithm**(DAN 초기화) / COLD-Attack=**Langevin**(연속 로짓). 유창성: GCG ×(탐지됨) / AutoDAN ✓ / COLD-Attack ✓(+빠름).

## Σ 수식 한 곳 모음 (이름 → 수식 → 한 줄 의미)

### AR factorization (#7)

$p(\mathbf{y}|\mathbf{x}) = \prod_{t=1}^T p(y_t | \mathbf{x}, \mathbf{y}_{<t})$  한 토큰씩, 모든 이전 토큰 조건부 —  
그래서 inference는 sequential.

### Temperature (#7)

$$p(y_t = v) = \frac{\exp(z_v / \tau)}{\sum_{v'} \exp(z_{v'} / \tau)}$$

softmax 이전 로짓 rescale;  $\tau \downarrow$  peaky(deterministic),  $\tau \uparrow$  smooth.

### COLD energy (#7/#13)

$$E(\mathbf{y}) = - \sum_i \lambda_i f_i(\mathbf{y}), \quad p(\mathbf{y}) = \frac{e^{-E(\mathbf{y})}}{Z}$$

제약 만족 $\uparrow$  → 에너지 $\downarrow$  → 확률 $\uparrow$  (Boltzmann form).

### Langevin dynamics (#7/#13)

$$\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}, \quad \epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$$

gradient step + 가우시안 노이즈 →  $n \rightarrow \infty$ 에서 목표 분포 샘플링.

### PageRank (#9)

$$PR(A) = \frac{1-d}{N} + d \sum_{B_i \in \text{In}(A)} \frac{PR(B_i)}{L(B_i)}$$

중요도=이웃 중요도/링크수 합;  $1-d$ =random jump 확률; power iteration 수렴.

### BM25 (#9)

$$\text{score}(D, Q) = \sum_i \text{IDF}(q_i) \cdot \frac{f(q_i, D)(k_1 + 1)}{f(q_i, D) + k_1(1 - b + b \frac{|D|}{\text{avgdl}})}, \quad \text{IDF}(q_i) = \ln\left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1\right)$$

IDF=corpus 전체 희소성 × TF=대상 문서 빈도(길이 보정); 무학습.

### DPR loss (#9)

$$\mathcal{L} = -\log \frac{e^{\text{sim}(q, p^+)}}{e^{\text{sim}(q, p^+)} + \sum_j e^{\text{sim}(q, p_j^-)}}, \quad \text{sim}(q, p) = E_Q(q)^\top E_P(p)$$

contrastive: positive 유사도 $\uparrow$ , negative $\downarrow$ ; Contriever도 같은 loss(데이터만 자기지도).

## REPLUG ensemble (#9)

$$p(y \mid x, \mathcal{D}') = \sum_{d \in \mathcal{D}'} p(y \mid d \circ x) \cdot \lambda(d, x), \quad \lambda(d, x) = \frac{e^{s(d, x)}}{\sum_{d'} e^{s(d', x)}}$$

문서별 독립 prepend 출력을 retrieval score로 가중 평균(블랙박스 LM).

---

## REPLUG LSR (#9)

$$\mathcal{L}_{LSR} = \mathbb{E}_x \text{KL}(P_R(d \mid x) \parallel Q_{LM}(d \mid x, y))$$

retrieval likelihood  $\leftrightarrow$  LM likelihood의 KL **최소화** — LM은 frozen, 검색기만 학습.

---

## Self-RAG generator loss (#9)

$$\max_{\mathcal{M}} \mathbb{E}_{(x, y, r) \sim \mathcal{D}_{gen}} [\log p_{\mathcal{M}}(y, r \mid x)]$$

reflection 토큰  $r$  포함 표준 likelihood; 검색 청크는 loss에서 마스킹.

---

## Search-R1 objective (#9)

$$\max_{\pi_{\theta}} \mathbb{E}_{x, y \sim \pi_{\theta}(\cdot \mid x; R)} [r_{\phi}(x, y)] - \beta \mathbb{D}_{KL}[\pi_{\theta}(y \mid x; R) \parallel \pi_{ref}(y \mid x; R)]$$

RLHF 목적과 동형(+검색기 R 개입); outcome reward만, retrieved token masking.

---

## Toolformer loss (#10)

$$L_i(\mathbf{z}) = - \sum_{j=i}^n w_{j-i} \log p_M(x_j \mid \mathbf{z}, x_{1:j-1})$$

호출 위치  $i$  이후의 가중 next-token loss;  $\mathbf{z}$ =프리픽스로 넣는 API 텍스트.

---

## Toolformer filtering (#10)

$$L_i^+ = L_i(e(c_i, r_i)), \quad L_i^- = \min(L_i(\varepsilon), L_i(e(c_i, \varepsilon))), \quad L_i^- - L_i^+ \geq \tau \Rightarrow \text{keep}$$

호출+결과가 loss를  $\tau$  이상 낮춰야 keep;  $\tau$  클수록 적게 살아남음.

---

## Policy gradient (#12)

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[ \sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) R(\tau) \right]$$

log-derivative trick + 환경항 gradient=0; MC 표본 평균으로 추정(on-policy).

---

## Baseline / Advantage (#12)

$$\mathbb{E}_{a_t \sim \pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) b(s_t)] = 0, \quad A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s)$$

state-only baseline은 기댓값 불변·분산↓; advantage=평균 대비 우수성.

---

## PPO-Clip (#12)

$$L = \min\left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)} A^{\pi_{\theta_k}}, \text{clip}\left(\frac{\pi_{\theta}(a|s)}{\pi_{\theta_k}(a|s)}, 1-\epsilon, 1+\epsilon\right) A^{\pi_{\theta_k}}\right)$$

A>0→min이 상한, A<0→하한; 급격한 정책 변화 억제(완전 보장은 아님).

#### GRPO advantage & KL (#12)

$$\hat{A}_{i,t} = \frac{r_i - \text{mean}(\{r_1..r_G\})}{\text{std}(\{r_1..r_G\})}, \quad \mathbb{D}_{KL} = \frac{\pi_{ref}}{\pi_{\theta}} - \log \frac{\pi_{ref}}{\pi_{\theta}} - 1$$

그룹 내 정규화로 value model 대체; KL은 별도 estimator(항상 ≥0).

#### AutoDAN objective (#13)

$$\max_{J_i} \prod_{t=1}^k p(r_{m+t} \mid J_i, Q_i, r_{m+1:m+t-1})$$

proxy target("Sure, here is...")의 likelihood를 GA의 fitness로 최대화.

#### SafeDecoding (#13)

$$P_n(x) = p_{\theta}(x \mid x_{1:n-1}) + \alpha(p_{\theta'}(x \mid x_{1:n-1}) - p_{\theta}(x \mid x_{1:n-1}))$$

expert(LoRA)와의 차이로 refusal 확률 증폭; first m tokens만; benign에선 cancel.

#### Refusal loss / Gradient Cuff (#13)

$$\phi_{\theta}(x) = 1 - p_{\theta}(x), \quad p_{\theta}(x) = \mathbb{E}_{y \sim T_{\theta}(x)}[JB(y)], \quad g_{\theta}(x) = \frac{1}{P} \sum_i \frac{f(e(x) \oplus \mu \mathbf{u}_i) - f(e(x))}{\mu} \mathbf{u}_i$$

JB = 1이면 refusal; zeroth-order로 기울기 norm 추정 — malicious=steep.

#### DetectGPT discrepancy (#14)

$$\mathbf{d}(x, p_{\theta}, q) = \log p_{\theta}(x) - \mathbb{E}_{\tilde{x} \sim q(\cdot|x)}[\log p_{\theta}(\tilde{x})] = -\frac{1}{2} \text{tr}(H_f(x))$$

크면 machine(local maximum); Taylor+Hutchinson으로 Hessian trace와 연결.

#### Fast-DetectGPT (#14)

$$\mathbf{d}(x, p_{\theta}, q_{\varphi}) = \frac{\log p_{\theta}(x|x) - \tilde{\mu}}{\tilde{\sigma}}, \quad \tilde{\mu} = \mathbb{E}_{\tilde{x} \sim q_{\varphi}(\cdot|x)}[\log p_{\theta}(\tilde{x}|x)]$$

조건부 독립 샘플링으로 N×L→L inferences (×340 가속).

#### Watermark z-test & soft (#14)

$$z = \frac{2(|s|_G - T/2)}{\sqrt{T}}, \quad p_k^{(t)} = \frac{\exp(l_k^{(t)} + \delta \mathbf{1}[k \in G])}{\sum_i \exp(l_i^{(t)} + \delta \mathbf{1}[i \in G])}$$

green 비율의 one-proportion z-test(τ=4→FP≈3×10<sup>-5</sup>); soft=green logit에 δ만 가산.

## 📁 암기 카드 — 논문 ↔ 학회 ↔ 연도 ↔ 키워드

| 장   | 논문/방법                                           | 학회·연도             | 핵심 키워드 1줄                                       |
|-----|-------------------------------------------------|-------------------|-------------------------------------------------|
| #7  | <b>COLD Decoding</b> (Qin et al.)               | NeurIPS 2022      | 제약=에너지 함수, 로짓 Langevin, training-free           |
| #7  | Langevin dynamics (Welling)                     | ICML 2011         | gradient step+노이즈 = 샘플링                         |
| #8  | <b>G-Eval</b> (Liu et al.)                      | EMNLP 2023        | criteria→LLM이 eval steps 생성, instance-wise      |
| #8  | <b>MT-Bench / LLM-as-a-Judge</b> (Zheng et al.) | NeurIPS 2023      | pairwise, 80 multi-turn Q, 85%>81%              |
| #8  | <b>AlpacaEval LC win rate</b> (Dubois et al.)   | COLM 2024         | 회귀로 length bias 제거, Arena 상관 0.98               |
| #8  | HH-RLHF (Bai et al.)                            | Anthropic 2022    | helpful vs harmless 트레이드오프, PMP                 |
| #8  | <b>Constitutional AI</b>                        | Anthropic 22.12   | 헌법만 사람이, SL-CAI→RL-CAI(RLAIF)                   |
| #8  | Self-Rewarding LM (Yuan et al., Meta)           | ICML 2024         | generator 겸 judge 반복 자기학습                       |
| #9  | <b>DPR</b> (Karpukhin et al.)                   | EMNLP 2020        | dual encoder + contrastive + in-batch negatives |
| #9  | <b>Contriever</b> (Izacard et al.)              | TMLR 2022         | 같은 문서 crop=positive, 자기지도, OOD 강건               |
| #9  | <b>REPLUG</b> (Shi et al.)                      | NAACL 2023        | 블랙박스 LM, 양상블 + LSR(KL min)                      |
| #9  | <b>IRCoT</b> (Trivedi et al.)                   | ACL 2023          | CoT↔검색 교차, 마지막 스텝=질의, multi-hop                 |
| #9  | <b>RetRobust</b> (Yoran et al.)                 | ICLR 2024         | NLI 필터 + 소량 학습으로 noise 강건                       |
| #9  | <b>Self-RAG</b> (Asai et al.)                   | ICLR 2024 Oral    | 4 reflection 토큰, SFT, critic 90% agree          |
| #9  | <b>Search-R1</b> (Jin et al.)                   | arXiv 25.03       | RL-outcome reward만, retrieved masking           |
| #10 | <b>Toolformer</b> (Schick et al.)               | NeurIPS 2023 Oral | self-supervised, loss filtering, GPT-J+5 tools  |
| #10 | <b>ToolLLM</b> (Qin et al.)                     | ICLR 2024         | 16,464 APIs, DFSDT, Pass/Win, BERT retriever    |
| #11 | ViT (Dosovitskiy et al.)                        | ICLR 2021 Oral    | 패치 임베딩 = 이미지의 토큰화                               |
| #11 | <b>LLaVA</b> (Visual Instruction Tuning)        | NeurIPS 2023 Oral | projector 2단계 학습, encoder frozen, GPT-4 데이터     |
| #11 | VideoPoet (Kondratyuk et al., Google)           | ICML 2024         | 모달리티별 encoder+projector 표준 패턴                   |

|     |                                                   |                      |                                              |
|-----|---------------------------------------------------|----------------------|----------------------------------------------|
| #11 | <b>ReAct</b> (Yao et al.)                         | ICLR 2023            | reason+act interleave, few-shot prompting    |
| #11 | <b>Reflexion</b> (Shinn et al.)                   | NeurIPS 2023         | verbal RL, 외부 메모리, weight update 없음          |
| #11 | Plan-and-Solve (Wang et al.)                      | ACL 2023             | zero-shot "plan 먼저" 프롬프트                     |
| #11 | <b>Tree of Thoughts</b> (Yao et al.)              | NeurIPS 2023<br>Oral | 생성→평가(value/vote)→BFS/DFS, ~100× 비용          |
| #11 | <b>MemGPT</b> (Packer et al.)                     | arXiv 23.10          | OS 비유(RAM/disk), 70% 경고·100% evict           |
| #11 | <b>A-Mem</b> (Xu et al.)                          | NeurIPS 2025         | agentic 노트+LLM 링크 생성+evolution               |
| #11 | MDAgents (Kim et al.)                             | NeurIPS 2024<br>Oral | 의료, complexity 적응형 solo/group/teams          |
| #12 | TRPO (Schulman et al.)                            | ICML 2015            | 2차 미분 비용 → PPO로 단순화                          |
| #12 | <b>RLHF / InstructGPT</b> (Ouyang et al., OpenAI) | NeurIPS 2022         | 3단계 SFT→RM→PPO                               |
| #12 | <b>GRPO / DeepSeekMath</b> (Shao et al.)          | arXiv 24.04          | group 정규화 advantage, value 제거                |
| #12 | DeepSeek-R1                                       | arXiv 25.01          | GRPO를 대규모 reasoning RL로 입증                   |
| #12 | GLM-5 (Team)                                      | arXiv 26.02          | Reasoning→Agentic→General RL, alignment 마지막  |
| #13 | <b>Jailbroken</b> (Wei et al.)                    | NeurIPS 2023<br>Oral | 2 failure modes, Comb_3 SOTA                 |
| #13 | GCG (Zou et al.)                                  | arXiv 2023           | gradient suffix, perplexity에 탐지됨             |
| #13 | <b>AutoDAN</b> (Liu et al.)                       | ICLR 2024            | hierarchical GA, DAN 초기화, fluent             |
| #13 | <b>COLD-Attack</b> (Guo et al.)                   | ICML 2024            | COLD 알고리즘 그대로 + 공격 제약                        |
| #13 | <b>SafeDecoding</b> (Xu et al.)                   | ACL 2024             | LoRA expert contrastive, first m tokens      |
| #13 | <b>Gradient Cuff</b> (Hu et al.)                  | NeurIPS 2024         | refusal loss landscape, zeroth-order 2단계     |
| #13 | FGSM / PGD (Goodfellow / Madry)                   | ICLR 2015 / 2018     | 1-step vs multi-step+projection              |
| #14 | <b>DetectGPT</b> (Mitchell et al.)                | ICML 2023            | negative curvature, zero-shot, not black-box |
| #14 | <b>Fast-DetectGPT</b> (Bao et al.)                | ICLR 2024            | conditional curvature, ×340 가속               |
| #14 | <b>ReMoDetect</b> (Lee et al.)                    | NeurIPS 2024         | reward model의 LGT bias 역이용, training-based   |
| #14 | <b>Watermark</b> (Kirchenbauer et al.)            | ICML 2023            | green/red hash 분할, z-test, SynthID           |

## ✅ 마지막 점검 — 이거 헛갈리면 그 챕터 다시 봐

- 1 **Temperature**는 **softmax** 이전 로짓에 적용,  $\tau \downarrow = \text{deterministic}$ . Top-p 후보 개수는 동적. (#7)
- 2 Toolformer는  $L_i^- - L_i^+ \geq \tau$ 일 때 keep (반대 방향이면 False); 사실성 검사 안 함. (#10)
- 3  $A = Q - V$  (V-Q 아님); baseline은 **state에만** 의존해야 unbiased. (#12)
- 4 PPO clip:  $A > 0 \rightarrow \text{min이 상한(ceiling)}$ ,  $A < 0 \rightarrow \text{하한}$ . GRPO의 동기는 stability가 아니라 **value model 제거**. (#12)
- 5 Self-RAG=**SFT** / Search-R1=**RL**; 둘 다 검색된 토큰은 **loss에서 마스킹**. Search-R1 원버전 보상은 outcome만. (#9)
- 6 RetRobust NLI: **passage=premise**, **Q+A=hypothesis**; not-entailed면 재검색이 아니라 **direct answering**. (#9)
- 7 Good bot=**refuse**; prefix injection=next-token vs safety / refusal suppression=instruction following vs safety / **Base64=mismatched generalization**. (#13)
- 8 DetectGPT는 **black-box** 아님( $\log p_\theta$  필요); watermark 탐지는 **모델 접근 불필요**(z-test만). perturbation은 별도 T5. (#14)
- 9 **RBRM=rule-based**(선호 데이터 학습 ×); LC win rate=회귀로 length 제거; position bias swap은 **2× cost**, 불일치=Tie. (#8/#13)
- 10 MemGPT: **70%=경고만**, **100%=50% evict+recursive summary**; LLaVA encoder는 **두 단계 모두 frozen**; Reflexion은 weight update 없음. (#11)

← 전체 목차

다음 장 →