

CAS4133 LLM · 기말 대비 · Chapter #13 (Special Lecture)

7. Jailbreak 정리 (Jailbreak of Large Language Models)

LLM 가드레일을 우회하는 공격(DAN → GCG → AutoDAN → COLD-Attack)과 이를 막는 방어(Red Teaming/RBRM → SafeDecoding → Gradient Cuff)의 공방전

 강의일: Special Lecture #13 예상 비중: 중상 (기말 신규 범위) 분량: 본문 7섹션 + 문제 14

출제 방식 공지 (교수 안내)

Special Lecture 두 개(#13 Jailbreak + #14 AI Text Detection)는 **하나의 챕터(Problem)로 묶여 multiple choice 문제로만 출제**된다. True/False가 아닌 **"Pick all that are correct" 형식**이므로 보기 4개를 각각 독립적으로 O× 판정하는 연습이 핵심. 두 특강 개념이 한 문제 안에 섞여 나올 수 있으니(예: COLD-Attack과 DetectGPT의 perturbation 차이) **#14 정리**와 묶어서 공부할 것.

목차

1. LLM 오용 위험과 Training-level 안전 대책 (Red Teaming, RBRM)
2. DAN Prompting과 Adversarial Robustness의 유비
3. Jailbreaking 기초 — 정의와 두 가지 Failure Mode (Jailbroken)
4. 자동화 공격 ①: GCG의 한계와 AutoDAN (Genetic Algorithm)
5. 자동화 공격 ②: COLD Decoding과 COLD-Attack
6. 방어 ①: SafeDecoding (Safety-Aware Contrastive Decoding)
7. 방어 ②: Gradient Cuff (Refusal Loss Landscape)
8. 예상문제 (T/F 8 + Pick-all 6)

LLM 오용 위험과 Training-level (Risk of Misuse & Safety Pipeline) 안전 대책

RLHF까지 마친 정렬(alignment)된 LLM도 **오용 위험(risk of misuse)**은 여전히 남는다. 강의에서는 한국의 챗봇 **이루다(Lee Luda)** 사례를 들었다 — 혐오 발언(hate speech)·개인정보(privacy) 문제로 서비스가 종료되었다. 이를 줄이기 위한 두 가지 **training-level 대책**이 GPT-4 Technical Report(OpenAI)에 소개되어 있다.

Approach #1: Red Teaming with Human Experts

정의

Red Teaming: 도메인 전문가(domain experts)를 고용해 "*prohibited되어야 하는데 LLM이 허용해버리는(should be prohibited yet allowed)*" 프롬프트를 찾게 하고, 수집된 프롬프트를 사람이 올바른 행동으로 라벨링하여 **추가 학습 데이터**(instruction tuning / RLHF 단계)로 사용하는 방법.

교수 강조 (강의 발언)

"Red teaming with human experts is quite a good and standard way, but the one certain disadvantage is the **cost for hiring the human experts.**" → 이 비용 문제가 Approach #2의 동기.

Approach #2: Model-Assisted Safety Pipeline (RBRM)

RLHF 과정을 **안전 전용 추가 reward model**로 보강(augment)하는 접근이다.

- 프롬프트 수집** — sensitive / disallowed 등 카테고리별 입력 프롬프트를 수집
- 응답 생성 후 RBRM으로 라벨링** — **Rule-Based Reward Models (RBRMs)**가 사전 정의된 규칙(pre-defined rules)으로 보상 부여: 예) 원하는 스타일로 거절(Refusal with desired style) → **1**, 금지 콘텐츠 포함(Containing disallowed content) → **0**

이 노력들로 GPT-4의 안전성은 크게 개선되었다. 강의 설명: text-davinci-003(초기 InstructGPT) 대비 GPT-3.5 Turbo는 **disallowed prompt**에서의 incorrect behavior rate가 크게 줄었지만 **sensitive**

prompt에서는 불충분했고, GPT-4에 와서 sensitive prompt에서도 크게 감소했다.

★ 시험 핵심

Red Teaming = 사람 전문가 + 추가 학습 데이터 / Model-Assisted Safety Pipeline = **RBRM**이
규칙 기반으로 보상을 주 RLHF를 보강. 둘 다 **training-level defense**로 분류된다(↔
SafeDecoding·Gradient Cuff는 inference-level).

⚠ 함정 포인트 (T/F 대비)

- "RBRMs are reward models trained on human preference data." → **False**. RBRM은 *pre-defined rules*에 따라 보상을 부여하는 rule-based 모델이다.
- "Red teaming eliminates the risk of misuse of LLMs." → **False**. 이 방법들로도 위험이 완전히 해소되지 않으며(DAN 등 stronger attack 존재), 이것이 jailbreak 연구의 출발점.
- "The model-assisted safety pipeline replaces RLHF." → **False**. RLHF를 대체하는 게 아니라 safety reward model로 *augment*한다.

Do Anything Now (DAN) Prompting

정의

DAN (Do Anything Now) prompting: LLM에게 "이제 무엇이든 할 수 있는" 역할을 부여하는 수작업 프롬프트로, 사전 정의된 **guardrail**을 쉽게 우회(**bypass**)하는 jailbreak의 대표 사례 (Reddit 유래).

강의 예시: 현재 시각을 물으면 원래 GPT는 실시간 추적 능력이 없어 거절해야 하지만, DAN 하에서는 특정 시각을 답한다 — 이는 **hallucination(가짜 정보)**이다. 히틀러 관련 민감 질문도 vanilla GPT는 거절하지만 DAN 하에서는 구체적으로 답변한다.

Adversarial Robustness와의 유사성

Jailbreaking은 컴퓨터 비전의 **adversarial robustness**와 매우 유사한 구도다(공격 ↔ 방어 군비경쟁).

개념	내용	출처
Adversarial example/noise	사람 눈에는 imperceptible 하지만 DNN 출력을 크게 바꾸는 노이즈 (panda 57.7% → gibbon)	Goodfellow et al., ICLR 2015
FGSM (Fast Gradient Signed Method)	single iteration with gradient sign — 가장 기본적인 공격	Goodfellow et al., ICLR 2015
Adversarial training	adversarial example을 생성해 추가 학습 데이터 (data augmentation) 로 사용하는 방어 → FGSM 강건성 크게 개선	Madry et al., ICLR 2018
PGD attack (Projected Gradient Descent)	one-step(FGSM) 대신 multiple steps of noise update + projection → 더 강한 공격, 정확도 ~0%까지 하락	Madry et al., ICLR 2018

 교수 강조 (강의 발언)

"Attack #1 → defense #1 → attack #2 ... this kind of development is continuously happening" — adversarial robustness는 NeurIPS 2020에서 **전체 토픽 중 논문 수 #1**이었고, jailbreaking은 LLM 맥락에서의 adversarial robustness로 볼 수 있다.

 함정 포인트 (T/F 대비)

- "PGD uses a single gradient step like FGSM." → **False**. FGSM이 single iteration, PGD는 *multiple steps + projection*.
- "Adversarial training fully defends against PGD." → **False**. adversarial training 후에도 PGD 같은 stronger attack에는 충분히 방어하지 못했다.
- "DAN prompts are generated by gradient-based optimization." → **False**. DAN은 사용자들이 *manually* 작성한 프롬프트다(이 수작업의 scalability 한계가 GCG의 동기).

Jailbreaking 기초 — 정의와 두 가지 (Jailbroken, NeurIPS 2023 Oral)

Failure Mode

형식적 정의 (Wei et al., Jailbroken: How Does LLM Safety Training Fail?)

정의

- **Restricted behaviors**: safe LLM이 피하도록 학습된(*trained to avoid*) 행동.
- **Jailbreak attack**: restricted behavior에 대한 프롬프트 P 의 **on-topic response**를 끌어내기 위해 수정된 프롬프트 P' 을 제출하는 시도.

P 와 P' 에 대한 결과(outcome)에 따라 3가지 클래스를 정의한다:

클래스	조건
Good bot	LLM이 P' 을 refuse 하는 경우
Bad bot	LLM이 P' 에 대해 P 에 대한 on-topic response 로 응답하는 경우 (jailbreak 성공)
Unclear	그 외 (둘 다 아닌 경우)

Failure Mode #1: Competing Objectives

최근 LLM의 복잡한 학습 파이프라인(pre-training + instruction tuning + RLHF)에서 각 부분의 목적이 서로 충돌(conflict)할 수 있다는 관찰에서 출발.

- **Prefix Injection** (next token prediction vs. safety training) — LLM이 먼저 무해해 보이는 (innocuous-looking) prefix("Absolutely! Here's...")를 출력하게 만들면, 그 prefix에 조건부(conditioning)로는 refusal이 unlikely해진다.
- **Refusal Suppression** (instruction following vs. safety training) — "do not apologize", "never say cannot/unable" 등 흔한 거절 응답을 배제하는 제약(constraints that rule out common refusal responses) 하에 응답하도록 지시 → unsafe response가 more likely. DAN prompting도 이 카테고리에 해당.

Failure Mode #2: Mismatched Generalization

Pre-training은 **safety training**보다 더 크고 다양한(**larger/diverse**) 데이터로 수행된다는 관찰. 이 mismatch를 악용해, *pre-training과 instruction tuning은 generalize하지만 safety training은 generalize하지 못하는* 프롬프트를 구성하면, LLM은 **safety consideration 없이** 응답하게 된다.

📚 교수 강조 (강의 발언)

"**Base64** is an encoding method that converts natural syntax to machine-oriented one. With high probability the LLM learns it during pre-training, but it will not be utilized during safety training — so the LLM was never trained to prohibit prompts in this encoding, and jailbreaking can succeed."

Combination Attacks & Experiments

- **Comb_1** = Prefix injection + Refusal suppression + **Base64** attack
- **Comb_2** = Comb_1 + **Style injection** ("asking for no long words" — *refusals are usually long*이므로)
- **Comb_3** = Comb_2 + **website content 생성 + formatting constraints** (여러 task를 동시에 요청하면 단일 task 거절 확률이 줄어든다는 관찰)

실험 데이터셋: (1) OpenAI·Anthropic의 red-teaming 노력에서 가져온 **32개 curated prompts**, (2) GPT-4가 생성한 **317개 synthetic prompts**. 결과: **Comb_3가 SOTA 공격 성공률**; **AIM**은 웹 사용자들이 (원리 없이) 만든 combination attack(jailbreakchat.com)인데 Comb_3가 이보다 강함;

Adaptive attack은 평가된 **28개 공격 중 하나라도 성공하면 성공**으로 치는 oracle — GPT-4와 Claude 조차 가드레일이 뚫린다.

★ 시험 핵심

두 failure mode의 이름·원인·예시 매칭이 최우선: **Competing objectives**(파이프라인 목적 충돌) → prefix injection-refusal suppression-DAN / **Mismatched generalization**(pre-training ⊃ safety training 데이터) → Base64. Good/Bad bot 정의 방향도 자주 헷갈리니 암기.

⚠ 함정 포인트 (T/F 대비)

- "A 'good bot' is one that responds helpfully to the modified prompt P' ." → **False**. Good bot은 P' 을 *refuse*하는 경우다. on-topic 응답이면 *bad bot*.

- "Base64 attack exploits competing objectives." → **False**. Base64는 *mismatched generalization*의 예시.
- "Prefix injection exploits the conflict between instruction following and safety training." → **False**. prefix injection은 *next token prediction* vs. safety training. instruction following vs. safety training은 *refusal suppression*.
- "Style injection asks for no long words because refusals are usually long." → **True**. (그대로 출제 가능한 디테일)
- "The adaptive attack is a single new attack method." → **False**. 28개 공격 중 *any one* 이 성공하면 성공으로 보는 oracle 지표.

수작업 jailbreak의 두 가지 한계와 GCG

1. **Scalability 문제** — DAN 같은 프롬프트는 **manually written**이라 확장 불가 → **learning-based 접근 GCG** (Greedy Coordinate Gradient; Zou et al., *Universal and Transferable Adversarial Attacks on Aligned Language Models*) 등장. GCG는 **adversarial objective**를 설정하고 이를 최소화하는 후보를 **gradient 기반으로 탐색**한다 (affirmative target에 대한 cross-entropy 최소화).
2. **Stealthiness 문제** — GCG가 만드는 프롬프트(adversarial suffix)는 **semantically meaningless** → **perplexity** 같은 language-based detector에 매우 쉽게 탐지된다.

AutoDAN (Liu et al., ICLR 2024): 개요와 목적함수

정의

AutoDAN: stealthy(=fluent)한 jailbreak prompt를 자동 생성하는 것이 목표. 핵심 아이디어는 GCG의 greedy search 대신 **hierarchical genetic algorithm**을 사용하는 것.

Notation: malicious questions $\mathbf{Q} = \{Q_1, \dots, Q_n\}$, jailbreak prompts $\mathbf{J} = \{J_1, \dots, J_n\}$, combined input $\mathbf{T} = \{T_i := \langle J_i, Q_i \rangle\}$, LLM responses $\mathbf{R} = \{R_1, \dots, R_n\}$. 목표는 R_i 가 refusal이 아니라 Q_i 와 **closely associated**되게 만드는 것.

각 Q_i 에 정답 라벨을 다는 것은 impractical → 공통 관행(GCG 따라)으로 **target response를 affirmative로 지정**: "Sure, here is how to [Q_i]." 이런 **proxy target** $R_i \cong \langle r_{m+1}, \dots, r_{m+k} \rangle$ 을 두면 목표는:

AutoDAN 최적화 목표 (proxy target의 likelihood 최대화)

$$\max_{J_i} \prod_{t=1}^k p(r_{m+t} \mid J_i, Q_i, r_{m+1:m+t-1})$$

jailbreak prompt J_i 를 최적화하여, 입력(J_i, Q_i)과 이전 토큰들이 주어졌을 때 affirmative proxy target의 생성 확률을 최대화. 이 likelihood가 곧 fitness score로 쓰인다.

Genetic Algorithm 3단계

Genetic algorithm은 (1) 기존 후보로부터 새 후보(population) 생성(mutation/crossover) ↔ (2) 평가·선택을 반복하는 **metaheuristic**이다.

- 1 Population Initialization** — 이미 효과가 입증된 **handcrafted jailbreak prompt(DAN 등)**로 초기화 + 다양성을 위해 LLM에게 "revise the following sentence with no change to its length"라고 시켜 diversified 버전 생성
- 2 Fitness (quality) Evaluation** — 위의 **proxy target에 대한 likelihood**를 fitness score로 사용
- 3 Genetic Policies** — **AutoDAN-GA**: fitness 상위 **top-K = elite prompts** 보존, 나머지에서 N-K개의 parent를 fitness 비례 확률(softmax)로 추가 선택 → **Crossover**(문단 내 *문장 교환*, *swapping sentences in paragraphs*) + **Mutation**(LLM-based diversification).
AutoDAN-HGA: 자연어의 계층성을 반영해 **word scoring을 통한 sentence-level mutation**을 추가 — word score는 iteration에 걸친 **average와 momentum**으로 계산.

실험 (AdvBench) & 결과

- Dataset**: AdvBench Harmful Behaviors — 520 prompts
- Metrics**: ① **ASR**(attack success rate) — keyword 기반("I'm sorry", "As a responsible AI" 검출 시 실패 처리) ② **Recheck** — keyword 방식의 불완전성을 보완하기 위해 **GPT에게 공격 성공 재평가를 prompting** ③ **PPL**(sentence perplexity) — **GPT-2로 측정**한 프롬프트 품질
- 결과**: GCG·AutoDAN 모두 공격은 성공하지만 **GCG는 PPL이 매우 높아 perplexity filter에 쉽게 걸림** → perplexity defense 하에서 GCG 효과는 급감, **AutoDAN은 효과 유지** (PPL이 handcrafted DAN과 비슷한 수준)
- Transferability**: Vicuna로 만든 프롬프트가 Guanaco·Llama 등 다른 모델에 전이(transfer)됨 + 샘플 간 **universality**도 확인
- Ablation**: ① DAN을 이용한 좋은 initialization ② LLM-based mutation ③ hierarchical GA(HGA) 모두 중요

구분	GCG	AutoDAN
탐색 방식	greedy gradient-based search (continuous space)	hierarchical genetic algorithm (discrete space)

프롬프트 생성	자동 (learning-based)	자동 (learning-based)
Fluency / Stealth	semantically meaningless → perplexity filter에 취약	fluent → perplexity defense에도 효과 유지
목적함수	affirmative target에 대한 CE 최소화	동일한 proxy target likelihood를 fitness 로 사용

★ 시험 핵심

공통 관행 = **affirmative proxy target ("Sure, here is how to ...")의 likelihood 최대화** — GCG·AutoDAN·COLD-Attack이 전부 공유한다. AutoDAN 3단계(초기화→fitness→GA policies)와 GA vs HGA 차이(HGA = +sentence-level mutation via word scoring), 3개 평가 지표(ASR/Recheck/PPL)는 그대로 출제 가능.

⚠ 함정 포인트 (T/F 대비)

- "AutoDAN uses gradient-based greedy search like GCG." → **False**. AutoDAN은 GCG의 greedy search를 *genetic algorithm*으로 대체했다.
- "AutoDAN initializes its population with random strings." → **False**. *handcrafted* jailbreak prompt(DAN)로 초기화 + LLM 기반 다양화. ablation에서 이 초기화가 매우 중요함이 확인됨.
- "ASR in AutoDAN's experiments is computed by prompting GPT to judge." → **False**. ASR은 *keyword 기반*; GPT 판정은 별도 지표 *Recheck*.
- "Crossover in AutoDAN-GA swaps individual words." → **False**. crossover는 문단 내 문장(*sentences*) 교환; word 수준은 HGA의 word scoring 기반 mutation에서 다룬다.
- "GCG prompts easily evade perplexity-based detectors." → **False**. 정반대 — GCG는 perplexity filter에 쉽게 탐지된다.

AutoDAN의 한계 → COLD-Attack의 동기

- 한계 ①: genetic algorithm의 **search space**가 상대적으로 작다 (discrete < continuous — GCG는 continuous space 기반)
- 한계 ②: **fluency**만으로는 **stealthiness**가 보장되지 않는다

정의

COLD-Attack (Guo et al., ICML 2024): jailbreak prompt 생성에 **multiple constraints**(fluency, lexical constraint, semantic similarity 등)를 통합하는 것이 목표. 핵심 통찰은 **controlled text generation 기법(COLD Decoding)**을 **jailbreaking에 활용**하는 것 — 이름도 COLD Decoding에서 따왔다.

COLD Decoding 복습 (Qin et al., NeurIPS 2022)

#7 Decoding과 연결

핵심 아이디어: (1) 제약을 수식으로 정식화 & (2) **gradient-based update**로 제약 만족.

- 출력 텍스트 $\mathbf{y} \in \mathbb{N}^T$ 는 discrete → 대신 **logit** $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$ (V = vocab size)를 다뤄 continuous space에서 최적화
- 각 제약은 함수 $f_i(\mathbf{y}) \in \mathbb{R}$ 로 표현 (예: fluency 제약 = $\mathbf{y}$ 의 likelihood)

Energy function과 energy-based 분포 (EBM에서 동기)

$$E(\mathbf{y}) := - \sum_i \lambda_i f_i(\mathbf{y}), \quad \mathbf{y} \sim p(\mathbf{y}) \propto \exp(-E(\mathbf{y}))$$

λ_i 는 제약별 계수. 제약 하의 텍스트 생성 = 이 energy-based distribution에서의 샘플링. 효율적 샘플링은 gradient $\nabla_{\mathbf{y}} E(\mathbf{y})$ 를 쓰는 **Langevin dynamics**로.

Langevin dynamics (Markov chain의 gradient step)

$$\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}, \quad \epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$$

η = step size, $\epsilon^{(n)}$ = iteration n 의 noise. $n \rightarrow \infty$ 일 때 $\tilde{\mathbf{y}}^{(n)}$ 의 분포가 $p(\tilde{\mathbf{y}})$ 로 수렴함이 증명되어 있다 (Welling et al., ICML 2011). 교수: "adversarial attack과 매우 유사 — gradient로 energy를 낮추는 작은 step."

COLD-Attack: COLD Decoding과의 관계 & 제약 설계

📖 교수 강조 (강의 발언)

"The underlying algorithm is **exactly the same** as COLD Decoding. The only differences are (1) its **purpose** (jailbreak prompt 생성) and (2) the **newly proposed constraints** for this."

- **(1) Attack success 제약**: AutoDAN과 동일하게 **proxy target $\mathbf{z}$** (예: "Sure, here is [malicious user request].")의 likelihood
- **(2) Fluency 제약**: LM likelihood
- **(3) 기타**: semantic similarity(원문과의 의미 유사성), lexical constraint(n-gram uniqueness 등)

실험 결과 (데이터셋 지표는 AutoDAN과 동일)

- AutoDAN 대비 비슷하거나 더 좋은 **ASR** + 비슷하거나 더 낮은 **PPL** (perplexity filter 우회에 중요)
- 더 다양한(**diverse**) **jailbreak prompt** 생성
- **효율성**: 프롬프트 생성 시간이 **GCG·AutoDAN보다 훨씬 짧다**

구분	GCG	AutoDAN	COLD-Attack
탐색/최적화	greedy coordinate gradient (continuous)	hierarchical genetic algorithm (discrete)	Langevin dynamics on logits (continuous, energy-based)
Stealth (PPL)	나쁨 (탐지 쉬움)	좋음 (fluent)	좋음 + 다중 제약 제어 가능
제어 가능 제약	attack success만	attack success + fluency(GA 부산물)	attack success + fluency + semantic similarity + lexical 등 자유롭게 추가

⚠ 함정 포인트 (T/F 대비)

- "COLD-Attack proposes a fundamentally new sampling algorithm different from COLD Decoding." → **False**. 알고리즘은 *exactly the same*; 목적과 제약(energy function)만 새로 제안.
- "COLD-Attack performs gradient updates directly on discrete tokens $\mathbf{y}$." → **False**. discrete space의 어려움 때문에 *logit* $\tilde{\mathbf{y}}$ (continuous)에서 업데이트.
- "In the energy function, higher energy means better constraint satisfaction." → **False**. $E = - \sum \lambda_i f_i$ 이므로 제약을 잘 만족할수록 energy는 낮다.
- "COLD-Attack is slower than AutoDAN because it handles multiple constraints." → **False**. COLD-Attack이 GCG·AutoDAN보다 더 효율적(짧은 생성 시간)이다.

Red Teaming-RBRM이 **training-level defense**라면, SafeDecoding(Xu et al., ACL 2024)은 **inference-level(decoding 단계) defense**다.

관찰과 핵심 아이디어

정의

SafeDecoding: 디코딩 중 malicious prompt에 응답할 위험을 직접 줄이는 방법. **관찰** — 출력 토큰 확률분포에는 refusal 토큰과 accept 토큰이 둘 다 높은 확률로 존재한다(예: jailbreak 성공 시 "Sure"가 1등이지만 "Sorry/I" 등 refusal 계열도 상위권). **아이디어** — **safe(refusal) 토큰의 확률은 키우고 risky 토큰의 확률은 줄인다**. 도구는 **contrastive decoding** (Li et al., ACL 2023).

Step #0 (Training): Expert model 구축

- 1 36개 harmful queries 수집 — well-aligned LLM이라면 거절할 것으로 기대되는 쿼리
- 2 LLM이 자율적으로 응답 생성 (prompting LLM to autonomously generate responses)
- 3 GPT-4로 필터링 — harmful query를 거절한 응답만 보존
- 4 이 query-response 쌍으로 target 모델을 LoRA로 fine-tuning → expert model 완성

Step #1 (Inference): Sample space $\mathcal{V}_n^{(c)}$ 구성

Sample space (plausibility constraint)

$$\mathcal{V}_n^{(c)} = \text{smallest } k \text{ such that } |\mathcal{V}_n^k \cap \mathcal{V}_n'| \geq c$$

$\mathcal{V}_n = x_{1:n-1}$ 다음에 올 수 있는 모든 토큰 집합, $\mathcal{V}_n^k$ = 원본 모델의 top-k, $\mathcal{V}_n'$ = expert model 쪽 토큰 집합. **두 모델 top-k의 교집합**이 하이퍼파라미터 c 이상이 되도록 잡는다 — c 는 SafeDecoding이 요구하는 **sample space의 최소 크기** (c 가 너무 작으면 sample space가 제한됨).

Step #2 (Inference): 확률함수 P_n 정의

SafeDecoding 확률 (contrastive 보정)

$$P_n(x) = p_\theta(x \mid x_{1:n-1}) + \alpha(p_{\theta'}(x \mid x_{1:n-1}) - p_\theta(x \mid x_{1:n-1}))$$

θ = 원본 모델, θ' = expert 모델, $\alpha \geq 0$ 은 하이퍼파라미터. P_n 은 $\sum_{x \in \mathcal{V}_n^{(c)}} P_n(x) = 1$ 로 정규화 → 확률이므로 greedy/beam search 등 어떤 디코딩 알고리즘도 그 위에 적용 가능.

- **Case 1 — benign query**: 원본·expert 모두 긍정적으로 응답 → 뒤 항이 **cancel out** → 사실상 원본 p_θ 에서 생성 (utility 보존)
- **Case 2 — malicious(jailbreak) query**: human-aligned 토큰이면 expert가 더 높은 확률을 줘서 뒤 항이 **양수**(확률 ↑), unsafe 토큰이면 **음수**(확률 ↓)

Heuristic: 처음 m 토큰에만 적용

📢 교수 강조 (강의 발언)

"Contrastive decoding requires **two separate forward passes**, so it increases computational cost. The acceptance or refusal is usually **decided within the first few tokens** — 'Sure, here is how to make a bomb' or 'I'm sorry, I can't' — so they apply SafeDecoding only for the **first m steps**." (+ 뒤쪽 토큰에선 benign case에 덜 도움됨)

실험 결과

- (행=defense, 열=attack) 모든 공격에 대해 **SafeDecoding이 defense 중 최고 성능**
- **Utility 보존**: Self-Examination은 MT-Bench 등에서 성능이 크게 하락, ICD·Paraphrase도 비슷한 문제 — SafeDecoding은 **vanilla 성능을 가장 잘 보존**
- Heuristic 덕분에 **inference time 증가도 크지 않음**

★ 시험 핵심

SafeDecoding = **expert(LoRA로 safety fine-tune된) 모델과 원본 모델의 확률 차이를 α 배 더 하는 contrastive decoding**. 36 harmful queries → LLM 자율 생성 → GPT-4 필터 → LoRA, 그리고 "first m tokens" heuristic의 근거(refusal/accept는 첫 몇 토큰에서 결정)가 단골 출제 디테일.

⚠ 함정 포인트 (T/F 대비)

- "SafeDecoding is a training-level defense." → **False**. *inference(decoding)-level* defense다 (expert model 구축에 학습이 들어가긴 하지만 방어 자체는 디코딩 단계).
- "The expert model is trained from scratch on a large safety corpus." → **False**. *target* 모델을 LoRA로, GPT-4로 필터링한 (36 harmful query 기반) 소규모 거절 데이터로 fine-tuning.
- "SafeDecoding applies the modified probability to all generated tokens." → **False**. 비용 절감과 benign 케이스 고려로 *first m tokens*에만 적용.
- "For benign queries, SafeDecoding significantly alters the output distribution." → **False**. 두 모델이 비슷하게 반응하므로 보정향이 cancel out → 원본 분포 유지.
- "After SafeDecoding's probability adjustment, only greedy decoding can be used." → **False**. P_n 은 정규화된 확률이므로 greedy·beam search 등 임의의 디코딩 적용 가능.

목표와 핵심 통찰

정의

Gradient Cuff (Hu et al., NeurIPS 2024): jailbreak prompt를 탐지(detect)하고 응답을 거부하는 방어. 핵심 통찰 — LLM의 **refusal loss**를 정의·조사하면 **benign** 쿼리는 **평평한(flat) loss surface**, **malicious** 쿼리는 **가파른(steeep) loss surface**라는 다른 행태를 보인다. 2단계 필터: ① 쿼리의 **refusal loss** 확인 ② loss function의 **gradient norm** 확인.

Refusal Loss 정의

Refusal loss

$$\phi_{\theta}(x) = 1 - p_{\theta}(x), \quad p_{\theta}(x) = \mathbb{E}_{y \sim T_{\theta}(x)} [JB(y)]$$

T_{θ} = LLM, y = 응답, $JB(y)$ = 응답이 refusal인지의 **binary indicator**. p_{θ} = refusal을 받을 기대 비율, $\phi_{\theta}(x)$ = **non-refusal**을 받을 **likelihood**.

- $JB(y)$ 는 prior work(**SmoothLLM**) 따라 **keyword 기반**: y ="Sure, here is the python code to ..." → $JB = 0$ (공격 성공), y ="Sorry, I cannot fulfill your request..." → $JB = 1$ (refusal)
- $Y = JB(y)$ 를 확률 p_{θ} 의 **Bernoulli** 확률변수로 보면 $\phi_{\theta}(x)$ 는 **expected refusal loss** → $\phi_{\theta}(x) < 0.5$ 를 탐지 기준으로 쓸 수 있음
- 실제로는 p_{θ} 를 모르므로 **여러 번 샘플링한 sample mean** $f_{\theta}(x)$ 로 대체 → **Idea #1: $f_{\theta}(x) < 0.5$ 이면 reject**

Loss surface 시각화와 Gradient Norm

두 random vector δ, η 를 이용한 보간(Li et al., *Visualizing the Loss Landscape of Neural Nets*, NeurIPS 2018 방식)으로 refusal loss surface를 시각화 → **malicious는 steep, benign은 flat**. "어떤 측정량이 이 차이를 포착하나?" → **Gradient Norm** (malicious 쿼리의 gradient norm이 훨씬 크다).

Zeroth-order Gradient Estimation

그러나 LLM의 **discrete 연산 때문에** $\phi_\theta(x)$ 의 **exact gradient**는 계산 불가(**infeasible**) → **zeroth-order gradient estimation**: perturbed input들에 대한 **함수값 차이로 gradient를 근사** (Taylor expansion에서 2차 이상 항 무시).

- 쿼리 x (n tokens)의 word embedding $e_\theta(x) \in \mathbb{R}^{n \times d}$ 에 **mean pooling**을 적용해 sentence embedding을 얻음 — mean pooling은 perturbation $\mathbf{v}$ 에 대한 등가성(개별 원소에 더하는 것과 동일) 성질이 있음

Directional derivative approximation (estimated gradient)

$$g_\theta(x) = \frac{1}{P} \sum_{i=1}^P \frac{f_\theta(e_\theta(x) \oplus \mu \mathbf{u}_i) - f_\theta(e_\theta(x))}{\mu} \mathbf{u}_i$$

$\mathbf{u}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 는 d차원 random vector, μ = smoothing parameter, $\oplus$ = row-wise broadcasting add. 여러 방향을 평균해 단일 추정의 분산을 줄인다. 논문의 정리: random vector 수 P 가 커질수록 추정이 정확 (교수: "easy to derive, recommend for study").

Overall Method (2단계 필터)

- 1 Sampling-based Rejection** — 응답을 여러 번 샘플링해 keyword 검출로 $f_\theta(x)$ 계산; $f_\theta(x) < 0.5$ 이면 **reject**. (예: Vicuna에선 이 단계로 탐지되지만 Llama에선 놓칠 수 있음)
- 2 Gradient Norm Rejection** — 추정 gradient $g_\theta(x)$ 의 norm이 **pre-defined threshold t 보다 크면 reject**. (step 1에서 Llama가 놓친 malicious 쿼리를 여기서 분리) 두 필터를 모두 통과하면 benign으로 accept.

실험 (AdvBench 100 harmful instructions)

평가지표

$$\text{FPR} = \frac{FP}{FP + TN}, \quad \text{TPR}(= \text{recall}) = \frac{TP}{TP + FN}$$

이상적으로 **FPR ↓ (benign을 잘못 거절할 위험)**, **TPR ↑ (malicious 탐지율)**.

- Gradient Cuff는 Llama·Vicuna 모두에서 **낮은 FPR + 높은 TPR** — 둘을 함께 보면 거의 최적

- **MMLU로 측정한 원래 LLM 성능이 잘 보존됨** (SmoothLLM은 보존 실패)
- vs. **SafeDecoding**: SafeDecoding은 **FPR이 높다(바람직하지 않음)**는 단점이 있지만 **TPR도 높다**
→ **trade-off가 존재하므로 어느 방법이 더 낫다고 결론 내릴 수 없다** (교수가 명시적으로 강조)

구분	SafeDecoding (ACL 2024)	Gradient Cuff (NeurIPS 2024)
방어 유형	inference-level — 디코딩 분포 수정	inference-level — 쿼리 탐지 후 거부
핵심 도구	contrastive decoding (expert – original)	refusal loss + zeroth-order gradient norm
추가 학습	필요 (LoRA expert model)	불필요 (loss landscape 관찰만)
판정 신호	토큰 확률 보정 (first m tokens)	① $f_{\theta}(x) < 0.5$ ② $\ g_{\theta}(x)\ > t$
실험상 특성	높은 TPR, 그러나 높은 FPR	낮은 FPR + 높은 TPR, MMLU 보존

⚠ **함정 포인트 (T/F 대비)**

- "Gradient Cuff computes the exact gradient of the refusal loss by backpropagation." → **False**. discrete 연산 때문에 exact gradient는 infeasible → *zeroth-order estimation*(함수값 차이) 사용.
- "A query is rejected when $f_{\theta}(x) > 0.5$." → **False**. $f_{\theta}(x) < 0.5$ (non-refusal 가능성이 높을 때 = expected refusal이 낮을 때) 거절. 부등호 방향 주의.
- "Benign queries exhibit steep refusal loss landscapes." → **False**. benign = flat, malicious = steep.
- " $JB(y) = 1$ when the model is successfully jailbroken." → **False**. $JB(y) = 1$ 은 *refusal* 응답일 때; jailbreak 성공("Sure, here is...")이면 0.
- "Gradient Cuff strictly dominates SafeDecoding in all metrics." → **False**. SafeDecoding은 FPR이 높지만 TPR도 높음 — trade-off라 우열 결론 불가.

- "FPR should be high and TPR should be low for a good detector." → **False**. 반대 — FPR ↓, TPR ↑.

Q 예상문제 (기출 직접 문항 없음 — 중간고사 이후 범위)

True / False

Q1. (True/False) 예상문제

In the Jailbroken paper, an LLM is classified as a "bad bot" if it refuses the modified prompt P' .

▼ 정답 & 해설 보기

False. If the LLM refuses P' , it is a *good bot*. A bad bot is when the LLM responds to P' with an on-topic response to the original prompt P ; all other cases are "unclear".

Q2. (True/False) 예상문제

The Base64 attack succeeds because pre-training is done on larger and more diverse data than safety training, so the safety training fails to generalize to Base64-encoded prompts.

▼ 정답 & 해설 보기

True. This is exactly the *mismatched generalization* failure mode: pre-training (and instruction tuning) generalize to the encoding, but safety training does not, so the model responds without safety considerations.

Q3. (True/False) 예상문제

AutoDAN replaces the greedy gradient-based search of GCG with a hierarchical genetic algorithm in order to generate stealthy (fluent) jailbreak prompts.

▼ 정답 & 해설 보기

True. AutoDAN's goal is to automatically generate stealthy, i.e., fluent, jailbreak prompts, and its key idea is the hierarchical genetic algorithm substituting GCG's greedy search. Unlike GCG's semantically meaningless suffixes, AutoDAN's prompts maintain low perplexity and survive perplexity-based defenses.

Q4. (True/False) 예상문제

In AutoDAN, the fitness of a candidate jailbreak prompt is evaluated using the likelihood of an affirmative proxy target such as "Sure, here is how to [Qi]."

▼ 정답 & 해설 보기

True. Since labeling each malicious question is impractical, the common practice (following GCG) is to designate the target response as affirmative, and AutoDAN uses the likelihood of this proxy target as the fitness score.

Q5. (True/False) 예상문제

COLD-Attack performs Langevin dynamics updates directly in the discrete token space to satisfy multiple constraints.

▼ 정답 & 해설 보기

False. Gradient updates in the discrete token space are infeasible. COLD Decoding (and thus COLD-Attack) operates on the *logits* $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$, a continuous space, where the Langevin dynamics gradient step is performed.

Q6. (True/False) 예상문제

SafeDecoding constructs its expert model by fine-tuning the target model with LoRA on query-response pairs where the responses, filtered by GPT-4, refuse harmful queries.

▼ 정답 & 해설 보기

True. 36 harmful queries are collected, the LLM autonomously generates responses, GPT-4 filters them so that only refusing responses are kept, and the target model is fine-tuned via LoRA on this dataset to obtain the expert model.

Q7. (True/False) 예상문제

SafeDecoding applies its modified probability function to every decoding step, which is why its inference cost is roughly double that of vanilla decoding.

▼ 정답 & 해설 보기

False. SafeDecoding uses a heuristic of applying the safety-aware probability only for the *first m tokens*, motivated by the observation that acceptance/refusal is usually decided within the first few tokens. Thanks to this heuristic, the increase in inference time is not large.

Q8. (True/False) 예상문제

Gradient Cuff rejects a query x in its first stage when the sample mean of the refusal loss satisfies $f_{\theta}(x) < 0.5$, and in its second stage when the estimated gradient norm exceeds a pre-defined threshold.

▼ 정답 & 해설 보기

True. Step #1 is sampling-based rejection ($f_{\theta}(x) < 0.5$, estimated via multiple samplings since p_{θ} is unknown), and Step #2 is gradient norm rejection ($\|g_{\theta}(x)\| > t$, with the gradient estimated by zeroth-order methods). A query passing both filters is accepted as benign.

Pick all that are correct (any wrong answer will lead to 0 points)

Q9. (Pick all that are correct) 예상문제

Which of the following are true about the two failure modes identified in the Jailbroken paper (Wei et al., NeurIPS 2023)?

- a. Prefix injection exploits the competition between next token prediction and safety training: once an innocuous-looking prefix is generated, conditioning on it makes refusal unlikely.
- b. Refusal suppression instructs the LLM to respond under constraints that rule out common refusal responses, and DAN prompting also belongs to this category.
- c. Mismatched generalization arises because safety training uses larger and more diverse data than pre-training.
- d. Combination 3, which adds website-content generation and formatting constraints, achieved the state-of-the-art attack success rate.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. Prefix injection = next token prediction vs. safety training.
- (b) Correct. Refusal suppression = instruction following vs. safety training; DAN corresponds to this category.
- (c) Incorrect. The direction is reversed: *pre-training* is done on larger/more diverse data than safety training, which is what jailbreaks exploit.
- (d) Correct. Comb_3 (= prefix injection + refusal suppression + Base64 + style injection + website content/formatting) achieved SOTA ASR.

Q10. (Pick all that are correct) 예상문제

Which of the following are true about GCG and the motivation for AutoDAN?

- a. Manually written jailbreak prompts such as DAN suffer from scalability issues, which motivated learning-based attacks like GCG.
- b. GCG sets an adversarial objective and searches candidates via gradients, but its prompts are semantically meaningless.
- c. GCG prompts are easily detected by perplexity-based detectors, while AutoDAN remains effective even under a perplexity defense.

- d. AutoDAN's search space is larger than GCG's because the genetic algorithm operates in a continuous space.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. Scalability of manual prompts is limitation #1; GCG is the learning-based answer.
- (b) Correct. GCG optimizes an adversarial objective with gradient-based search, producing weird, meaningless suffixes.
- (c) Correct. GCG's high PPL makes it easy to filter; AutoDAN's effectiveness remains under the perplexity defense.
- (d) Incorrect. It is the opposite: the genetic algorithm works in a *discrete* space, so AutoDAN's search space is relatively *small* compared to GCG's continuous space — this is a stated limitation of AutoDAN that motivated COLD-Attack.

Q11. (Pick all that are correct) 예상문제

Which of the following are true about AutoDAN's genetic algorithm and experiments?

- The population is initialized with handcrafted jailbreak prompts, with diversity increased by LLM-based revision.
- In AutoDAN-GA, crossover swaps sentences in paragraphs and mutation uses LLM-based diversification, while AutoDAN-HGA additionally performs sentence-level mutation via word scoring.
- The evaluation uses AdvBench Harmful Behaviors (520 prompts) with three metrics: keyword-based ASR, GPT Recheck, and sentence perplexity measured by GPT-2.
- Jailbreak prompts generated with Vicuna failed to transfer to other models such as Llama.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. Handcrafted prompts (already demonstrated efficacy) + LLM-prompted diversification.
- (b) Correct. This is exactly the GA vs. HGA distinction; word scores use average and momentum over iterations.
- (c) Correct. All three metrics and the dataset match the paper.
- (d) Incorrect. AutoDAN showed *transferability*: prompts constructed on Vicuna transfer to Guanaco and Llama, and also show universality across samples.

Q12. (Pick all that are correct) 예상문제

Which of the following are true about COLD Decoding and COLD-Attack?

- a. The energy function is defined as $E(\mathbf{y}) = -\sum_i \lambda_i f_i(\mathbf{y})$, and constrained generation corresponds to sampling from the energy-based distribution.
- b. Sampling is performed efficiently via Langevin dynamics, whose iterates are proven to converge in distribution to $p(\tilde{\mathbf{y}})$ as the number of iterations goes to infinity.
- c. COLD-Attack uses the same underlying algorithm as COLD Decoding, differing only in its purpose and the newly proposed constraints (e.g., attack success via a proxy target, fluency, semantic similarity, lexical constraints).
- d. Compared to GCG and AutoDAN, COLD-Attack requires more generation time due to its multiple constraints.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. The energy function aggregates the constraint functions with coefficients λ_i , motivated by energy-based models.
- (b) Correct. Langevin dynamics with gradient $\nabla_{\mathbf{y}} E$ plus Gaussian noise; convergence as $n \rightarrow \infty$ is proven (Welling et al.).
- (c) Correct. The professor emphasized the algorithm is "exactly the same" — only the purpose and constraints differ.

- (d) Incorrect. COLD-Attack is *more efficient* — it requires much shorter generation time than GCG and AutoDAN.

Q13. (Pick all that are correct) 예상문제

Which of the following are true about SafeDecoding (Xu et al., ACL 2024)?

- a. It is motivated by the observation that the output token probabilities contain both refusal and acceptance tokens with non-negligible probability, even for successful jailbreak prompts.
- b. The sample space $\mathcal{V}_n^{(c)}$ is the intersection of the top-k token sets of the original and expert models, where the hyperparameter c guarantees a minimum sample-space size.
- c. For benign queries, the contrastive term roughly cancels out so that generation effectively follows the original model's distribution, preserving utility.
- d. Among the compared defenses, Self-Examination best preserved utility on MT-Bench, while SafeDecoding suffered a large utility drop.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. Even when "Sure" is top-1 under a jailbreak, refusal tokens also have high probability — this is the core observation.
- (b) Correct. $\mathcal{V}_n^{(c)}$ is the overlap of the two models' top-k sets with size at least c , the minimum required sample-space size.
- (c) Correct. Both models respond positively to benign queries, so $p_{\theta'} - p_{\theta} \approx 0$ cancels out.
- (d) Incorrect. It is the opposite: Self-Examination largely *decreased* performance on MT-Bench (as did ICD and Paraphrase), while SafeDecoding best preserved the vanilla performance.

Q14. (Pick all that are correct) 예상문제

Which of the following are true about Gradient Cuff (Hu et al., NeurIPS 2024)?

- a. The refusal loss $\phi_\theta(x) = 1 - p_\theta(x)$ represents the likelihood of getting a non-refusal response, where $JB(y)$ is a keyword-based binary indicator of refusal.
- b. Since the exact gradient of the refusal loss is infeasible due to discrete operations, Gradient Cuff estimates it with zeroth-order (directional derivative) approximation using random Gaussian vectors on the mean-pooled sentence embedding.
- c. Malicious queries exhibit flat refusal-loss landscapes with small gradient norms, while benign queries exhibit steep landscapes.
- d. Compared with SafeDecoding, SafeDecoding shows both a higher false positive rate and a higher true positive rate, so neither method strictly dominates the other.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. p_θ is the expected rate of refusal, ϕ_θ the likelihood of non-refusal; $JB(y)$ follows SmoothLLM's keyword detection.
- (b) Correct. Zeroth-order estimation via function-value differences with perturbations $\mu \mathbf{u}_i, \mathbf{u}_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, averaged over P vectors.
- (c) Incorrect. Reversed: *benign* queries are flat with small gradient norm, *malicious* queries are steep with large gradient norm.
- (d) Correct. SafeDecoding has high FPR (undesirable) but also high TPR — there is a trade-off, so no definitive conclusion about which is better.

3분 요약

개념	한 줄 정리
Training-level defense	Red Teaming(전문가가 위험 프롬프트 발굴→학습 데이터) + Model-Assisted Safety Pipeline(RBRM이 규칙 기반 보상으로 RLHF 보강)
DAN prompting	수작업 역할부여 프롬프트로 guardrail을 쉽게 bypass — refusal suppression 카테고리
Jailbreak attack	restricted behavior 프롬프트 P를 P'로 수정해 on-topic 응답 유도; refuse=good bot, on-topic 응답=bad bot
Failure mode ①②	① Competing objectives(prefix injection, refusal suppression) ② Mismatched generalization(Base64) — Comb_3가 SOTA ASR
GCG	gradient 기반 자동 공격이지만 의미 없는 suffix → perplexity filter에 쉽게 탐지
AutoDAN	hierarchical genetic algorithm(초기화=handcrafted DAN, fitness=proxy target likelihood, crossover/mutation+word scoring)으로 fluent한 공격 — perplexity defense 생존, 전이성↑
COLD-Attack	COLD Decoding(energy function + Langevin dynamics on logits) 그대로 + attack/fluency/similarity/lexical 제약 — 더 다양하고 더 빠름
SafeDecoding	LoRA expert와의 contrastive decoding으로 refusal 토큰 확률↑ — first m tokens만 적용, utility 최고 보존
Gradient Cuff	refusal loss $f < 0.5$ + zeroth-order gradient norm $> t$ 2단계 탐지 — benign=flat/malicious=steep, FPR↓ TPR↑, SafeDecoding과는 trade-off