

CAS4133 LLM · 기말 대비 · Chapter 7

Chapter 7. Decoding of LLMs (Controllability · COLD

Decoding)

제어 가능성(Controllability)과 COLD Decoding — 제약을 에너지 함수로 정식화하고 Langevin dynamics로 로짓을 직접 업데이트하는 제약 생성 + 디코딩 핵심 개념 정리

 강의일: 2026-05-04 예상 비중: 중 (COLD 신규 + 기말 Inference 계산 대비) 분량: 본문 7개 섹션 + 문제

목차

1. 디코딩 기초 & 고급 디코딩 요약 (기말 Inference 계산 대비)
2. Controllability — 동기와 문제 설정
3. COLD Decoding — 정식화: 로짓 공간 $\tilde{\mathbf{y}}$ 와 제약 함수 f_i
4. 에너지 기반 모델(EBM)과 에너지 함수 $E(\mathbf{y})$
5. Langevin Dynamics — 그래디언트 기반 샘플링
6. COLD 전체 알고리즘 & Lexically Constrained Decoding 실험
7. COLD의 위상 — 프롬프팅 시대에 왜 덜 쓰이는가
8. 기출 & 예상문제

교수는 #7 디코딩 챕터에서 **기초(basics) → 고급 알고리즘(speculative / diverse decoding) → test-time compute → 제어 가능성(controllability)** 순서로 진행했고, 시간 제약으로 이번 강의에서는 controllability만 신규로 다뤘다. 앞의 세 파트는 **기말 Inference 계산 문제(Problem 2)에서 디코딩 알고리즘을 손으로 적용**할 때 필요한 토대이므로, 요점만 압축 정리한다.

교수 강조 (강의 발언)

"우리는 강의의 마지막 부분으로 디코딩을 다뤘습니다. 먼저 디코딩의 기초를 배웠고, 이후 speculative decoding이나 diverse decoding 같은 고급 디코딩 알고리즘으로 넘어갔으며, 그다음 보상 모델을 사용하는 test-time compute를 다뤘습니다. 이제 시간 제약 때문에 controllability라는 한 부분만 다루겠습니다."

1.1 Autoregressive Decoding (자기회귀 디코딩)

정의

자기회귀 디코딩(autoregressive decoding): 한 번에 한 토큰씩, **모든 이전 토큰을 조건으로 (conditioning on all previous tokens)** 다음 토큰을 생성. **EOS(end-of-sequence) 토큰**이 생성되거나 미리 정의된 최대 길이(**pre-defined max length**)에 도달할 때까지 반복.

자기회귀 분해 (Autoregressive Factorization)

$$p(\mathbf{y} \mid \mathbf{x}) = \prod_{t=1}^T p(y_t \mid \mathbf{x}, y_{<t})$$

$\mathbf{x}$ 는 입력(프롬프트), $y_{<t}$ 는 t 시점 이전에 생성된 모든 토큰. 각 스텝의 토큰은 모델이 출력하는 **확률 분포 (softmax over vocabulary)**에서 선택/샘플링되며, 고정된 가우시안 분포 같은 것이 아니다.

함정 포인트 (T/F 대비)

- "The decoding process can be parallelized across all tokens during inference." → **False**. Autoregressive decoding is **inherently sequential** — token t requires tokens

$1, \dots, t - 1$. (Training-time teacher forcing은 병렬 가능하지만, inference-time decoding은 불가)

- "The next token is sampled from a fixed Gaussian distribution." → **False**. Sampled from the model's output probability distribution (softmax over logits).

1.2 Greedy / Beam Search / Diverse Beam Search

방법	핵심 아이디어	특징 / 함정
Greedy decoding	매 스텝 argmax 토큰 선택	지역 최적(local optimum) — 전체 시퀀스 확률 최대를 보장하지 않음. 결정적(deterministic).
Beam search	매 스텝 누적 확률 상위 k 개 가설 (beam)을 유지하며 탐색	greedy보다 높은 likelihood의 시퀀스 발견 가능. 그러나 빔들끼리 매우 유사해지는 다양성 부족 문제.
Diverse Beam Search (DBS)	빔을 그룹으로 나누고, 그룹 간 diversity term (페널티)을 목적 함수에 추가	diversity 향 때문에 최종 선택 시퀀스가 perplexity 관점에서 최적 이 아닐 수 있음.

1.3 Sampling 계열: Temperature / Top-k / Top-p

Temperature Scaling

$$p(y_t = v) = \frac{\exp(z_v / \tau)}{\sum_{v'} \exp(z_{v'} / \tau)}$$

z_v 는 토큰 v 의 로짓, τ 는 temperature. **softmax 이전에 로짓을 rescale**한다(applied before softmax — 기출 함정). $\tau \downarrow \rightarrow$ 분포가 뾰족(peaky)해져 더 결정적(deterministic) 출력, $\tau \uparrow \rightarrow$ 더 평평(smooth)해져 더 무작위적 출력. $\tau \rightarrow 0$ 이면 greedy와 동일.

구분	Top-k sampling	Top-p (nucleus) sampling
----	----------------	--------------------------

후보 집합 결정	확률 상위 고정 개수 k 개	누적 확률(cumulative probability) 이 p 를 넘는 최소 집합
후보 개수	항상 k 개 (고정)	분포 모양(distribution's shape)에 따라 동적으로 변함 (dynamic flexibility)
설계 목적	저확률 꼬리 토큰 제거	unnatural / degenerate completion 방지 (text degeneration 완화)
Temperature와의 관계	둘 다 temperature와 함께 사용 가능 (temperature로 분포를 조정한 뒤 truncation) — "temperature is irrelevant in top-k"는 False	

⚠ **함정 포인트 (T/F 대비)**

- "Top-p is a special case of beam search with $p=1$." → **False**. Top-p is a **sampling** method, unrelated to beam search (search-based).
- "Temperature is applied after the softmax operation." → **False**. It rescales **logits before softmax**.
- "Lower temperature increases randomness." → **False**. Lower τ → peakier distribution → **more deterministic**.

1.4 Speculative Decoding (추측 디코딩)

- 1 **Draft** — 작은 **draft model**이 여러 토큰을 (자기회귀적으로) 빠르게 제안
- 2 **Verify** — 큰 **target model**이 draft 토큰들을 **한 번의 병렬 forward pass**로 검증 (accept/reject)
- 3 **Accept & continue** — 수락된 prefix까지 확정, 거절 지점부터 다시 draft → 큰 모델 호출 횟수 감소로 속도 향상. 출력 분포는 target model과 동일하게 유지.

⚠ **함정 포인트 (T/F 대비)**

- "It eliminates the need for sequential generation." → **False**. The **draft model still generates tokens autoregressively**; only verification is parallelized.

- "Speculation changes the output distribution of the large model." → **False**.
Acceptance/rejection scheme은 target model의 분포를 보존하도록 설계됨.

1.5 Test-time Compute Scaling

📖 정의

Test-time compute scaling: 학습이 아닌 **추론(inference) 시점**에 더 많은 연산을 투입해 성능을 높이는 전략. 어려운 질의에 동적으로 더 많은 compute를 할당(dynamically allocate more inference compute to harder queries)하고, "longer thinking"으로 복잡한 과제의 추론 정확도를 높임. 예: Best-of-N + reward model, self-consistency, 긴 chain-of-thought.

⚠ 함정 포인트 (T/F 대비)

- "It is a technique for fine-tuning LLMs using RL." → **False**. It is an **inference strategy**, not a fine-tuning method.
- "It improves model capacity by increasing the number of parameters at test time."
→ **False. Parameters are fixed**; only inference time/compute increases.

★ 시험 핵심

디코딩 4대 오답 패턴을 외울 것: ① autoregressive = sequential(병렬 불가), ② temperature = *before softmax* & low τ = deterministic, ③ top-p = dynamic candidate set (beam search와 무관), ④ speculative = draft는 여전히 autoregressive / test-time compute = 파라미터 고정·inference 전략. DBS는 diversity 향 때문에 최저 perplexity 시퀀스를 보장하지 않음.

Controllability — 동기과 문제 설 (Controllability: Motivation)

정의

제어 가능성(Controllability): 출력 생성에서 **우도(likelihood)**만이 아니라 **추가적인 제약 (constraints)**을 만족하도록 디코딩하는 것. 슬라이드 원문: "Adding constraints in output generation (**not only likelihood**)".

기존 디코딩(greedy, beam, sampling)은 모두 **likelihood 하나의 목적**을 중심으로 동작한다. 그러나 응용에 따라 likelihood 외의 제약을 생성 과정에 넣고 싶을 수 있다. 교수가 든 예시:

- **Diversity** — 가장 고전적인 예. DBS가 likelihood 목적에 diversity를 추가 제약으로 넣은 사례 → controllability의 한 형태로 볼 수 있음.
- **Keyword inclusion (lexical constraint)** — 특정 키워드(예: "cat", "fox")를 반드시 포함하는 문장 생성.
- **Infilling (text in-between)** — 과거 문맥(past context)과 미래 문맥(future context)이 둘 다 주어졌을 때 그 사이의 중간 텍스트를 생성. 기존 autoregressive 디코딩은 **과거만** 조건으로 보지만, 여기서 생성 결과가 **미래 문맥 관점에서도 자연스러워야** 하므로 이것이 추가 제약으로 모델링됨.
- **Counterfactual reasoning** — 조건의 일부가 바뀌었을 때 일관되도록 텍스트 일부를 수정하는 생성.

2.1 프롬프팅 vs 디코딩 수준 제어

교수 강조 (강의 발언)

"최근 LLM 시대에 더 직접적인 해법은 프롬프팅이겠죠? 예를 들어 'cat'을 키워드로 포함해야 한다'고 프롬프트에 주면 됩니다. 하지만 이런 프롬프팅은 **암묵적(implicit) 해법**이라서, 특정 출력을 실제로 제어할 수는 없습니다. 그래서 디코딩에서 controllability의 목표는 **디코딩 알고리즘 자체를 직접 수정**하는 것입니다."

구분

Prompting (e.g., "include the keyword cat")

Decoding-level control (e.g., COLD)

제어 방식	입력 문맥으로 제약을 전달 — implicit	디코딩 목적함수/알고리즘을 직접 수정 — explicit
보장	모델이 지시를 따를 것이라는 보장 없음	제약 함수를 직접 최적화 → 만족 확률을 원칙적으로 높임
학습 필요	없음	없음 (COLD도 training-free , 디코딩만 수정)

⚠ **함정 포인트 (T/F 대비)**

- "Controllable decoding aims to maximize only the likelihood of the output." → **False**. The whole point is adding constraints **beyond likelihood**.
- "Prompting with the constraint (e.g., 'include keyword X') guarantees that the output satisfies the constraint." → **False**. Prompting is an **implicit** solution and cannot directly control the output.
- "Text infilling with both past and future contexts can be handled by standard autoregressive decoding without modification." → **False**. Standard AR decoding conditions only on the **past**; naturalness w.r.t. the future context must be modeled as an additional constraint.

COLD Decoding — (Formulation: Logit Space & Constraint Functions)

정식화

정의

COLD Decoding (Qin et al., *COLD Decoding: Energy-based Constrained Text Generation with Langevin Dynamics*, **NeurIPS 2022**): 제약을 생성을 ① **제약을 수학적 목적함수(에너지 함수)로 정식화**하고 ② **출력(로짓) 수준에서 gradient-based update**를 반복해 제약을 만족시키는 **에너지 기반(energy-based) 제약 텍스트 생성 프레임워크**. 모델 파라미터는 건드리지 않는다.

교수 강조 (강의 발언)

"핵심 아이디어는 첫째, 제약을 수학적 목적함수로 정식화하고, 둘째, 제약을 만족시키기 위해 **출력 수준에서 gradient-based 업데이트**를 수행한다는 것입니다. **adversarial example을 위한 gradient descent와 매우 유사**합니다 — 파라미터가 아니라 입력/출력을 업데이트한다는 점에서요."

3.1 표기법: 왜 로짓 공간인가

- $\mathbf{y} \in \mathbb{N}^T$: 출력 텍스트(토큰 ID 시퀀스). T = 출력 토큰 개수.
- $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$: $\mathbf{y}$ 의 **로짓(logit)**. V = LLM의 vocabulary 크기. 각 위치마다 V 차원 실수 벡터(soft token representation).
- $f_i(\mathbf{y}) \in \mathbb{R}$: i 번째 **제약 함수(constraint function)**. 각 제약이 스칼라 함수로 포착될 수 있다고 가정. 값이 **클수록 제약을 잘 만족**.

이산 → 연속 완화 (Discrete-to-Continuous Relaxation)

$$\mathbf{y} \in \mathbb{N}^T \xrightarrow{\text{discrete, no gradient}} \tilde{\mathbf{y}} \in \mathbb{R}^{T \times V} \text{ (continuous, differentiable)}$$

텍스트 $\mathbf{y}$ 는 **이산(discrete)** 값이므로 그래디언트를 직접 구할 수 없다. COLD의 해결책: 이산 토큰 공간 대신 **연속인 로짓 공간 $\tilde{\mathbf{y}}$ 를 최적화 변수**로 삼아 업데이트한다. 마지막에만 이산화(discretization)하여 실제 토큰으로 되돌린다.

3.2 제약 함수 f_i 의 예

제약 종류	제약 함수 f_i 의 구현
Fluency constraint (유창성)	LM이 매기는 likelihood of y — 슬라이드의 대표 예시 ("e.g., likelihood of y as fluency constraint")
Keyword/lexical constraint	목표 키워드와의 counting / n-gram overlap (n-gram match)
Future-context coherence	미래 문맥에 조건부인 likelihood (역방향 LM 등)

이후 할 일은 f_i 들을 최대화하도록 $\tilde{y}$ 를 업데이트하는 것. 업데이트된 $\tilde{y}$ 는 제약을 만족할 가능성이 더 큰 후보가 된다. 남은 질문: "어떻게 **원칙에 입각한(principled)** 방식으로 업데이트하는가?" → 에너지 기반 모델 (§4)과 Langevin dynamics (§5)가 답.

★ 시험 핵심

COLD의 3대 키워드 매핑을 정확히: **optimization variable = 로짓 $\tilde{y} \in \mathbb{R}^{T \times V}$** (이산 $y \in \mathbb{N}^T$ 가 아님), **constraint = 스칼라 함수 $f_i(y) \in \mathbb{R}$** , **update = gradient-based** (output-level, parameter-level 아님). 차원 표기 $\mathbb{R}^{T \times V}$, $\mathbb{N}^T$ 가 그대로 T/F로 나올 수 있다.

⚠ 함정 포인트 (T/F 대비)

- "COLD performs gradient updates directly on the discrete token sequence y ." → **False**. Gradients are intractable in the discrete space; COLD updates the **continuous logits $\tilde{y}$** .
- "COLD fine-tunes the LLM's parameters to satisfy the constraints." → **False**. It is a **decoding-time** method; the update target is the output logits, not model parameters.
- "Each constraint f_i must be a binary indicator (satisfied / not satisfied)." → **False**. $f_i(y) \in \mathbb{R}$ is a real-valued (differentiable) score, e.g., likelihood or n-gram overlap.

에너지 기반 모델과 에너지 함수 (Energy-Based Model & Energy Function)

정의

에너지 기반 모델(Energy-Based Model, EBM): 에너지 함수 $E(\mathbf{y})$ 로 확률 분포를 기술하는 모델링 방식. 에너지가 낮을수록 안정(stable) → 높은 확률, 에너지가 높을수록 불안정(unstable) → 낮은 확률. (교수의 직관: 화학에서 분자의 에너지 — 낮은 에너지 = 안정 상태)

COLD의 에너지 함수 — 제약의 선형 결합

$$E(\mathbf{y}) := - \sum_i \lambda_i f_i(\mathbf{y})$$

$\lambda_i \geq 0$ 는 i 번째 제약의 가중치. **마이너스 부호**에 주의: f_i 가 클수록(제약을 잘 만족할수록) 에너지 E 는 **낮아진다**. 즉 "제약 만족 = 저에너지 = 고크률"의 방향이 되도록 정의.

에너지 기반 분포 (Boltzmann form)

$$p(\mathbf{y}) = \frac{\exp(-E(\mathbf{y}))}{Z}, \quad Z = \sum_{\mathbf{y}'} \exp(-E(\mathbf{y}'))$$

Z 는 분모의 **정규화 항(normalizing term/constant)**. $-E(\mathbf{y}) = \sum_i \lambda_i f_i(\mathbf{y})$ 이므로, 이 분포에서 $\mathbf{y} \sim p(\mathbf{y})$ 를 샘플링하면 **높은 확률로 제약들을 만족하는 텍스트**가 나온다. 따라서 "제약 하의 텍스트 생성 = 에너지 기반 분포 p 로부터의 샘플링"으로 문제가 재정의된다.

교수 강조 (강의 발언)

"에너지가 높으면 샘플링될 확률이 낮고, 에너지가 낮으면 샘플링될 확률이 높습니다. 높은 에너지는 불안정한 상태를 나타내기 때문에 마이너스 E를 취합니다. 유일한 문제는: **어떻게 이 분포로부터 샘플링하는가?** 단순한 분포가 아니기 때문에(정규화 항 Z 계산 불가) 직접 샘플링이 간단하지 않습니다."

★ 시험 핵심

① $E(\mathbf{y}) = - \sum_i \lambda_i f_i(\mathbf{y})$ 의 **마이너스 부호와 방향성**(높은 $f_i \Rightarrow$ 낮은 에너지 $\Rightarrow$ 높은 확률), ② $p(\mathbf{y}) \propto \exp(-E(\mathbf{y}))$, ③ 이 분포에서의 직접 샘플링은 intractable $\rightarrow$ **Langevin dynamics**

가 필요해지는 이유. 이 3단 논리 흐름이 Pick-all로 나오기 좋다.

⚠ 함정 포인트 (T/F 대비)

- "In COLD, a higher energy $E(\mathbf{y})$ means the text is more likely to satisfy the constraints." → **False**. **Lower** energy $\leftrightarrow$ higher constraint satisfaction $\leftrightarrow$ higher probability under p .
- "The energy function is defined as the product of the constraint functions." → **False**. It is a (negative) **weighted linear combination**: $E = - \sum_i \lambda_i f_i$.
- "Sampling from the energy-based distribution $p(\mathbf{y})$ is straightforward since p is explicitly normalized." → **False**. The normalizing constant Z is intractable; that is exactly why Langevin dynamics is used.

Langevin Dynamics — 그래디언트 기반 샘플링 (Sampling via Langevin Dynamics)

정의

Langevin dynamics: 에너지 기반 분포처럼 직접 샘플링이 어려운 분포에서, 임의의 점에서 시작해 에너지 함수의 그래디언트 $\nabla_y E(y)$ 를 따라 내려가면서 가우시안 잡음을 더하는 반복(Markov chain)으로 샘플을 얻는 고전적 샘플링 알고리즘. (수렴 증명: Welling & Teh, *Bayesian Learning via Stochastic Gradient Langevin Dynamics*, ICML 2011)

Langevin 업데이트 (Markov chain / gradient step)

$$\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}, \quad \epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$$

η 는 **step size**, $\epsilon^{(n)}$ 은 반복 n 에서의 **가우시안 잡음(Gaussian noise)**. 잡음 항 덕분에 단순 경사 하강(한 점으로의 수렴)이 아니라 **분포로부터의 샘플링**이 된다. 핵심 성질: $n \rightarrow \infty$ 일 때 $\tilde{\mathbf{y}}^{(n)}$ 의 분포가 목표 분포 $p(\tilde{\mathbf{y}})$ 로 수렴함이 증명되어 있다.

5.1 경사 하강(파라미터 학습)과의 비교 — 교수의 핵심 직관

교수 강조 (강의 발언)

"손실 함수를 최소화하려고 **파라미터 수준에서** 경사 하강할 때와 매우 유사한 식이죠? 유일한 차이는, **파라미터 자리에 $\tilde{\mathbf{y}}$ 가, 손실 함수 자리에 에너지 함수가** 대입된다는 것뿐입니다. 업데이트 대상이 출력으로, 목적이 에너지 함수로 바뀐 것입니다."

구분	일반 학습 (gradient descent)	COLD의 Langevin dynamics
업데이트 변수	모델 파라미터 θ	출력 로짓 $\tilde{\mathbf{y}}$ (모델은 고정)
목적 함수	손실 $\mathcal{L}(\theta)$	에너지 $E(\tilde{\mathbf{y}}) = -\sum_i \lambda_i f_i$

잡음 항	없음 (결정적 하강)	가우시안 잡음 $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$ 필수 — 샘플링이 되게 함
결과	손실 최소화점	$n \rightarrow \infty$ 에서 $p(\tilde{\mathbf{y}})$ 로부터의 샘플 (수렴 보장)
유사 사례	—	adversarial example 생성(입력에 대한 gradient)과 구조 동일

★ 시험 핵심

Langevin 업데이트 식의 3요소를 식별할 수 있어야 함: ① **gradient term** $-\eta \nabla_{\tilde{\mathbf{y}}} E$ (에너지를 낮추는 방향 = 제약 만족도를 높이는 방향), ② **noise term** $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$, ③ **수렴 성질** ("distribution of $\tilde{\mathbf{y}}^{(n)}$ converges to p as $n \rightarrow \infty$ "). "Markov chain을 형성한다"는 표현도 슬라이드 원문.

⚠ 함정 포인트 (T/F 대비)

- "Langevin dynamics in COLD performs gradient ascent on the energy function." → **False**. It takes gradient **descent** steps on E (lower energy = better constraint satisfaction). (Equivalently, gradient ascent on $\sum_i \lambda_i f_i$.)
- "The Gaussian noise term is an optional trick for escaping local minima and can be dropped without changing what the procedure computes." → **False**. The noise is what makes the iterates **samples from p** rather than a deterministic minimizer; the convergence-to- p guarantee relies on it.
- "After a finite, small number of steps, $\tilde{\mathbf{y}}^{(n)}$ is guaranteed to be an exact sample from p ." → **False**. The guarantee is asymptotic: convergence holds as $n \rightarrow \infty$.
- "Langevin dynamics requires computing the normalizing constant Z of p ." → **False**. It only needs $\nabla_{\tilde{\mathbf{y}}} E - Z$ 와 무관하다는 점이 이 방법을 쓰는 이유.

6.1 전체 알고리즘 (Algorithm Description)

입력: 제약 함수들 $\{f_i\}$ (목표 속성에 맞게 사용자가 직접 정의), 반복 횟수 N , 출력 길이 T .

- 1 초기화 (Initialization) — 전통적인 우도 기반 디코딩으로 초기 로짓 $\tilde{\mathbf{y}}^{(0)}$ 을 얻는다 (이 초기 생성은 제약을 위반할 수 있는 vanilla 출력).
- 2 에너지 함수 정식화 — 제약들의 선형 결합으로 $E(\tilde{\mathbf{y}}) = -\sum_i \lambda_i f_i(\tilde{\mathbf{y}})$ 구성.
- 3 Langevin 업데이트 $\times N$ 회 — $\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}$ 를 $n = 0, \dots, N-1$ 반복.
- 4 이산화 (Discretization) — 업데이트된 로짓 $\tilde{\mathbf{y}}^{(N)}$ 에서 전통적 방식(top-k 필터링 등)으로 실제 토큰 시퀀스 $\mathbf{y}$ 를 샘플링.

6.2 응용: Lexically Constrained Decoding (어휘 제약 디코딩)

COLD 논문에는 여러 응용(abductive reasoning, counterfactual reasoning 등)이 있지만, 강의에서는 가장 직관적인 어휘 제약 디코딩만 소개. 목표: 특정 키워드들을 포함하는 자연스러운 문장 생성.

교수 강조 (강의 발언)

"우려되는 점은 **reward hacking**입니다 — 제약을 만족시키는 부자연스러운 방식은 키워드를 무작위 위치에 삽입해 버리는 것이죠. 제약 측면에서는 만족되지만 문장은 자연스럽지 않습니다. 그래서 목표는: **자연스러운 문장을 생성하되, 키워드를 가능한 한 자연스럽게 포함시키는 것**입니다."

설계된 에너지 함수 E_1 — 4개의 제약 함수 결합

Lexically constrained decoding을 위한 에너지 (개념 구조)

$$E_1(\tilde{\mathbf{y}}) = - \left[\underbrace{\lambda_a f_{\overrightarrow{\text{LM}}}(\tilde{\mathbf{y}}; \mathbf{x})}_{\text{① 순방향 유창성}} + \underbrace{\lambda_b f_{\overleftarrow{\text{LM}}}(\tilde{\mathbf{y}})}_{\text{② 역방향 유창성}} + \underbrace{\lambda_c f_{\text{pred}}(\mathbf{x} | \tilde{\mathbf{y}})}_{\text{③ 입력 부분의 우도}} + \underbrace{\lambda_d f_{\text{sim}}(\tilde{\mathbf{y}}; \mathbf{y}^*)}_{\text{④ n-gram 유사도}} \right]$$

$\mathbf{y}^*$ 는 목표 키워드(target keywords). 각 항의 의미는 아래 표 참조.

항	제약 함수	의미 (강의 설명)
① soft fluency	좌→우(forward) LM likelihood의 cross-entropy	출력의 자연스러움(naturalness) — 우도의 전통적 정의. 주어진 문맥에 대한 확률 계산.
② reverse LM fluency	같은 모델 로 우도의 역방향(reverse direction) 고려	역방향에서도 유창하도록 — 키워드 삽입이 앞뒤 어느 쪽에서 봐도 자연스럽게.
③ future-context / input likelihood	출력 y 가 주어졌을 때 입력 x 부분 자체의 우도	출력이 아니라 입력 부분을 우도 측면에서 생각 — 출력이 입력 문맥과 일관되도록.
④ n-gram similarity	현재 $\tilde{y}$ 와 목표 키워드 y^* 의 n-gram match	어휘 제약의 가장 직접적 목적 — 키워드 포함 정도를 측정.

이 네 제약을 하나의 에너지 함수로 결합해 그래디언트를 취한다. ①~③은 "자연스럽게", ④는 "키워드를 포함하게" — ④만 있으면 reward hacking(무작위 삽입)이 일어나므로 **유창성 제약들과의 결합이 핵심 설계**다.

6.3 실험 결과 (vs NeuroLogic 등 베이스라인)

- COLD는 이전 알고리즘들 대비 **더 유창(fluent)**한 출력을 생성.
- **키워드 포함률(coverage) 약 95%** — 대부분의 키워드를 성공적으로 포함.
- 단, **NeuroLogic 베이스라인과 비교하면** human 평가 기준 점수에서 **perplexity가 상당히 낮음(= 더 유창함)**이 COLD의 강점으로 제시됨 — 즉 NeuroLogic 같은 탐색 기반 방법 대비 fluency에서 우위.

★ 시험 핵심

알고리즘 4단계의 **순서**(likelihood 초기화 → 에너지 정식화 → N회 Langevin 업데이트 → 이산화)와, lexical constraint에서 **에너지 함수가 4개 항**(forward fluency / reverse fluency / input-side likelihood / n-gram match)으로 구성된다는 것, 그리고 **fluency 항들이 reward hacking(키워드 무작위 삽입)을 막기 위해 존재**한다는 설계 의도. 실험 수치는 "**~95% keyword coverage + more fluent than baselines (incl. NeuroLogic)**".

⚠ 함정 포인트 (T/F 대비)

- "In COLD's lexically constrained decoding, the n-gram match term alone is sufficient to produce natural outputs." → **False**. Alone it invites **reward hacking** (inserting keywords at random positions); fluency terms (forward + reverse LM) are needed.
- "COLD initializes $\tilde{\mathbf{y}}^{(0)}$ randomly from Gaussian noise." → **False**. It is initialized using **conventional likelihood-based decoding** (the vanilla generation).
- "The final output of COLD is the continuous logit $\tilde{\mathbf{y}}^{(N)}$ itself." → **False**. A **discretization** step samples actual tokens from the updated logits at the end.
- "The reverse-LM term in E_1 requires training a separate backward language model from scratch." → **False** (강의 기준). The **same model** is used to consider the reverse direction of the likelihood.

COLD의 위상 — 프롬프팅 시대의 controllable decoding

(Where COLD
Stands Today)

교수 강조 (강의 발언)

"만약 언어 모델이 in-context learning을 완전히 수행해서 — 'cat과 fox를 키워드로 포함하라' 같은 — 여러분의 지시를 **100% 따를 수 있다면, 이런 종류의 디코딩은 필요하지 않겠죠?** 그것이 이 알고리즘이 최근에 자주 사용되지 않는 이유입니다. 하지만 이런 모델링 기법은 **고급 디코딩에 관한 지식 체계의 일부로서 소개할 가치가 충분**하다고 생각합니다."

- **현대적 한계:** 강력한 instruction-following LLM에서는 프롬프팅(in-context learning)만으로 제약 만족이 상당 부분 가능 → COLD류 명시적 제약 디코딩의 실용적 수요 감소.
- **그럼에도 배우는 이유:** ① 프롬프팅은 여전히 implicit·무보장, ② 에너지 기반 정식화 + Langevin 샘플링이라는 **모델링 기법 자체의 일반성** (출력 공간 최적화, training-free 제어라는 사고방식은 test-time 기법 전반과 연결됨).

함정 포인트 (T/F 대비)

- "COLD-style constrained decoding is widely used in production with today's instruction-following LLMs." → **False**. The professor explicitly noted it is **not frequently used recently**, since strong in-context instruction following often suffices.
- "Because prompting can express constraints, decoding-level controllability is conceptually equivalent to prompting." → **False**. Prompting is implicit with no guarantee; decoding-level control **directly modifies the decoding objective/algorithm**.

Q 기출 & 예상문제

🎯 작년 기말 출제: Inference 계산 문제 (Problem 2, 20점)

⚠ 기말 유형 경고 — 손계산 필수

기말 Problem 2는 객관식이 아니라 손계산(hand-calculation)이다. 행렬곱 · word embedding concat · 해밍거리 · top-K/temperature · greedy/beam을 직접 계산하는 연습이 필수. 작년에는 ① 입력 시퀀스 → embedding 행렬 → ② 행렬곱 $\tilde{x} \circ M$ → ③ 해밍거리로 output logit → ④ top-K(K=1) 샘플링 → ⑤ autoregressive로 다음 토큰까지, 다섯 단계를 모두 손으로 풀게 했다.

대비 포인트: 디코딩 알고리즘(greedy / top-k / top-p / temperature / beam)을 손으로 적용하는 유형을 반드시 연습할 것. logit 벡터가 주어지면 (i) greedy=argmax, (ii) top-k=상위 k개만 남기고 정규화 후 샘플, (iii) top-p=누적확률 임계, (iv) temperature= z/τ 후 softmax — 각각을 직접 계산해보는 것이 핵심.

P2. Problem 2: Inference with LLM (총 20점, 4문항 × 5점)

2025 기말 기출 원문

아주 단순한 LLM M 이 단 하나의 행렬로만 구성된다고 하자:

$$M = \begin{bmatrix} 1 & 1 & 0 \\ -1 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

M 은 벡터 시퀀스 $\tilde{x} \in \mathbb{R}^{L \times 3}$ 를 단순 행렬곱 $\circ$ 로 매핑한다 (주의: 곱 순서는 아래와 동일해야 함):

$$M : \tilde{x} \longrightarrow \tilde{x} \circ M$$

또한 M 은 다음 word embedding을 갖는다 (CAS 4133 Final 어휘):

#	단어	embedding	#	단어	embedding
1	한	[1, 0, 0]	8	고맙습니다	[3, 0, 1]
2	학기	[1, 1, 0]	9	했습니다	[0, 2, 3]

3	동안	[0, 1, 1]	10	많았습니다	[1, 2, 3]
4	매우	[-1, 1, 0]	11	감사합니다	[3, 1, 2]
5	수고	[0, 1, 2]	12	하셨습니다	[0, 2, 2]
6	고생	[1, 1, 2]	13	많았어요	[1, 2, 2]
7	정말	[0, 0, 2]			

1. **(5점)** 입력 시퀀스 $x = \text{"한 학기 동안"}$ 을 받았다고 하자. row-axis로 embedding을 concat하여 단어 시퀀스를 하나의 행렬로 변환하라 (공백 무시).
2. **(5점)** next word prediction을 위한 output logit o 를 계산하라. inner product 대신 해밍거리 $H(\cdot, \cdot)$ 를 사용한다: $H(u, v) = \sum_{i=1}^d 1[u_i \neq v_i]$.
3. **(5점)** 위에서 얻은 o 에 **top-K (K=1) random sampling**을 적용하면 next word y_1 은?
4. **(5점)** 같은 디코딩 알고리즘으로 autoregressive하게 한 토큰 더 생성하면 y_2 는?

▼ 정답 & 단계별 풀이 (KaTeX) 보기

① **embedding 행렬 concat (5점)** — "한"=[1,0,0], "학기"=[1,1,0], "동안"=[0,1,1]을 row로 쌓는다:

$$\tilde{x} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}$$

② **행렬곱 후 해밍거리로 logit o (5점)**

먼저 $\tilde{x} \circ M$ 을 계산한다 (각 row가 M 과 곱해짐):

$$\tilde{x} \circ M = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ -1 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

next word prediction이므로 **마지막 row** $q = [0, 1, 2]$ 를 query로 사용한다. 각 vocabulary embedding v 에 대해 해밍거리 $H(q, v) = \sum_i 1[q_i \neq v_i]$ (성분이 **같으면 +1**):

예: "한"=[1,0,0] → 0=1?아니오, 1=0?아니오, 2=0?아니오 → 0. "수고"=[0,1,2] → 세 성분 모두 일치 → 3.

$$o = [0, 1, 2, 1, \mathbf{3}, 2, 2, 0, 1, 0, 2, 2, 1]$$

(순서: 한, 학기, 동안, 매우, **수고**, 고생, 정말, 고맙습니다, 했습니다, 많았습니다, 감사합니다, 하셨습니다, 많았어요)

③ **top-K (K=1) → y_1 (5점)** — K=1이면 logit이 최대인 토큰 하나만 후보로 남으므로 random sampling이라도 결국 argmax와 동일:

$$y_1 = \arg \max_v o_v = o_5 = 3 \Rightarrow \boxed{y_1 = \text{“수고”}}$$

④ **autoregressive로 y_2 (5점)** — "수고"=[0,1,2]를 시퀀스에 append하여 다시 행렬곱:

$$\tilde{\mathbf{x}}' = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}, \quad \tilde{\mathbf{x}}' \circ M = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \\ 1 & 2 & 3 \end{bmatrix}$$

새 마지막 row $q' = [1, 2, 3]$ 로 해밍거리 logit:

$$o' = [1, 1, 0, 0, 0, 1, 0, 0, 2, \mathbf{3}, 0, 1, 2]$$

"많았습니다"=[1,2,3] → 세 성분 모두 q' 와 일치 → 3 (최대).

$$y_2 = \arg \max_v o'_v = o'_{10} = 3 \Rightarrow \boxed{y_2 = \text{“많았습니다”}}$$

∴ **정답:** $y_1 = \text{“수고”}$, $y_2 = \text{“많았습니다”}$ (생성 시퀀스: "한 학기 동안 **수고 많았습니다**")

P1-viii. Problem 1 (viii): DoLa (True/False, 3점)

2025 기말 기출 원문

작년 출제·올해 범위 밖 (참고용)

※ DoLa는 **올해 슬라이드에는 없는** 항목이다. 작년 기말 True/False에 나왔던 문항이라 참고용으로만 수록한다 (직접 출제 가능성은 낮음).

DoLa selects the intermediate layer that achieves the **minimum** JSD compared to the output probability at the last layer, and then applies contrastive decoding.

▼ 정답 & 해설 보기

False. Choose the layer that **maximizes** JSD (not minimizes). (DoLa = Decoding by

Contrasting Layers: 마지막 층 출력 분포와의 JSD가 가장 큰 — 즉 가장 다른 — 중간 층을 골라 대조 디코딩을 수행한다. "minimum JSD"라고 한 점이 오답 포인트.)

B1. (True/False)

예상문제

In COLD decoding, the gradient-based update is performed on the discrete token sequence $\mathbf{y} \in \mathbb{N}^T$ directly.

▼ 정답 & 해설 보기

False. Since $\mathbf{y}$ is discrete, gradients are intractable. COLD instead updates the continuous logits $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$, and discretizes only at the end.

B2. (True/False)

예상문제

In COLD decoding, the energy function is defined as $E(\mathbf{y}) := -\sum_i \lambda_i f_i(\mathbf{y})$, so that an output satisfying the constraints better (higher f_i) has lower energy and thus higher probability under the energy-based distribution.

▼ 정답 & 해설 보기

True. $p(\mathbf{y}) \propto \exp(-E(\mathbf{y})) = \exp(\sum_i \lambda_i f_i(\mathbf{y}))$; higher constraint satisfaction $\rightarrow$ lower energy $\rightarrow$ higher sampling probability, mirroring the stable/unstable intuition of energy-based models.

B3. (True/False)

예상문제

Langevin dynamics in COLD adds Gaussian noise at each iteration, and the distribution of the updated variable $\tilde{\mathbf{y}}^{(n)}$ is proved to converge to the target energy-based distribution as $n \rightarrow \infty$.

▼ 정답 & 해설 보기

True. The update is $\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}$ with $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$; convergence to the target distribution as $n \rightarrow \infty$ was proved by Welling et al. (ICML 2011).

B4. (True/False)

예상문제

COLD decoding requires fine-tuning the language model so that its outputs satisfy the target constraints.

▼ 정답 & 해설 보기

False. COLD is a decoding-time (training-free) method: the model parameters are fixed, and only the output logits $\tilde{\mathbf{y}}$ are iteratively updated via gradients of the energy function.

B5. (True/False) 예상문제

In COLD's lexically constrained decoding, using only the n-gram match constraint with the target keywords is enough, since maximizing keyword overlap naturally produces fluent sentences.

▼ 정답 & 해설 보기

False. Maximizing the n-gram match alone invites a reward-hacking style failure: keywords can be inserted at random positions, satisfying the constraint but producing unnatural text. Hence fluency constraints (forward and reverse LM likelihoods) are combined in the energy function.

B6. (True/False) 예상문제

In COLD decoding, the initial logits $\tilde{\mathbf{y}}^{(0)}$ are obtained by conventional likelihood-based decoding, and the final text is obtained by discretizing the updated logits after N Langevin iterations.

▼ 정답 & 해설 보기

True. The algorithm: initialize $\tilde{\mathbf{y}}^{(0)}$ with conventional likelihood, formulate the energy as a linear combination of constraints, take N gradient-based (Langevin) updates, then sample tokens from the updated logits via conventional discretization.

B7. (True/False) 예상문제

Prompting an instruction-following LLM with a constraint (e.g., "include the keyword cat") is an explicit control method that guarantees the constraint is satisfied in the output.

▼ 정답 & 해설 보기

False. Prompting is an implicit solution — it cannot directly control the output and provides no guarantee. Decoding-level controllability methods like COLD explicitly modify the decoding algorithm/objective instead.

B8. (True/False) 예상문제

Sampling from the energy-based distribution $p(\mathbf{y}) = \exp(-E(\mathbf{y}))/Z$ is non-trivial because the normalizing term is intractable, which is why COLD resorts to Langevin dynamics using the gradient $\nabla_{\mathbf{y}} E(\mathbf{y})$.

▼ 정답 & 해설 보기

True. Direct sampling from the unnormalized energy-based distribution is not straightforward; Langevin dynamics only requires gradients of the energy (not Z), making sampling tractable.

Q-C. 예상문제 — Pick all that are correct

C1. (Pick all that are correct; any wrong answer will lead to 0 points) 예상문제

Which of the following are true about the formulation of COLD decoding?

- a. The output text $\mathbf{y}$ lives in $\mathbb{N}^T$, while its logit $\tilde{\mathbf{y}}$ lives in $\mathbb{R}^{T \times V}$, where V is the vocabulary size.
- b. Each constraint is assumed to be captured by a real-valued function $f_i(\mathbf{y}) \in \mathbb{R}$, e.g., the likelihood of $\mathbf{y}$ as a fluency constraint.
- c. The optimization variable is the discrete token sequence, since logits are not differentiable.

- d. Working in the logit space mitigates the challenge that gradients are hard to compute in the discrete space.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. This is exactly the notation in the lecture: $\mathbf{y} \in \mathbb{N}^T, \tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$.
- (b) Correct. Constraints are scalar functions; likelihood serves as the fluency constraint example.
- (c) Incorrect. It is the opposite: the discrete sequence is not differentiable, so the continuous logits are optimized.
- (d) Correct. The continuous relaxation is precisely the motivation for considering $\tilde{\mathbf{y}}$.

C2. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about the energy-based formulation in COLD decoding?

- a. The energy function is defined as $E(\mathbf{y}) := -\sum_i \lambda_i f_i(\mathbf{y})$, a weighted linear combination of constraint functions.
- b. Generating text under constraints is cast as sampling from the energy-based distribution $p(\mathbf{y}) \propto \exp(-E(\mathbf{y}))$.
- c. Higher energy corresponds to higher probability of being sampled.
- d. The framework is motivated by energy-based models, where low energy indicates a stable (preferred) state.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. This is the slide's definition of E .
- (b) Correct. Constrained generation = sampling $\mathbf{y} \sim p(\mathbf{y})$ from the energy-based distribution.
- (c) Incorrect. Higher energy means an unstable state and *lower* probability; the minus sign in $\exp(-E)$ encodes this.

- (d) Correct. The chemistry analogy: low-energy molecules are stable.

C3. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about Langevin dynamics as used in COLD decoding?

- a. The update rule takes a gradient step on the energy function plus Gaussian noise:
$$\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}.$$
- b. The iterates form a Markov chain whose distribution converges to the target distribution as the number of iterations goes to infinity.
- c. The update is structurally similar to gradient descent for training, except that the parameters are replaced by the output logits and the loss by the energy function.
- d. Langevin dynamics requires explicitly computing the normalizing constant of the energy-based distribution at each step.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. η is the step size and $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$ is the noise at iteration n .
- (b) Correct. This convergence property (Welling et al., ICML 2011) is what guarantees the updates yield samples from p .
- (c) Correct. The professor's key analogy: same equation as parameter-level gradient descent, with $\tilde{\mathbf{y}}$ in place of parameters and E in place of the loss.
- (d) Incorrect. It only needs the gradient of the energy; avoiding the intractable normalizer is exactly why it is used.

C4. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following correctly describe the COLD decoding algorithm?

- a. $\tilde{\mathbf{y}}^{(0)}$ is initialized using conventional likelihood-based decoding.
- b. The energy function is formulated as a linear combination of the user-defined constraint functions.

- c. The gradient-based update is repeated for a fixed number of iterations N .
- d. The final output text is read off directly from $\tilde{\mathbf{y}}^{(N)}$ without any discretization step.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. The vanilla likelihood-based generation provides the starting point (which may violate the constraints).
- (b) Correct. $E = -\sum_i \lambda_i f_i$, with constraints defined by the user for the target property.
- (c) Correct. The Langevin update is applied N times.
- (d) Incorrect. A conventional discretization step samples actual tokens from the updated logits at the end.

C5. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about COLD's lexically constrained decoding experiments?

- a. The designed energy function combines four constraint terms, including forward and reverse LM fluency terms.
- b. One term computes the likelihood of the input part $\mathbf{x}$ given the output, rather than the likelihood of the output itself.
- c. The keyword constraint is implemented as an n-gram match between the current $\tilde{\mathbf{y}}$ and the target keywords $\mathbf{y}^*$.
- d. COLD covered fewer keywords than the baselines but produced less fluent text.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. E_1 consists of four constraint functions: forward fluency, reverse-direction fluency, input-side likelihood, and n-gram match.
- (b) Correct. The third term evaluates the input part's likelihood given the output, encouraging coherence with the context.

- (c) Correct. The most direct lexical objective is the n-gram match with the target keywords.
- (d) Incorrect. The opposite: COLD was *more* fluent than previous algorithms and successfully included about 95% of the keywords.

C6. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about controllability in LLM decoding?

- a. Controllability means adding constraints to output generation beyond the likelihood objective.
- b. Generating text in-between a past and a future context requires modeling naturalness with respect to the future context, which standard autoregressive decoding does not consider.
- c. Diversity-promoting decoding (e.g., diverse beam search) can be viewed as a classic example of adding a constraint to the likelihood objective.
- d. With perfectly instruction-following LLMs, explicit constrained-decoding algorithms like COLD would become even more necessary.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. This is the definition: constraints in output generation, not only likelihood.
- (b) Correct. AR decoding conditions only on the past; coherence with the future context must be added as a constraint.
- (c) Correct. The professor cited diversity as the classic example of an added constraint.
- (d) Incorrect. The opposite — if models followed instructions 100%, such decoding would not be needed, which is why it is less used recently.

3분 요약

개념	한 줄 정리
Controllability	likelihood만이 아니라 추가 제약(키워드, 미래 문맥, 다양성 등)을 디코딩에 직접 반영 — 프롬프팅은 implicit·무보장, 디코딩 수정은 explicit
COLD Decoding (Qin et al., NeurIPS 2022)	① 제약을 에너지 함수로 정식화 ② 로짓 공간에서 gradient 업데이트 — training-free 제약 생성
로짓 완화	이산 $\mathbf{y} \in \mathbb{N}^T$ 는 미분 불가 $\rightarrow$ 연속 로짓 $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$ 를 최적화 변수로
에너지 함수	$E(\mathbf{y}) = -\sum_i \lambda_i f_i(\mathbf{y})$ — 제약 만족 $\uparrow$ = 에너지 $\downarrow$ = $p \propto \exp(-E)$ 에서 확률 $\uparrow$
Langevin dynamics	$\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla E + \epsilon^{(n)}, \epsilon \sim \mathcal{N}(0, \sigma) - n \rightarrow \infty$ 에서 목표 분포로 수렴 (Welling, ICML 2011)
알고리즘 4단계	likelihood 초기화 $\rightarrow$ 에너지 정식화 $\rightarrow$ N회 Langevin 업데이트 $\rightarrow$ 이산화 (discretization)
Lexical constraint E_1	forward fluency + reverse fluency + 입력측 우도 + n-gram match — fluency 향들이 키워드 무작위 삽입(reward hacking)을 방지; ~95% coverage, NeuroLogic보다 유창
현대적 위상	instruction following이 강해져 최근엔 덜 쓰이나, 출력 공간 최적화라는 모델링 기법으로서 가치
디코딩 기초 4종	AR = sequential·EOS까지 / temperature = before softmax·low τ = deterministic / top-p = 누적확률 동적 후보 / speculative = draft도 autoregressive·test-time compute = 파라미터 고정