

CAS4133 LLM · 기말 대비 · Chapter 7

Chapter 7. Decoding of LLMs (Controllability · COLD

Decoding)

제어 가능성(Controllability)과 COLD Decoding — 제약을 에너지 함수로 정식화하고 Langevin dynamics로 로짓을 직접 업데이트하는 제약 생성 + 중간고사 디코딩 핵심 복습

 강의일: 2026-05-04 예상 비중: 중 (COLD 신규 + 기출 Problem 5 재출제 대비) 분량: 본문 7개 섹션 + 문제 20문항

목차

1. 중간고사 복습 — 디코딩 기초 & 고급 디코딩 요약 (기출 Problem 5 출처)
2. Controllability — 동기와 문제 설정
3. COLD Decoding — 정식화: 로짓 공간 $\tilde{\mathbf{y}}$ 와 제약 함수 f_i
4. 에너지 기반 모델(EBM)과 에너지 함수 $E(\mathbf{y})$
5. Langevin Dynamics — 그래디언트 기반 샘플링
6. COLD 전체 알고리즘 & Lexically Constrained Decoding 실험
7. COLD의 위상 — 프롬프팅 시대에 왜 덜 쓰이는가
8. 기출 & 예상문제

중간고사 복습 — 디코딩 기초 & 고급

디코딩

(Decoding Basics Recap)

교수는 #7 디코딩 챕터에서 **기초(basics) → 고급 알고리즘(speculative / diverse decoding) → test-time compute → 제어 가능성(controllability)** 순서로 진행했고, 시간 제약으로 이번 강의에서는 controllability만 신규로 다뤘다. 앞의 세 파트는 중간고사 범위였고 **2025 중간 기출 Problem 5 전체(15 점)가 전부 여기서 출제**되었으므로, 기말 재출제에 대비해 요점만 압축 복습한다.

📖 교수 강조 (강의 발언)

"우리는 강의의 마지막 부분으로 디코딩을 다뤘습니다. 먼저 디코딩의 기초를 배웠고, 이후 speculative decoding이나 diverse decoding 같은 고급 디코딩 알고리즘으로 넘어갔으며, 그다음 보상 모델을 사용하는 test-time compute를 다뤘습니다. 이제 시간 제약 때문에 controllability라는 한 부분만 다루겠습니다."

1.1 Autoregressive Decoding (자기회귀 디코딩)

📖 정의

자기회귀 디코딩(autoregressive decoding): 한 번에 한 토큰씩, **모든 이전 토큰을 조건으로 (conditioning on all previous tokens)** 다음 토큰을 생성. **EOS(end-of-sequence) 토큰**이 생성되거나 미리 정의된 **최대 길이(pre-defined max length)**에 도달할 때까지 반복.

자기회귀 분해 (Autoregressive Factorization)

$$p(\mathbf{y} \mid \mathbf{x}) = \prod_{t=1}^T p(y_t \mid \mathbf{x}, y_{<t})$$

$\mathbf{x}$ 는 입력(프롬프트), $y_{<t}$ 는 t 시점 이전에 생성된 모든 토큰. 각 스텝의 토큰은 모델이 출력하는 **확률 분포 (softmax over vocabulary)**에서 선택/샘플링되며, 고정된 가우시안 분포 같은 것이 아니다.

⚠️ 함정 포인트 (T/F 대비)

- "The decoding process can be parallelized across all tokens during inference." → **False**. Autoregressive decoding is **inherently sequential** — token t requires tokens

$1, \dots, t - 1$. (Training-time teacher forcing은 병렬 가능하지만, inference-time decoding은 불가 — 기출 Problem 5-1(b))

- "The next token is sampled from a fixed Gaussian distribution." → **False**. Sampled from the model's output probability distribution (softmax over logits). (기출 Problem 5-1(d))

1.2 Greedy / Beam Search / Diverse Beam Search

방법	핵심 아이디어	특징 / 함정
Greedy decoding	매 스텝 argmax 토큰 선택	지역 최적(local optimum) — 전체 시퀀스 확률 최대를 보장하지 않음. 결정적(deterministic).
Beam search	매 스텝 누적 확률 상위 k 개 가설(beam)을 유지하며 탐색	greedy보다 높은 likelihood의 시퀀스 발견 가능. 그러나 빔들끼리 매우 유사해지는 다양성 부족 문제.
Diverse Beam Search (DBS)	빔을 그룹으로 나누고, 그룹 간 diversity term(페널티) 을 목적함수에 추가	diversity 향 때문에 최종 선택 시퀀스가 perplexity 관점에서 최적일 수 있음 — 기출 Problem 1(x)의 포인트.

1.3 Sampling 계열: Temperature / Top-k / Top-p

Temperature Scaling

$$p(y_t = v) = \frac{\exp(z_v / \tau)}{\sum_{v'} \exp(z_{v'} / \tau)}$$

z_v 는 토큰 v 의 로짓, τ 는 temperature. **softmax 이전에 로짓을 rescale**한다(applied before softmax — 기출 함정). $\tau \downarrow \rightarrow$ 분포가 뾰족(peaky)해져 더 결정적(deterministic) 출력, $\tau \uparrow \rightarrow$ 더 평평(smooth)해져 더 무작위적 출력. $\tau \rightarrow 0$ 이면 greedy와 동일.

구분	Top-k sampling	Top-p (nucleus) sampling
----	----------------	--------------------------

후보 집합 결정	확률 상위 고정 개수 k 개	누적 확률(cumulative probability) 이 p 를 넘는 최소 집합
후보 개수	항상 k 개 (고정)	분포 모양(distribution's shape)에 따라 동적으로 변함 (dynamic flexibility)
설계 목적	저확률 꼬리 토큰 제거	unnatural / degenerate completion 방지 (text degeneration 완화)
Temperature와의 관계	둘 다 temperature와 함께 사용 가능 (temperature로 분포를 조정한 뒤 truncation) — "temperature is irrelevant in top-k"는 False	

⚠ **함정 포인트 (T/F 대비)**

- "Top-p is a special case of beam search with $p=1$." → **False**. Top-p is a **sampling** method, unrelated to beam search (search-based). (기출 Problem 5-3(b))
- "Temperature is applied after the softmax operation." → **False**. It rescales **logits before softmax**. (기출 Problem 5-2(d))
- "Lower temperature increases randomness." → **False**. Lower τ → peakier distribution → **more deterministic**.

1.4 Speculative Decoding (추측 디코딩)

- Draft** — 작은 **draft model**이 여러 토큰을 (자기회귀적으로) 빠르게 제안
- Verify** — 큰 **target model**이 draft 토큰들을 **한 번의 병렬 forward pass**로 검증 (accept/reject)
- Accept & continue** — 수락된 prefix까지 확정, 거절 지점부터 다시 draft → 큰 모델 호출 횟수 감소로 속도 향상. 출력 분포는 target model과 동일하게 유지.

⚠ **함정 포인트 (T/F 대비)**

- "It eliminates the need for sequential generation." → **False**. The **draft model still generates tokens autoregressively**; only verification is parallelized. (기출 Problem 5-4(c))

- "Speculation changes the output distribution of the large model." → **False**.
Acceptance/rejection scheme은 target model의 분포를 보존하도록 설계됨.

1.5 Test-time Compute Scaling

📖 정의

Test-time compute scaling: 학습이 아닌 **추론(inference) 시점**에 더 많은 연산을 투입해 성능을 높이는 전략. 어려운 질의에 동적으로 더 많은 compute를 할당(dynamically allocate more inference compute to harder queries)하고, "longer thinking"으로 복잡한 과제의 추론 정확도를 높임. 예: Best-of-N + reward model, self-consistency, 긴 chain-of-thought.

⚠️ 함정 포인트 (T/F 대비)

- "It is a technique for fine-tuning LLMs using RL." → **False**. It is an **inference strategy**, not a fine-tuning method. (기출 Problem 5-5(b))
- "It improves model capacity by increasing the number of parameters at test time." → **False. Parameters are fixed**; only inference time/compute increases. (기출 Problem 5-5(d))

★ 시험 핵심

기출 Problem 5의 4대 오답 패턴을 외울 것: ① autoregressive = sequential(병렬 불가), ② temperature = *before* softmax & low τ = deterministic, ③ top-p = dynamic candidate set (beam search와 무관), ④ speculative = draft는 여전히 autoregressive / test-time compute = 파라미터 고정·inference 전략. DBS는 diversity 향 때문에 최저 perplexity 시퀀스를 보장하지 않음.

Controllability — 동기와 문제 설 (Controllability: Motivation)

정의

제어 가능성(Controllability): 출력 생성에서 **우도(likelihood)**만이 아니라 **추가적인 제약 (constraints)**을 만족하도록 디코딩하는 것. 슬라이드 원문: "Adding constraints in output generation (**not only likelihood**)".

기존 디코딩(greedy, beam, sampling)은 모두 **likelihood 하나의 목적**을 중심으로 동작한다. 그러나 응용에 따라 likelihood 외의 제약을 생성 과정에 넣고 싶을 수 있다. 교수가 든 예시:

- **Diversity** — 가장 고전적인 예. DBS가 likelihood 목적에 diversity를 추가 제약으로 넣은 사례 → controllability의 한 형태로 볼 수 있음.
- **Keyword inclusion (lexical constraint)** — 특정 키워드(예: "cat", "fox")를 반드시 포함하는 문장 생성.
- **Infilling (text in-between)** — 과거 문맥(past context)과 미래 문맥(future context)이 둘 다 주어졌을 때 그 사이의 중간 텍스트를 생성. 기존 autoregressive 디코딩은 **과거만** 조건으로 보지만, 여기서 생성 결과가 **미래 문맥 관점에서도 자연스러워야** 하므로 이것이 추가 제약으로 모델링됨.
- **Counterfactual reasoning** — 조건의 일부가 바뀌었을 때 일관되도록 텍스트 일부를 수정하는 생성.

2.1 프롬프팅 vs 디코딩 수준 제어

교수 강조 (강의 발언)

"최근 LLM 시대에 더 직접적인 해법은 프롬프팅이겠죠? 예를 들어 'cat'을 키워드로 포함해야 한다'고 프롬프트에 주면 됩니다. 하지만 이런 프롬프팅은 **암묵적(implicit) 해법**이라서, 특정 출력을 실제로 제어할 수는 없습니다. 그래서 디코딩에서 controllability의 목표는 **디코딩 알고리즘 자체를 직접 수정**하는 것입니다."

구분

Prompting (e.g., "include the keyword cat")

Decoding-level control (e.g., COLD)

제어 방식	입력 문맥으로 제약을 전달 — implicit	디코딩 목적함수/알고리즘을 직접 수정 — explicit
보장	모델이 지시를 따를 것이라는 보장 없음	제약 함수를 직접 최적화 → 만족 확률을 원칙적으로 높임
학습 필요	없음	없음 (COLD도 training-free , 디코딩만 수정)

⚠ **함정 포인트 (T/F 대비)**

- "Controllable decoding aims to maximize only the likelihood of the output." → **False**. The whole point is adding constraints **beyond likelihood**.
- "Prompting with the constraint (e.g., 'include keyword X') guarantees that the output satisfies the constraint." → **False**. Prompting is an **implicit** solution and cannot directly control the output.
- "Text infilling with both past and future contexts can be handled by standard autoregressive decoding without modification." → **False**. Standard AR decoding conditions only on the **past**; naturalness w.r.t. the future context must be modeled as an additional constraint.

COLD Decoding — (Formulation: Logit Space & Constraint Functions)

정식화

정의

COLD Decoding (Qin et al., *COLD Decoding: Energy-based Constrained Text Generation with Langevin Dynamics*, **NeurIPS 2022**): 제약을 생성을 ① **제약을 수학적 목적함수(에너지 함수)로 정식화**하고 ② **출력(로짓) 수준에서 gradient-based update**를 반복해 제약을 만족시키는 **에너지 기반(energy-based) 제약 텍스트 생성 프레임워크**. 모델 파라미터는 건드리지 않는다.

교수 강조 (강의 발언)

"핵심 아이디어는 첫째, 제약을 수학적 목적함수로 정식화하고, 둘째, 제약을 만족시키기 위해 **출력 수준에서 gradient-based 업데이트**를 수행한다는 것입니다. **adversarial example을 위한 gradient descent와 매우 유사**합니다 — 파라미터가 아니라 입력/출력을 업데이트한다는 점에서요."

3.1 표기법: 왜 로짓 공간인가

- $\mathbf{y} \in \mathbb{N}^T$: 출력 텍스트(토큰 ID 시퀀스). T = 출력 토큰 개수.
- $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$: $\mathbf{y}$ 의 **로짓(logit)**. V = LLM의 vocabulary 크기. 각 위치마다 V 차원 실수 벡터(soft token representation).
- $f_i(\mathbf{y}) \in \mathbb{R}$: i 번째 **제약 함수(constraint function)**. 각 제약이 스칼라 함수로 포착될 수 있다고 가정. 값이 **클수록 제약을 잘 만족**.

이산 → 연속 완화 (Discrete-to-Continuous Relaxation)

$$\mathbf{y} \in \mathbb{N}^T \xrightarrow{\text{discrete, no gradient}} \tilde{\mathbf{y}} \in \mathbb{R}^{T \times V} \text{ (continuous, differentiable)}$$

텍스트 $\mathbf{y}$ 는 **이산(discrete)** 값이므로 그래디언트를 직접 구할 수 없다. COLD의 해결책: 이산 토큰 공간 대신 **연속인 로짓 공간 $\tilde{\mathbf{y}}$ 를 최적화 변수**로 삼아 업데이트한다. 마지막에만 이산화(discretization)하여 실제 토큰으로 되돌린다.

3.2 제약 함수 f_i 의 예

제약 종류	제약 함수 f_i 의 구현
Fluency constraint (유창성)	LM이 매기는 likelihood of $\mathbf{y}$ — 슬라이드의 대표 예시 ("e.g., likelihood of $\mathbf{y}$ as fluency constraint")
Keyword/lexical constraint	목표 키워드와의 counting / n-gram overlap (n-gram match)
Future-context coherence	미래 문맥에 조건부인 likelihood (역방향 LM 등)

이후 할 일은 f_i 들을 최대화하도록 $\tilde{\mathbf{y}}$ 를 업데이트하는 것. 업데이트된 $\tilde{\mathbf{y}}$ 는 제약을 만족할 가능성이 더 큰 후보가 된다. 남은 질문: "어떻게 **원칙에 입각한(principled)** 방식으로 업데이트하는가?" → 에너지 기반 모델 (§4)과 Langevin dynamics (§5)가 답.

★ 시험 핵심

COLD의 3대 키워드 매핑을 정확히: **optimization variable = 로짓 $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$** (이산 $\mathbf{y} \in \mathbb{N}^T$ 가 아님), **constraint = 스칼라 함수 $f_i(\mathbf{y}) \in \mathbb{R}$** , **update = gradient-based** (output-level, parameter-level 아님). 차원 표기 $\mathbb{R}^{T \times V}$, $\mathbb{N}^T$ 가 그대로 T/F로 나올 수 있다.

⚠ 함정 포인트 (T/F 대비)

- "COLD performs gradient updates directly on the discrete token sequence $\mathbf{y}$." → **False**. Gradients are intractable in the discrete space; COLD updates the **continuous logits $\tilde{\mathbf{y}}$** .
- "COLD fine-tunes the LLM's parameters to satisfy the constraints." → **False**. It is a **decoding-time** method; the update target is the output logits, not model parameters.
- "Each constraint f_i must be a binary indicator (satisfied / not satisfied)." → **False**. $f_i(\mathbf{y}) \in \mathbb{R}$ is a real-valued (differentiable) score, e.g., likelihood or n-gram overlap.

에너지 기반 모델과 에너지 함수 (Energy-Based Model & Energy Function)

정의

에너지 기반 모델(Energy-Based Model, EBM): 에너지 함수 $E(\mathbf{y})$ 로 확률 분포를 기술하는 모델링 방식. 에너지가 낮을수록 안정(stable) → 높은 확률, 에너지가 높을수록 불안정(unstable) → 낮은 확률. (교수의 직관: 화학에서 분자의 에너지 — 낮은 에너지 = 안정 상태)

COLD의 에너지 함수 — 제약의 선형 결합

$$E(\mathbf{y}) := - \sum_i \lambda_i f_i(\mathbf{y})$$

$\lambda_i \geq 0$ 는 i 번째 제약의 가중치. **마이너스 부호**에 주의: f_i 가 클수록(제약을 잘 만족할수록) 에너지 E 는 **낮아진다**. 즉 "제약 만족 = 저에너지 = 고확률"의 방향이 되도록 정의.

에너지 기반 분포 (Boltzmann form)

$$p(\mathbf{y}) = \frac{\exp(-E(\mathbf{y}))}{Z}, \quad Z = \sum_{\mathbf{y}'} \exp(-E(\mathbf{y}'))$$

Z 는 분모의 **정규화 항(normalizing term/constant)**. $-E(\mathbf{y}) = \sum_i \lambda_i f_i(\mathbf{y})$ 이므로, 이 분포에서 $\mathbf{y} \sim p(\mathbf{y})$ 를 샘플링하면 **높은 확률로 제약들을 만족하는 텍스트**가 나온다. 따라서 "제약 하의 텍스트 생성 = 에너지 기반 분포 p 로부터의 샘플링"으로 문제가 재정의된다.

교수 강조 (강의 발언)

"에너지가 높으면 샘플링될 확률이 낮고, 에너지가 낮으면 샘플링될 확률이 높습니다. 높은 에너지는 불안정한 상태를 나타내기 때문에 마이너스 E를 취합니다. 유일한 문제는: **어떻게 이 분포로부터 샘플링하는가?** 단순한 분포가 아니기 때문에(정규화 항 Z 계산 불가) 직접 샘플링이 간단하지 않습니다."

★ 시험 핵심

① $E(\mathbf{y}) = - \sum_i \lambda_i f_i(\mathbf{y})$ 의 **마이너스 부호와 방향성**(높은 $f_i \Rightarrow$ 낮은 에너지 $\Rightarrow$ 높은 확률), ② $p(\mathbf{y}) \propto \exp(-E(\mathbf{y}))$, ③ 이 분포에서의 직접 샘플링은 intractable $\rightarrow$ **Langevin dynamics**

가 필요해지는 이유. 이 3단 논리 흐름이 Pick-all로 나오기 좋다.

⚠ 함정 포인트 (T/F 대비)

- "In COLD, a higher energy $E(\mathbf{y})$ means the text is more likely to satisfy the constraints." → **False**. **Lower** energy $\leftrightarrow$ higher constraint satisfaction $\leftrightarrow$ higher probability under p .
- "The energy function is defined as the product of the constraint functions." → **False**. It is a (negative) **weighted linear combination**: $E = - \sum_i \lambda_i f_i$.
- "Sampling from the energy-based distribution $p(\mathbf{y})$ is straightforward since p is explicitly normalized." → **False**. The normalizing constant Z is intractable; that is exactly why Langevin dynamics is used.

Langevin Dynamics — 그래디언트 기반 샘플링 (Sampling via Langevin Dynamics)

정의

Langevin dynamics: 에너지 기반 분포처럼 직접 샘플링이 어려운 분포에서, 임의의 점에서 시작해 에너지 함수의 그래디언트 $\nabla_y E(y)$ 를 따라 내려가면서 가우시안 잡음을 더하는 반복(Markov chain)으로 샘플을 얻는 고전적 샘플링 알고리즘. (수렴 증명: Welling & Teh, *Bayesian Learning via Stochastic Gradient Langevin Dynamics*, ICML 2011)

Langevin 업데이트 (Markov chain / gradient step)

$$\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}, \quad \epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$$

η 는 **step size**, $\epsilon^{(n)}$ 은 반복 n 에서의 **가우시안 잡음(Gaussian noise)**. 잡음 항 덕분에 단순 경사 하강(한 점으로의 수렴)이 아니라 **분포로부터의 샘플링**이 된다. 핵심 성질: $n \rightarrow \infty$ 일 때 $\tilde{\mathbf{y}}^{(n)}$ 의 분포가 목표 분포 $p(\tilde{\mathbf{y}})$ 로 수렴함이 증명되어 있다.

5.1 경사 하강(파라미터 학습)과의 비교 — 교수의 핵심 직관

교수 강조 (강의 발언)

"손실 함수를 최소화하려고 **파라미터 수준에서** 경사 하강할 때와 매우 유사한 식이죠? 유일한 차이는, **파라미터 자리에 $\tilde{\mathbf{y}}$ 가, 손실 함수 자리에 에너지 함수가** 대입된다는 것뿐입니다. 업데이트 대상이 출력으로, 목적이 에너지 함수로 바뀐 것입니다."

구분	일반 학습 (gradient descent)	COLD의 Langevin dynamics
업데이트 변수	모델 파라미터 θ	출력 로짓 $\tilde{\mathbf{y}}$ (모델은 고정)
목적 함수	손실 $\mathcal{L}(\theta)$	에너지 $E(\tilde{\mathbf{y}}) = -\sum_i \lambda_i f_i$

잡음 항	없음 (결정적 하강)	가우시안 잡음 $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$ 필수 — 샘플링이 되게 함
결과	손실 최소화점	$n \rightarrow \infty$ 에서 $p(\tilde{\mathbf{y}})$ 로부터의 샘플 (수렴 보장)
유사 사례	—	adversarial example 생성(입력에 대한 gradient)과 구조 동일

★ 시험 핵심

Langevin 업데이트 식의 3요소를 식별할 수 있어야 함: ① **gradient term** $-\eta \nabla_{\tilde{\mathbf{y}}} E$ (에너지를 낮추는 방향 = 제약 만족도를 높이는 방향), ② **noise term** $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$, ③ **수렴 성질** ("distribution of $\tilde{\mathbf{y}}^{(n)}$ converges to p as $n \rightarrow \infty$ "). "Markov chain을 형성한다"는 표현도 슬라이드 원문.

⚠ 함정 포인트 (T/F 대비)

- "Langevin dynamics in COLD performs gradient ascent on the energy function." → **False**. It takes gradient **descent** steps on E (lower energy = better constraint satisfaction). (Equivalently, gradient ascent on $\sum_i \lambda_i f_i$.)
- "The Gaussian noise term is an optional trick for escaping local minima and can be dropped without changing what the procedure computes." → **False**. The noise is what makes the iterates **samples from p** rather than a deterministic minimizer; the convergence-to- p guarantee relies on it.
- "After a finite, small number of steps, $\tilde{\mathbf{y}}^{(n)}$ is guaranteed to be an exact sample from p ." → **False**. The guarantee is asymptotic: convergence holds as $n \rightarrow \infty$.
- "Langevin dynamics requires computing the normalizing constant Z of p ." → **False**. It only needs $\nabla_{\tilde{\mathbf{y}}} E - Z$ 와 무관하다는 점이 이 방법을 쓰는 이유.

6.1 전체 알고리즘 (Algorithm Description)

입력: 제약 함수들 $\{f_i\}$ (목표 속성에 맞게 사용자가 직접 정의), 반복 횟수 N , 출력 길이 T .

- 초기화 (Initialization)** — 전통적인 우도 기반 디코딩으로 초기 로짓 $\tilde{\mathbf{y}}^{(0)}$ 을 얻는다 (이 초기 생성은 제약을 위반할 수 있는 vanilla 출력).
- 에너지 함수 정식화** — 제약들의 선형 결합으로 $E(\tilde{\mathbf{y}}) = -\sum_i \lambda_i f_i(\tilde{\mathbf{y}})$ 구성.
- Langevin 업데이트 × N회** — $\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}$ 를 $n = 0, \dots, N-1$ 반복.
- 이산화 (Discretization)** — 업데이트된 로짓 $\tilde{\mathbf{y}}^{(N)}$ 에서 전통적 방식(top-k 필터링 등)으로 실제 토큰 시퀀스 $\mathbf{y}$ 를 샘플링.

6.2 응용: Lexically Constrained Decoding (어휘 제약 디코딩)

COLD 논문에는 여러 응용(abductive reasoning, counterfactual reasoning 등)이 있지만, 강의에서는 가장 직관적인 **어휘 제약 디코딩**만 소개. 목표: **특정 키워드들을 포함하는 자연스러운 문장** 생성.

교수 강조 (강의 발언)

"우려되는 점은 **reward hacking**입니다 — 제약을 만족시키는 부자연스러운 방식은 키워드를 **무작위 위치에 삽입**해 버리는 것이죠. 제약 측면에서는 만족되지만 문장은 자연스럽지 않습니다. 그래서 목표는: **자연스러운 문장을 생성하되, 키워드를 가능한 한 자연스럽게 포함**시키는 것입니다."

설계된 에너지 함수 E_1 — 4개의 제약 함수 결합

Lexically constrained decoding을 위한 에너지 (개념 구조)

$$E_1(\tilde{\mathbf{y}}) = - \left[\underbrace{\lambda_a f_{\overrightarrow{\text{LM}}}(\tilde{\mathbf{y}}; \mathbf{x})}_{\text{① 순방향 유창성}} + \underbrace{\lambda_b f_{\overleftarrow{\text{LM}}}(\tilde{\mathbf{y}})}_{\text{② 역방향 유창성}} + \underbrace{\lambda_c f_{\text{pred}}(\mathbf{x} | \tilde{\mathbf{y}})}_{\text{③ 입력 부분의 우도}} + \underbrace{\lambda_d f_{\text{sim}}(\tilde{\mathbf{y}}; \mathbf{y}^*)}_{\text{④ n-gram 유사도}} \right]$$

$\mathbf{y}^*$ 는 목표 키워드(target keywords). 각 항의 의미는 아래 표 참조.

항	제약 함수	의미 (강의 설명)
① soft fluency	좌→우(forward) LM likelihood의 cross-entropy	출력의 자연스러움(naturalness) — 우도의 전통적 정의. 주어진 문맥에 대한 확률 계산.
② reverse LM fluency	같은 모델 로 우도의 역방향(reverse direction) 고려	역방향에서도 유창하도록 — 키워드 삽입이 앞뒤 어느 쪽에서 봐도 자연스럽게.
③ future-context / input likelihood	출력 y 가 주어졌을 때 입력 x 부분 자체의 우도	출력이 아니라 입력 부분을 우도 측면에서 생각 — 출력이 입력 문맥과 일관되도록.
④ n-gram similarity	현재 $\tilde{y}$ 와 목표 키워드 y^* 의 n-gram match	어휘 제약의 가장 직접적 목적 — 키워드 포함 정도를 측정.

이 네 제약을 하나의 에너지 함수로 결합해 그래디언트를 취한다. ①~③은 "자연스럽게", ④는 "키워드를 포함하게" — ④만 있으면 reward hacking(무작위 삽입)이 일어나므로 **유창성 제약들과의 결합이 핵심 설계**다.

6.3 실험 결과 (vs NeuroLogic 등 베이스라인)

- COLD는 이전 알고리즘들 대비 **더 유창(fluent)**한 출력을 생성.
- **키워드 포함률(coverage) 약 95%** — 대부분의 키워드를 성공적으로 포함.
- 단, **NeuroLogic 베이스라인과 비교하면** human 평가 기준 점수에서 **perplexity가 상당히 낮음(= 더 유창함)**이 COLD의 강점으로 제시됨 — 즉 NeuroLogic 같은 탐색 기반 방법 대비 fluency에서 우위.

★ 시험 핵심

알고리즘 4단계의 **순서**(likelihood 초기화 → 에너지 정식화 → N회 Langevin 업데이트 → 이산화)와, lexical constraint에서 **에너지 함수가 4개 항**(forward fluency / reverse fluency / input-side likelihood / n-gram match)으로 구성된다는 것, 그리고 **fluency 항들이 reward hacking(키워드 무작위 삽입)을 막기 위해 존재**한다는 설계 의도. 실험 수치는 "**~95% keyword coverage + more fluent than baselines (incl. NeuroLogic)**".

⚠ 함정 포인트 (T/F 대비)

- "In COLD's lexically constrained decoding, the n-gram match term alone is sufficient to produce natural outputs." → **False**. Alone it invites **reward hacking** (inserting keywords at random positions); fluency terms (forward + reverse LM) are needed.
- "COLD initializes $\tilde{\mathbf{y}}^{(0)}$ randomly from Gaussian noise." → **False**. It is initialized using **conventional likelihood-based decoding** (the vanilla generation).
- "The final output of COLD is the continuous logit $\tilde{\mathbf{y}}^{(N)}$ itself." → **False**. A **discretization** step samples actual tokens from the updated logits at the end.
- "The reverse-LM term in E_1 requires training a separate backward language model from scratch." → **False** (강의 기준). The **same model** is used to consider the reverse direction of the likelihood.

COLD의 위상 — 프롬프팅 시대의 controllable decoding

(Where COLD
Stands Today)

교수 강조 (강의 발언)

"만약 언어 모델이 in-context learning을 완전히 수행해서 — 'cat과 fox를 키워드로 포함하라' 같은 — 여러분의 지시를 **100% 따를 수 있다면, 이런 종류의 디코딩은 필요하지 않겠죠?** 그것이 이 알고리즘이 최근에 자주 사용되지 않는 이유입니다. 하지만 이런 모델링 기법은 **고급 디코딩에 관한 지식 체계의 일부로서 소개할 가치가 충분**하다고 생각합니다."

- **현대적 한계:** 강력한 instruction-following LLM에서는 프롬프팅(in-context learning)만으로 제약 만족이 상당 부분 가능 → COLD류 명시적 제약 디코딩의 실용적 수요 감소.
- **그럼에도 배우는 이유:** ① 프롬프팅은 여전히 implicit·무보장, ② 에너지 기반 정식화 + Langevin 샘플링이라는 **모델링 기법 자체의 일반성** (출력 공간 최적화, training-free 제어라는 사고방식은 test-time 기법 전반과 연결됨).

함정 포인트 (T/F 대비)

- "COLD-style constrained decoding is widely used in production with today's instruction-following LLMs." → **False**. The professor explicitly noted it is **not frequently used recently**, since strong in-context instruction following often suffices.
- "Because prompting can express constraints, decoding-level controllability is conceptually equivalent to prompting." → **False**. Prompting is implicit with no guarantee; decoding-level control **directly modifies the decoding objective/algorithm**.

Q 기출 & 예상문제

🎯 작년 기말 출제: Inference 계산 문제 (Problem 2, 20점)

⚠ 기말 유형 경고 — 손계산 필수

기말 Problem 2는 객관식이 아니라 손계산(hand-calculation)이다. 행렬곱 · word embedding concat · 해밍거리 · top-K/temperature · greedy/beam을 직접 계산하는 연습이 필수. 작년에는 ① 입력 시퀀스 → embedding 행렬 → ② 행렬곱 $\tilde{x} \circ M$ → ③ 해밍거리로 output logit → ④ top-K(K=1) 샘플링 → ⑤ autoregressive로 다음 토큰까지, 다섯 단계를 모두 손으로 풀게 했다.

대비 포인트: 디코딩 알고리즘(greedy / top-k / top-p / temperature / beam)을 손으로 적용하는 유형을 반드시 연습할 것. logit 벡터가 주어지면 (i) greedy=argmax, (ii) top-k=상위 k개만 남기고 정규화 후 샘플, (iii) top-p=누적확률 임계, (iv) temperature= z/τ 후 softmax — 각각을 직접 계산해보는 것이 핵심.

P2. Problem 2: Inference with LLM (총 20점, 4문항 × 5점)

2025 기말 기출 원문

아주 단순한 LLM M 이 단 하나의 행렬로만 구성된다고 하자:

$$M = \begin{bmatrix} 1 & 1 & 0 \\ -1 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

M 은 벡터 시퀀스 $\tilde{x} \in \mathbb{R}^{L \times 3}$ 를 단순 행렬곱 $\circ$ 로 매핑한다 (주의: 곱 순서는 아래와 동일해야 함):

$$M : \tilde{x} \longrightarrow \tilde{x} \circ M$$

또한 M 은 다음 word embedding을 갖는다 (CAS 4133 Final 어휘):

#	단어	embedding	#	단어	embedding
1	한	[1, 0, 0]	8	고맙습니다	[3, 0, 1]
2	학기	[1, 1, 0]	9	했습니다	[0, 2, 3]

3	동안	[0, 1, 1]	10	많았습니다	[1, 2, 3]
4	매우	[-1, 1, 0]	11	감사합니다	[3, 1, 2]
5	수고	[0, 1, 2]	12	하셨습니다	[0, 2, 2]
6	고생	[1, 1, 2]	13	많았어요	[1, 2, 2]
7	정말	[0, 0, 2]			

1. **(5점)** 입력 시퀀스 $x = \text{"한 학기 동안"}$ 을 받았다고 하자. row-axis로 embedding을 concat하여 단어 시퀀스를 하나의 행렬로 변환하라 (공백 무시).
2. **(5점)** next word prediction을 위한 output logit o 를 계산하라. inner product 대신 해밍거리 $H(\cdot, \cdot)$ 를 사용한다: $H(u, v) = \sum_{i=1}^d 1[u_i \neq v_i]$.
3. **(5점)** 위에서 얻은 o 에 **top-K (K=1) random sampling**을 적용하면 next word y_1 은?
4. **(5점)** 같은 디코딩 알고리즘으로 autoregressive하게 한 토큰 더 생성하면 y_2 는?

▼ 정답 & 단계별 풀이 (KaTeX) 보기

① **embedding 행렬 concat (5점)** — "한"=[1,0,0], "학기"=[1,1,0], "동안"=[0,1,1]을 row로 쌓는다:

$$\tilde{x} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}$$

② **행렬곱 후 해밍거리로 logit o (5점)**

먼저 $\tilde{x} \circ M$ 을 계산한다 (각 row가 M 과 곱해짐):

$$\tilde{x} \circ M = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ -1 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

next word prediction이므로 **마지막 row** $q = [0, 1, 2]$ 를 query로 사용한다. 각 vocabulary embedding v 에 대해 해밍거리 $H(q, v) = \sum_i 1[q_i \neq v_i]$ (성분이 **같으면 +1**):

예: "한"=[1,0,0] → 0=1?아니오, 1=0?아니오, 2=0?아니오 → 0. "수고"=[0,1,2] → 세 성분 모두 일치 → 3.

$$o = [0, 1, 2, 1, \mathbf{3}, 2, 2, 0, 1, 0, 2, 2, 1]$$

(순서: 한, 학기, 동안, 매우, **수고**, 고생, 정말, 고맙습니다, 했습니다, 많았습니다, 감사합니다, 하셨습니다, 많았어요)

③ **top-K (K=1) → y_1 (5점)** — K=1이면 logit이 최대인 토큰 하나만 후보로 남으므로 random sampling이라도 결국 argmax와 동일:

$$y_1 = \arg \max_v o_v = o_5 = 3 \Rightarrow y_1 = \text{“수고”}$$

④ **autoregressive로 y_2 (5점)** — "수고"=[0,1,2]를 시퀀스에 append하여 다시 행렬곱:

$$\tilde{\mathbf{x}}' = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}, \quad \tilde{\mathbf{x}}' \circ M = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \\ 1 & 2 & 3 \end{bmatrix}$$

새 마지막 row $q' = [1, 2, 3]$ 로 해밍거리 logit:

$$o' = [1, 1, 0, 0, 0, 1, 0, 0, 2, \mathbf{3}, 0, 1, 2]$$

"많았습니다"=[1,2,3] → 세 성분 모두 q' 와 일치 → 3 (최대).

$$y_2 = \arg \max_v o'_v = o'_{10} = 3 \Rightarrow y_2 = \text{“많았습니다”}$$

∴ **정답: $y_1 = \text{“수고”}, y_2 = \text{“많았습니다”}$ (생성 시퀀스: "한 학기 동안 수고 많았습니다")**

P1-viii. Problem 1 (viii): DoLa (True/False, 3점)

2025 기말 기출 원문

작년 출제·올해 범위 밖 (참고용)

※ DoLa는 **올해 슬라이드에는 없는** 항목이다. 작년 기말 True/False에 나왔던 문항이라 참고용으로만 수록한다 (직접 출제 가능성은 낮음).

DoLa selects the intermediate layer that achieves the **minimum** JSD compared to the output probability at the last layer, and then applies contrastive decoding.

▼ 정답 & 해설 보기

False. Choose the layer that **maximizes** JSD (not minimizes). (DoLa = Decoding by

Contrasting Layers: 마지막 층 출력 분포와의 JSD가 가장 큰 — 즉 가장 다른 — 중간 층을 골라 대조 디코딩을 수행한다. "minimum JSD"라고 한 점이 오답 포인트.)

A1. Problem 1 (x) (True/False, 3 pts)

2025 중간 기출 원문

Diverse Beam Search (DBS) always chooses the most probable sequence (i.e., the lowest perplexity) from all beams.

▼ 정답 & 해설 보기

False. As the diversity term is introduced, the selected sequence can be not optimal in the perspective of perplexity. (diversity 페널티가 목적함수에 추가되므로, 선택된 시퀀스가 perplexity 기준 최적이 아닐 수 있음)

A2. Problem 5-1 (Pick all that are correct; any wrong answer will lead to 0 points, 3 pts)

2025 중간 기출 원문

Which of the following are true about autoregressive decoding in LLMs?

- a. Each token is generated by conditioning on all previous tokens.
- b. The decoding process can be parallelized across all tokens during inference.
- c. The process continues until an end-of-sequence (EOS) token is generated or upon reaching a pre-defined max length.
- d. The next token is sampled from a fixed Gaussian distribution.

▼ 정답 & 해설 보기

정답: (a), (c)

- (a) Correct. Standard autoregressive decoding generates one token at a time, using all the previous tokens.
- (b) Incorrect. It is inherently sequential (not parallel).
- (c) Correct. Generation typically stops when an EOS token is generated or predefined threshold is reached.
- (d) Incorrect. Tokens are sampled from the model's output probability distribution, not Gaussian.

A3. Problem 5-2 (Pick all that are correct; any wrong answer will lead to 0 points, 3 pts) 2025 중간 기출 원문

Which of the following are true about temperature-controlled sampling?

- a. Temperature controls the sharpness or smoothness of the output distribution.
- b. Lower temperature values result in more deterministic outputs.
- c. Temperature is irrelevant in top-k sampling.
- d. Temperature is applied after the softmax operation.

▼ 정답 & 해설 보기

정답: (a), (b)

- (a) Correct. High temperature → more randomness, low temperature → peaky distribution.
- (b) Correct. Lower temperatures lead to more confident predictions.
- (c) Incorrect. Temperature is still relevant and often used alongside top-k.
- (d) Incorrect. It rescales logits before applying softmax.

A4. Problem 5-3 (Pick all that are correct; any wrong answer will lead to 0 points, 3 pts) 2025 중간 기출 원문

Which of the following statements are correct about top-p (nucleus) sampling?

- a. Top-p sampling adjusts the candidate set based on cumulative probability.
- b. Top-p is a special case of beam search with $p=1$.
- c. Top-p allows dynamic flexibility based on the distribution's shape.
- d. It is designed to avoid unnatural or degenerate completions.

▼ 정답 & 해설 보기

정답: (a), (c), (d)

- (a) Correct. The candidate pool is chosen based on cumulative probability and predefined threshold.

- (b) Incorrect. Top-p is not related to beam search.
- (c) Correct. It adapts the number of candidates per step.
- (d) Correct. It was designed to mitigate degeneration in sampling.

A5. Problem 5-4 (Pick all that are correct; any wrong answer will lead to 0 points, 3 pts) 2025 중간 기출 원문

Which of the following describe speculative decoding?

- a. It uses a small draft model to propose multiple tokens at once.
- b. It verifies the drafts with a larger target model.
- c. It eliminates the need for sequential generation.
- d. It speeds up decoding by reducing the number of expensive large model inferences.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. A lightweight model proposes token drafts.
- (b) Correct. The large target model checks and filters the drafts.
- (c) Incorrect. The draft model still generates the tokens via autoregressive generation.
- (d) Correct. It reduces the number of calls to the large model.

A6. Problem 5-5 (Pick all that are correct; any wrong answer will lead to 0 points, 3 pts) 2025 중간 기출 원문

Which of the following describe the concept of test-time compute scaling in LLMs?

- a. It allows models to dynamically allocate more inference compute to harder queries.
- b. It is a technique for fine-tuning large language models using reinforcement learning.
- c. It enables more accurate reasoning by allowing "longer thinking" on complex tasks.
- d. It improves model capacity by increasing the number of parameters at test time.

▼ 정답 & 해설 보기

정답: (a), (c)

- (a) Correct. Dynamic inference strategies help allocate more resources to harder problems.
- (b) Incorrect. Test-time compute scaling is not a fine-tuning method, but an inference strategy.
- (c) Correct. It enables the model to produce better results by spending more compute.
- (d) Incorrect. The number of parameters is fixed; it increases inference time, not model size.

Q-B. 예상문제 — True/False (COLD / Controllability 중심)

B1. (True/False) 예상문제

In COLD decoding, the gradient-based update is performed on the discrete token sequence $\mathbf{y} \in \mathbb{N}^T$ directly.

▼ 정답 & 해설 보기

False. Since $\mathbf{y}$ is discrete, gradients are intractable. COLD instead updates the continuous logits $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$, and discretizes only at the end.

B2. (True/False) 예상문제

In COLD decoding, the energy function is defined as $E(\mathbf{y}) := -\sum_i \lambda_i f_i(\mathbf{y})$, so that an output satisfying the constraints better (higher f_i) has lower energy and thus higher probability under the energy-based distribution.

▼ 정답 & 해설 보기

True. $p(\mathbf{y}) \propto \exp(-E(\mathbf{y})) = \exp(\sum_i \lambda_i f_i(\mathbf{y}))$; higher constraint satisfaction $\rightarrow$ lower energy $\rightarrow$ higher sampling probability, mirroring the stable/unstable intuition of energy-based models.

B3. (True/False) 예상문제

Langevin dynamics in COLD adds Gaussian noise at each iteration, and the distribution of the updated variable $\tilde{\mathbf{y}}^{(n)}$ is proved to converge to the target energy-based distribution as $n \rightarrow \infty$.

▼ 정답 & 해설 보기

True. The update is $\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}$ with $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$; convergence to the target distribution as $n \rightarrow \infty$ was proved by Welling et al. (ICML 2011).

B4. (True/False) 예상문제

COLD decoding requires fine-tuning the language model so that its outputs satisfy the target constraints.

▼ 정답 & 해설 보기

False. COLD is a decoding-time (training-free) method: the model parameters are fixed, and only the output logits $\tilde{\mathbf{y}}$ are iteratively updated via gradients of the energy function.

B5. (True/False) 예상문제

In COLD's lexically constrained decoding, using only the n-gram match constraint with the target keywords is enough, since maximizing keyword overlap naturally produces fluent sentences.

▼ 정답 & 해설 보기

False. Maximizing the n-gram match alone invites a reward-hacking style failure: keywords can be inserted at random positions, satisfying the constraint but producing unnatural text. Hence fluency constraints (forward and reverse LM likelihoods) are combined in the energy function.

B6. (True/False) 예상문제

In COLD decoding, the initial logits $\tilde{\mathbf{y}}^{(0)}$ are obtained by conventional likelihood-based decoding, and the final text is obtained by discretizing the updated logits after N Langevin iterations.

▼ 정답 & 해설 보기

True. The algorithm: initialize $\tilde{\mathbf{y}}^{(0)}$ with conventional likelihood, formulate the energy as a linear combination of constraints, take N gradient-based (Langevin) updates, then sample tokens from the updated logits via conventional discretization.

B7. (True/False) 예상문제

Prompting an instruction-following LLM with a constraint (e.g., "include the keyword cat") is an explicit control method that guarantees the constraint is satisfied in the output.

▼ 정답 & 해설 보기

False. Prompting is an implicit solution — it cannot directly control the output and provides no guarantee. Decoding-level controllability methods like COLD explicitly modify the decoding algorithm/objective instead.

B8. (True/False) 예상문제

Sampling from the energy-based distribution $p(\mathbf{y}) = \exp(-E(\mathbf{y}))/Z$ is non-trivial because the normalizing term is intractable, which is why COLD resorts to Langevin dynamics using the gradient $\nabla_{\mathbf{y}} E(\mathbf{y})$.

▼ 정답 & 해설 보기

True. Direct sampling from the unnormalized energy-based distribution is not straightforward; Langevin dynamics only requires gradients of the energy (not Z), making sampling tractable.

C1. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about the formulation of COLD decoding?

- a. The output text $\mathbf{y}$ lives in $\mathbb{N}^T$, while its logit $\tilde{\mathbf{y}}$ lives in $\mathbb{R}^{T \times V}$, where V is the vocabulary size.
- b. Each constraint is assumed to be captured by a real-valued function $f_i(\mathbf{y}) \in \mathbb{R}$, e.g., the likelihood of $\mathbf{y}$ as a fluency constraint.
- c. The optimization variable is the discrete token sequence, since logits are not differentiable.
- d. Working in the logit space mitigates the challenge that gradients are hard to compute in the discrete space.

▼ 정답 & 해설 보기**정답: (a), (b), (d)**

- (a) Correct. This is exactly the notation in the lecture: $\mathbf{y} \in \mathbb{N}^T$, $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$.
- (b) Correct. Constraints are scalar functions; likelihood serves as the fluency constraint example.
- (c) Incorrect. It is the opposite: the discrete sequence is not differentiable, so the continuous logits are optimized.
- (d) Correct. The continuous relaxation is precisely the motivation for considering $\tilde{\mathbf{y}}$.

C2. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about the energy-based formulation in COLD decoding?

- a. The energy function is defined as $E(\mathbf{y}) := -\sum_i \lambda_i f_i(\mathbf{y})$, a weighted linear combination of constraint functions.
- b. Generating text under constraints is cast as sampling from the energy-based distribution $p(\mathbf{y}) \propto \exp(-E(\mathbf{y}))$.
- c. Higher energy corresponds to higher probability of being sampled.

- d. The framework is motivated by energy-based models, where low energy indicates a stable (preferred) state.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. This is the slide's definition of E .
- (b) Correct. Constrained generation = sampling $\mathbf{y} \sim p(\mathbf{y})$ from the energy-based distribution.
- (c) Incorrect. Higher energy means an unstable state and lower probability; the minus sign in $\exp(-E)$ encodes this.
- (d) Correct. The chemistry analogy: low-energy molecules are stable.

C3. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about Langevin dynamics as used in COLD decoding?

- a. The update rule takes a gradient step on the energy function plus Gaussian noise:
$$\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla_{\tilde{\mathbf{y}}} E(\tilde{\mathbf{y}}^{(n)}) + \epsilon^{(n)}.$$
- b. The iterates form a Markov chain whose distribution converges to the target distribution as the number of iterations goes to infinity.
- c. The update is structurally similar to gradient descent for training, except that the parameters are replaced by the output logits and the loss by the energy function.
- d. Langevin dynamics requires explicitly computing the normalizing constant of the energy-based distribution at each step.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. η is the step size and $\epsilon^{(n)} \sim \mathcal{N}(0, \sigma)$ is the noise at iteration n .
- (b) Correct. This convergence property (Welling et al., ICML 2011) is what guarantees the updates yield samples from p .
- (c) Correct. The professor's key analogy: same equation as parameter-level gradient descent, with $\tilde{\mathbf{y}}$ in place of parameters and E in place of the loss.

- (d) Incorrect. It only needs the gradient of the energy; avoiding the intractable normalizer is exactly why it is used.

C4. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following correctly describe the COLD decoding algorithm?

- a. $\tilde{\mathbf{y}}^{(0)}$ is initialized using conventional likelihood-based decoding.
- b. The energy function is formulated as a linear combination of the user-defined constraint functions.
- c. The gradient-based update is repeated for a fixed number of iterations N .
- d. The final output text is read off directly from $\tilde{\mathbf{y}}^{(N)}$ without any discretization step.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. The vanilla likelihood-based generation provides the starting point (which may violate the constraints).
- (b) Correct. $E = -\sum_i \lambda_i f_i$, with constraints defined by the user for the target property.
- (c) Correct. The Langevin update is applied N times.
- (d) Incorrect. A conventional discretization step samples actual tokens from the updated logits at the end.

C5. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about COLD's lexically constrained decoding experiments?

- a. The designed energy function combines four constraint terms, including forward and reverse LM fluency terms.
- b. One term computes the likelihood of the input part $\mathbf{x}$ given the output, rather than the likelihood of the output itself.

- c. The keyword constraint is implemented as an n-gram match between the current $\tilde{y}$ and the target keywords y^* .
- d. COLD covered fewer keywords than the baselines but produced less fluent text.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. E_1 consists of four constraint functions: forward fluency, reverse-direction fluency, input-side likelihood, and n-gram match.
- (b) Correct. The third term evaluates the input part's likelihood given the output, encouraging coherence with the context.
- (c) Correct. The most direct lexical objective is the n-gram match with the target keywords.
- (d) Incorrect. The opposite: COLD was *more* fluent than previous algorithms and successfully included about 95% of the keywords.

C6. (Pick all that are correct; any wrong answer will lead to 0 points)

예상문제

Which of the following are true about controllability in LLM decoding?

- a. Controllability means adding constraints to output generation beyond the likelihood objective.
- b. Generating text in-between a past and a future context requires modeling naturalness with respect to the future context, which standard autoregressive decoding does not consider.
- c. Diversity-promoting decoding (e.g., diverse beam search) can be viewed as a classic example of adding a constraint to the likelihood objective.
- d. With perfectly instruction-following LLMs, explicit constrained-decoding algorithms like COLD would become even more necessary.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. This is the definition: constraints in output generation, not only likelihood.

- (b) Correct. AR decoding conditions only on the past; coherence with the future context must be added as a constraint.
- (c) Correct. The professor cited diversity as the classic example of an added constraint.
- (d) Incorrect. The opposite — if models followed instructions 100%, such decoding would not be needed, which is why it is less used recently.

3분 요약

개념	한 줄 정리
Controllability	likelihood만이 아니라 추가 제약(키워드, 미래 문맥, 다양성 등)을 디코딩에 직접 반영 — 프롬프팅은 implicit·무보장, 디코딩 수정은 explicit
COLD Decoding (Qin et al., NeurIPS 2022)	① 제약을 에너지 함수로 정식화 ② 로짓 공간에서 gradient 업데이트 — training-free 제약 생성
로짓 완화	이산 $\mathbf{y} \in \mathbb{N}^T$ 는 미분 불가 $\rightarrow$ 연속 로짓 $\tilde{\mathbf{y}} \in \mathbb{R}^{T \times V}$ 를 최적화 변수로
에너지 함수	$E(\mathbf{y}) = -\sum_i \lambda_i f_i(\mathbf{y})$ — 제약 만족 $\uparrow$ = 에너지 $\downarrow$ = $p \propto \exp(-E)$ 에서 확률 $\uparrow$
Langevin dynamics	$\tilde{\mathbf{y}}^{(n+1)} = \tilde{\mathbf{y}}^{(n)} - \eta \nabla E + \epsilon^{(n)}, \epsilon \sim \mathcal{N}(0, \sigma) - n \rightarrow \infty$ 에서 목표 분포로 수렴 (Welling, ICML 2011)
알고리즘 4단계	likelihood 초기화 $\rightarrow$ 에너지 정식화 $\rightarrow$ N회 Langevin 업데이트 $\rightarrow$ 이산화 (discretization)
Lexical constraint E_1	forward fluency + reverse fluency + 입력측 우도 + n-gram match — fluency 향들이 키워드 무작위 삽입(reward hacking)을 방지; ~95% coverage, NeuroLogic보다 유창
현대적 위상	instruction following이 강해져 최근엔 덜 쓰이나, 출력 공간 최적화라는 모델링 기법으로서 가치
중간 복습 4종	AR = sequential·EOS까지 / temperature = before softmax·low τ = deterministic / top-p = 누적확률 동적 후보 / speculative = draft도 autoregressive·test-time compute = 파라미터 고정