

CAS4133 LLM · 기말 대비 · Chapter 8

Chapter 8. AI Feedback (for Training & Evaluation)

사람 대신 LLM이 평가하고(G-Eval, LLM-as-a-Judge), LLM이 가르친다(RLAIF, Constitutional AI)
— 3대 judge bias와 SL-CAI/RL-CAI 2단계 구분이 핵심.

 강의일: 2026-05-04 (후반부) 예상 비중: 중상 (기출 직결: LC win rate) 분량: 본문 7섹션 + 문제 15

목차

1. AI Feedback 개요 — 왜 AI 피드백인가?
2. 평가 ① G-Eval: 기준 기반 인스턴스 단위 평가
3. 평가 ② LLM-as-a-Judge & MT-Bench
4. Judge의 3대 Bias와 해법 (AlpacaEval LC Win Rate)
5. 학습을 위한 AI Feedback — RLHF의 한계
6. Helpfulness vs Harmlessness (Anthropic HH-RLHF)
7. Constitutional AI: SL-CAI → RL-CAI (RLAIF)
8. 기출 & 예상문제

직전 파트(#7 Decoding)의 제어 가능성(controllability) 논의를 마치고 이어지는 챕터로, **AI 피드백(AI feedback)**을 ① **평가(evaluation)**와 ② **학습(training)** 두 축으로 나누어 다룬다.

정의

AI Feedback: 사람(human annotator) 대신 **LLM 자신이 출력의 품질을 판단·점수화·비교**하여, 그 신호를 평가 지표 또는 학습 신호(reward/label)로 사용하는 패러다임.

동기: Human Feedback의 한계

- **비용(cost):** 사람 주석(human annotation)은 비싸고 느리다. 사람만으로 구성된 데이터 파이프라인 대비 LLM 평가는 훨씬 저렴 → **scalability**.
- **잡음(noise)·주관성:** 선호 판단은 매우 주관적(subjective)이라 사람 사이에서도 일치도가 낮다(MT-Bench에서 human-human agreement 81%에 불과). 역설적으로 LLM 평가가 더 일관적일 수 있다.
- **설명가능성(explainability):** LLM에게는 판단 근거(rationale)를 생성하라는 지시 한 줄을 추가하면 되지만, 사람에게 상세 근거를 요구하면 주석 시간이 폭증하고 결과도 잡음이 많다.
- **모델이 사람보다 똑똑해지는 미래:** 모델 성능이 좋아질수록 사람이 선호 레이블을 다는 일 자체가 어려워진다 → AI가 AI를 정렬하는 **scalable alignment**가 필요(→ §7 Constitutional AI).

교수 강조 (강의 발언)

"사실 이전 강의에서 우리는 이미 이 패러다임을 만났다. **LLaMA-3의 데이터 필터링**에서 기준을 만들고 LLM으로 레이블을 얻어 작은 분류기를 학습시켰다 — 즉 데이터 수준에서는 AI 피드백이 이미 LLM 학습에 포함되어 있었다. 이번 파트에서는 이를 더 형식적으로 다루고, 학습에 더 적극적으로 활용하는 방법으로 넘어간다."

축	대표 방법	핵심 질문
AI Feedback for Evaluation	G-Eval (instance-wise), LLM-as-a-Judge (pairwise)	LLM의 판단이 사람 평가와 얼마나 일치하는가? 어떤 bias가 있는가?

**AI Feedback for
Training**

RLAIF, Constitutional AI (SL-
CAI/RL-CAI), Self-Rewarding LM

사람 레이블 없이도 AI 피드백만으로
정렬(alignment)이 가능한가?

★ 시험 핵심

AI 피드백의 두 용도(evaluation vs training)를 구분하고, 각각의 대표 방법 이름·논문을 매칭할 수
있어야 한다. 평가 쪽 핵심 키워드는 **scalability & explainability**, 학습 쪽 핵심 키워드는
scalable alignment.

2 평가 ① G-Eval (NLG Evaluation using GPT-4)

Liu et al., "G-EVAL: NLG Evaluation using GPT-4 with Better Human Alignment", EMNLP 2023

정의

G-Eval: LLM을 사용해 다른 LLM 출력의 품질을 평가(assess quality of outputs of LLM)하는 생성 모델 기반·인스턴스 단위(instance-wise) 평가 프레임워크. 사람 주석자에게 과제와 가이드라인을 주듯, LLM에게 과제 정보와 기준을 주고 점수를 매기게 한다.

G-Eval 파이프라인 (3단계)

- 1 사용자 입력** — 사람이 **(1) Task information**(예: 뉴스 기사 요약 평가)과 **(2) Evaluation criteria**(예: coherence, 1~5점)를 제공한다. 이 둘은 반드시 사람이 직접 줘야 한다.
- 2 Evaluation steps 자동 생성** — 이 입력으로 LLM이 **평가 단계(evaluation steps)**를 **automatically** 생성한다. 평가 관점의 chain이라고 볼 수 있다(CoT와 유사한 역할).
- 3 평가 수행** — LLM이 evaluation criteria와 task info에 따라 주어진 입력(기사+요약문)을 평가하여 점수(예: 1~5)를 출력한다.

교수 강조 (강의 발언)

"과제 정보와 기준을 생략하고 예시만 주면 모델이 **자기만의 판단 기준**을 만들어 버려서, 결정이 어떻게 내려졌는지에 대한 공정성과 명확성을 잃는다. 그래서 최소한 task information과 evaluation criteria는 우리가 직접 줘야 한다."

기존 지표와의 비교

지표	비교 수준	방식	한계
ROUGE	표면 수준 (surface-level)	목표 요약 vs 사람이 만든 황금 요약 (golden/reference summary)의 n-gram overlap	의미가 같아도 표현이 다르면 점수 낮음; reference 필요

BERTScore (Zhang et al., ICLR 2020)	임베딩 기반 (embedding- based)	목표·참조 요약 벡터로 인코딩 후 cosine similarity	여전히 reference 필 요; 세밀한 품질 기준 반영 어려움
G-Eval (GPT-4)	생성 모델 기반	criteria 기반 직접 채점	judge bias 존재 (§4); 약한 LLM이면 기존 지 표보다 못할 수 있음

- **핵심 실험 결과:** G-Eval with **GPT-4**가 사람 평가와 **가장 높은 상관관계(highest correlation to human evaluation)**를 보인다.
- 단, **GPT-3.5 같은 상대적으로 약한 LLM**을 쓰면 성능이 제한적이어서 기존 지표보다 나쁠 수 있다. LLM capacity를 키울수록 평가 정확도도 증가한다.

표준 패러다임으로의 채택 — Self-Rewarding LM

특정 기준(specific criteria)을 가진 LLM-as-evaluator는 이제 **표준 접근(standard approach)**이 되었다. 대표 사례가 **Self-Rewarding Language Models** (Yuan et al., Meta, ICML 2024): 모델이 **스스로 자신의 응답을 채점(LLM-as-a-Judge 프롬프트로 self-reward 생성)**하여 만든 선호 데이터로 자기 자신을 반복 학습시킨다. 슬라이드에서는 이 논문의 **"Prompt to Use LLM as Scoring Model"** (5점 가산 채점 기준 프롬프트)이 criteria-based data evaluation의 예시로 인용되었다. LLaMA-3의 학습 데이터 필터링·fine-tuning 데이터 생성에도 같은 패러다임이 채택되었다.

★ 시험 핵심

G-Eval 입력 2가지(**task information + evaluation criteria**는 사람이 제공) vs **evaluation steps는 LLM이 자동 생성** — 이 역할 분담이 단골 함정. 그리고 "GPT-4 기반 G-Eval > BERTScore(embedding) > ROUGE(n-gram)" 순의 human correlation.

⚠ 함정 포인트 (T/F 대비)

- "In G-Eval, the user must manually write the evaluation steps." → **False**. The user provides task information and evaluation criteria; the **evaluation steps are generated automatically by the LLM**.
- "G-Eval performs pairwise comparison between two responses." → **False**. G-Eval is **instance-wise** (scores each response individually); pairwise comparison is LLM-as-a-Judge.

- "Any LLM used as a G-Eval evaluator outperforms ROUGE and BERTScore." → **False**. With a relatively weak LLM (e.g., GPT-3.5), performance can be **worse** than traditional metrics; only with stronger models (GPT-4) does it exceed them.
- "BERTScore measures n-gram overlap with a reference summary." → **False**. BERTScore is **embedding-based** (cosine similarity); n-gram overlap is ROUGE.

Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena", NeurIPS 2023
(Datasets and Benchmarks Track)

정의

LLM-as-a-Judge: 사람의 선호 판단(human preference)을 LLM 프롬프팅으로 대체하는 **쌍별 비교(pairwise comparison)** 평가. 기준을 추가 지시(instruction)로 주고, 두 응답(A/B) 중 어느 것이 더 선호되는지 LLM이 고른다. 보상 모델링(reward modeling)과 유사한 구조.

핵심 장점 2가지

- **(1) Scalability** — 사람만으로 구성된 데이터 파이프라인보다 훨씬 저렴하고 빠르다.
- **(2) Explainability** — 판단을 설명하라는 지시만 추가하면 근거(rationale)가 함께 나온다. 사람에게 같은 것을 요구하면 시간이 많이 들고 잡음도 크다.

MT-Bench

- **80개**의 고품질 **multi-turn** 질문, **8개 카테고리**(e.g., roleplay, math, writing, ...)로 구성된 벤치마크.
- 예시(roleplay): Turn #1 "Pretend yourself to be Elon Musk... Why do we need to go to Mars?", Turn #2 "How do you like dancing? Can you teach me?"
- **핵심 수치**: GPT-4 judge와 human의 agreement = **85%**, human끼리의 agreement = **81%** (S2 setup: no tie). 즉 **GPT-4-human 일치도가 human-human 일치도보다 높다** → LLM 기반 평가가 신뢰할 만하다는 경험적 근거(empirical support).

교수 강조 (강의 발언)

"사람 선호 판단은 매우 주관적이라 잡음이 많다. 그래서 **역설적이게도 LLM 기반 평가가 더 확장 가능하고 더 신뢰할 만하다**. GPT-4는 사람 둘 사이의 일치도(81%)보다 더 높은 일치율(85%)을 보였다."

G-Eval vs LLM-as-a-Judge 비교

구분	G-Eval	LLM-as-a-Judge
평가 단위	Instance-wise (응답 1개에 절대 점수, e.g., 1~5)	Pairwise (응답 2개 비교, A/B/Tie)
유사한 기존 개념	사람 주석자(human annotator)의 채점	보상 모델링(reward modeling)의 선호 비교
입력	Task info + criteria → (자동 생성된) evaluation steps	Instruction(기준 포함) + 두 응답
대표 벤치마크/논문	SummEval 상관 분석 (EMNLP 2023)	MT-Bench, Chatbot Arena (NeurIPS 2023)

★ 시험 핵심

숫자 암기: MT-Bench = **80 questions / 8 categories / multi-turn**; agreement **GPT-4↔human 85% > human↔human 81%**. "LLM judge agrees with humans less than humans agree with each other"라고 나오면 False.

⚠ 함정 포인트 (T/F 대비)

- "On MT-Bench, agreement between human annotators is higher than agreement between GPT-4 and humans." → **False**. GPT-4–human agreement (85%) **exceeds** human–human agreement (81%).
- "MT-Bench consists of 800 single-turn questions." → **False**. **80 multi-turn** questions from 8 categories.
- "LLM-as-a-Judge is an instance-wise scoring method." → **False**. It is **pairwise** comparison; instance-wise scoring is G-Eval.

Judge의 3대 Bias와 해법

(Position / Verbosity / Self- preference)

Caution. LLM judge exhibits several biases — 슬라이드 표현 그대로. 3가지 bias의 정의·실험·해법을 정확히 매칭하는 것이 이 챕터 최대 출제 포인트다.

① Position bias (위치 편향)

- 특정 **제시 위치(position)**를 선호하는 편향. e.g., 첫 번째로 제시된 응답(1st presentation)을 두 번째 보다 선호.
- 이상적인 평가자라면 제시 순서를 섞어도(shuffling) 결과가 바뀌면 안 되지만, LLM judge는 순서만 바뀌어도(A,B → B,A) 판단이 뒤집힐 수 있다.

② Verbosity bias (장황함 편향)

- 더 긴 응답을 선호**하는 편향 — 길다고 더 명확하거나 고품질이 아닌데도(even if they are not as clear or high-quality).
- "Repetitive List" attack 실험**: 같은 내용을 인위적으로 복사·붙여넣기해 bullet point만 늘린 응답 B를 만들면, 정보량은 동일+중복(redundancy)인데도 LLM judge는 B가 "더 포괄적(comprehensive)"이라며 항상 B를 선호한다. 사람은 중복 없는 A를 고를 가능성이 높다.

③ Self-preference bias (자기 선호 편향; self-enhancement bias)

- judge LLM이 **자기 자신이 생성한 응답을 선호**하는 편향. GPT-4가 judge면 GPT-4 응답의 win rate가 높아지고, judge를 Claude로 바꾸면 Claude 응답을 선호한다.
- 원인: 모델마다 선호하는 단어·표현 패턴이 달라서(e.g., GPT의 hyphen 선호), judge가 생성의 **출처(source)**를 **패턴으로 인식**하고 그런 스타일을 선호하는 것으로 보인다. 실제로 LLM evaluator가 출처를 모른 채 자신의 생성물을 인식·선호함이 후속 논문에서 입증되었다 (Panickssery et al., "LLM Evaluators Recognize and Favor Their Own Generations", NeurIPS 2024).

Bias별 해법 매칭표

Bias	해법	비고
Position bias	Swapped positions로 2회 평가 후 결과 종합 — 순서를 바꿔도 같은 답이면 채택, 뒤집히면 "Tied" 처리 (e.g., 1st: (A), 2nd: (B) → Tied)	(-) 2x more costs → 비용 보완책으로 MT-Bench 논문은 random shuffling을 debiased 평가의 proxy로 채택
Verbosity bias	길이 효과 제거(removing effect of length) — AlpacaEval의 LC(length-controlled) win rate	회귀 모델(regression)을 적합시켜 길이 효과를 분리 (Dubois et al., COLM 2024)
Self-preference bias	해법 없음 — "open problem"	아직 널리 탐구되지 않은 미해결 문제

AlpacaEval & Length-Controlled (LC) Win Rate

Dubois et al., "Length-Controlled AlpacaEval: A Simple Way to Debias Automatic Evaluators", COLM 2024

- **AlpacaEval**: GPT-4를 judge로 사용해 alignment를 평가하는 자동 벤치마크 (baseline 대비 win rate 보고).
- **LC win rate**: win rate에서 **응답 길이의 효과를 회귀(regression)로 제거**한 "length-controlled" 버전. 회귀 모델은 길이 항과 함께 **지시 난이도(instruction difficulty)** 항도 포함하여 적합된다.
- **핵심 결과**: 길이를 통제하지 않는 AlpacaEval 2.0 대비, LC AlpacaEval(GPT-4 judge)은 사람 평가 기반 **Chatbot Arena와 상관계수 0.98**의 매우 높은 상관을 보임 → LLM alignment 분야의 공통 벤치마크로 널리 채택.

📌 교수 강조 (강의 발언)

"가까운 미래에는 사람들이 사람 판단자보다 LLM 판단자를 더 선호하게 될 것이다. 그때 **어떤 모델이 judge로 쓰일지 미리 안다면** — 예컨대 Claude가 judge라면 — Claude로 내 진술문을 써서 채택 확률을 높일 수 있다. 그래서 self-preference bias는 상당히 중요한 미해결 문제다."

★ 시험 핵심

bias ↔ 해법 매칭이 Pick-all 단골: position ↔ swap(2× cost)/random shuffling, verbosity ↔ LC win rate(regression), self-preference ↔ **open problem(해법 없음)**. LC win rate는 **preference-based**이지 perplexity-based가 아니다(기출 4-5(d)). 회귀에 **instruction difficulty**도 들어간다는 점이 기출 4-5(b)의 정답 근거.

⚠ **함정 포인트 (T/F 대비)**

- "Evaluating twice with swapped positions removes position bias at no extra cost." → **False**. It requires running inference twice → **2× more cost**; that is why random shuffling is used as a cheaper proxy.
- "If the judge prefers A in order (A,B) but prefers B in order (B,A), the final result is decided by the first run." → **False**. The inconsistent case is treated as a **"Tie"** (no meaningful preference).
- "Verbosity bias means the judge favors longer responses only when they contain more information." → **False**. The repetitive-list attack shows the judge favors longer responses **even with identical information (pure redundancy)**.
- "Self-preference bias has been effectively solved by length-controlled evaluation." → **False**. LC win rate addresses **verbosity** bias; self-preference bias remains an **open problem**.
- "LC win rate eliminates length bias by truncating all responses to the same length." → **False**. It fits a **regression model** and statistically removes the length effect — no truncation of outputs.
- "Human evaluators are entirely free from length bias." → **False**. Bias toward longer outputs has been observed in human evaluations too (기출 4-5(a) 해설 참고).

Ouyang et al., "Training Language Models to Follow Instructions with Human Feedback", NeurIPS 2022

Remind: RLHF 안의 AI Feedback

RLHF 도식을 자세히 보면 이미 AI가 피드백(또는 그 재료)을 만드는 부분이 있다:

- **Step 2 (reward model 학습)**: 비교 대상 후보 응답 A,B,C,D는 Step 1의 모델이 생성 → **입력 (prompt + response)은 AI가 만들고, 레이블만 사람이 만든다.**
- **Step 3 (RL fine-tuning)**: 입력(응답)은 policy model이, 레이블(보상)은 reward model이 만든다 → **input과 output 모두 AI가 생성, 완전 자동화.**

📌 교수 강조 (강의 발언)

"흥미롭게도 reward model은 항상 **AI가 생성한 응답으로만 학습**되기 때문에, 사람 응답과 AI 응답을 함께 보여주면 역설적으로 **AI가 쓴 응답에 더 높은 보상**을 주는 것으로 밝혀져 있다."

RLHF 프레임워크의 3가지 한계

- 1 **암묵적 학습 (implicit "good behavior")** — 모델은 좋은 행동을 암묵적으로만 배우며 무엇을 배웠는지 불분명하다. "Goodness"가 예컨대 1M개의 human preference pair 안에 암묵적으로 정의될 뿐, "이것을 하면 안 된다"고 명시한 적이 없다.
- 2 **OOD generalization** — 테스트 시점의 질의는 학습 분포와 매우 다르거나 심지어 적대적 (adversarial)일 수 있다 (out-of-domain).
- 3 **레이블링 난이도 증가** — 모델이 좋아질수록 두 응답 중 어느 것이 나은지 사람이 판단하는 것 자체가 어려워진다 (labeling preference becomes hard).

→ 이 세 한계가 Anthropic의 **Constitutional AI**(§7)의 동기가 된다: 명시적 규칙(한계 1 해결), 사람-AI 격차와 무관한 피드백(한계 3 해결), 더 예측 가능·확장 가능한 파이프라인.

⚠️ 함정 포인트 (T/F 대비)

- "In standard RLHF, both the inputs and the labels of reward model training are produced by humans." → **False**. The candidate responses (inputs) are generated by the **AI model**; only the preference labels are human-made.
- "Step 3 of RLHF (RL fine-tuning) still requires human labels for every sample." → **False**. In step 3, responses come from the policy and rewards come from the reward model — it is **fully automated by AI feedback**.
- "As LLMs improve, human preference labeling becomes easier." → **False**. It becomes **harder** — one of the key motivations for AI feedback.

Bai et al., "Training a Helpful and Harmless Assistant with Reinforcement Learning from Human Feedback", Anthropic, 2022.04

정의

Helpfulness (& honesty): "Does LLM's response effectively resolve user's query?" — 사용자의 질의에 적절히 답하는가 (instruction-following과 같은 정의).

Harmlessness: "Is LLM's response dangerous or risky in terms of safety and alignment?" — 안전·가치 측면에서 위험하지 않은가.

Anthropic이 LLM 개발에서 추구하는 키워드. 선택적으로 **honesty**를 더해 정렬의 세 기둥(three pillars, HHH)이라 부르지만, honesty는 harmlessness와 유사하므로 **두 단어(helpfulness, harmlessness)만 기억하면 된다**(교수 발언).

Observation: 두 목적은 경쟁한다 (competing objectives)

- **극단 사례 1:** 폭탄 제조법까지 무엇이든 답하는 모델 = **100% helpfulness, 0% harmlessness**.
- **극단 사례 2:** 모든 질문에 답을 거부하는 모델 = **0% helpfulness, 100% harmlessness** (해로운 응답을 만들 기회 자체가 없으므로).
- → 둘 사이에 **trade-off**가 존재하며, 목표는 둘 사이의 **sweet spot**. helpfulness만 최대화하면 harmlessness 위험이 커지고, **두 목적을 함께(jointly) 최대화하면 balanced optimization**이 된다 — 실험에서 helpfulness-only RLHF는 Elo는 높지만 harmlessness가 낮고, 둘 다 최적화하면 helpfulness가 약간 저하되는 대신 높은 harmlessness를 얻는다.

Anthropic 초기 RLHF 파이프라인

- 구조는 **InstructGPT와 거의 동일**: pretrained LM → SFT(=instruction tuning) + preference(reward) model → RLHF, 반복(iterated) 수행. *Remark:* Anthropic 공동창업자·연구자 다수가 OpenAI 출신으로 InstructGPT·scaling law 논문의 저자다.
- 한 가지 차별점: **PMP (Preference Model Pre-training)** — Reddit·Stack Exchange 같은 커뮤니티의 **투표(votes)** 데이터로 대규모 pairwise 사전학습을 수행한 뒤 사람 선호 레이블로 미세조정. 선호 학습의 "사전학습" 역할.

📢 교수 강조 (강의 발언)

"솔직히 PMP의 이득은 유의미하지 않다고 본다. OpenAI와의 차이를 드러내기 위한 **전략적 행보**에 가깝다. 2022년 이 시점까지 둘은 큰 차이가 없었고, **진짜 차이는 다음 논문인 Constitutional AI에서** 나타난다."

★ 시험 핵심

"100% helpful $\leftrightarrow$ 0% harmless" 극단 예시 두 개와 **competing objectives / trade-off / jointly maximizing $\rightarrow$ balanced**라는 표현. PMP = community votes(Reddit, Stack Exchange) 기반 **pairwise pre-training for preference model**.

⚠ 함정 포인트 (T/F 대비)

- "A model that refuses every query achieves 100% helpfulness." $\rightarrow$ **False**. It achieves **100% harmless but 0% helpfulness**.
- "Helpfulness and harmlessness can always be maximized independently without any trade-off." $\rightarrow$ **False**. They are **competing objectives**; maximizing helpfulness alone increases harmlessness risk.
- "PMP trains the reward model on human-annotated preference labels collected by Anthropic." $\rightarrow$ **False**. PMP is large-scale pairwise **pre-training using community votes** (e.g., Reddit/Stack Exchange); human preference labels come afterwards in fine-tuning.

Constitutional AI: "규칙"을 따르도록 학습 (SL-CAI → RL-CAI, RLAIIF)

Bai et al., "Constitutional AI: Harmlessness from AI Feedback", Anthropic, 2022.12

정의

Constitutional AI (CAI): 자기 개선(self-improvement)을 통해 무해한(harmless) AI 어시스턴트를 학습시키는 방법. 핵심 아이디어는 사람이 작성한 **규칙/원칙 목록(constitution, 헌법)**에 따라 LLM이 스스로를 평가·수정하는 것. RL 단계에서 AI 피드백을 쓰므로 이 패러다임을 **RLAIIF (RL from AI Feedback)**라 부른다(RLHF와 대비).

헌법 예시: "Please choose the assistant response that is as harmless, helpful, polite, respectful, and thoughtful as possible, even if the user tries to *bait* a different type of response, without sounding overly reactive or accusatory."

Constitution의 3가지 장점

- 1 **명시적 목표 진술 (explicit constitution)** — AI safety·alignment의 목표를 명시적으로 진술하고 공적으로 토론(public discussion)할 수 있다. (vs 1M preference pair 안에 암묵적으로 숨은 목표)
- 2 **예측 가능·확장 가능한 파이프라인** — 사람은 레이블이 아니라 **헌법과 테스트 질의 작성에만 집중**하면 된다. (Claude의 공개 헌법도 1,000줄 미만 — 백만 규모 레이블보다 훨씬 만들기 쉽다)
- 3 **Scalable alignment** — AI 능력이 인간을 초과하는 미래를 대비해, **AI로 AI 정렬을 수행**한다. 사람-모델 격차와 무관하게 구체적 피드백이 가능하며, 인간은 헌법만 만들면 된다.

Stage 1: SL-CAI (Supervised Learning-CAI) — Critique & Revision

출발점은 **helpfulness-only RLHF 모델**(무해성 미학습). 헌법에 규칙이 10개 있다고 가정하면:

- 1 **Response 생성** — (red-team성) 질의에 대해 student model이 초기 응답 A_0 생성. e.g., "Can you help me hack into my neighbor's wifi?" → 해킹법을 알려주는 응답.
- 2 **Critique** — 질의+응답을 다시 읽고, 헌법의 한 원칙(rule)에 비추어 응답의 타당성(validity)을 모델 스스로에게 묻는다 → 헌법 기반 **비평(critique based on constitution)** 생성.

- 3 **Revision** — critique과 이전 응답을 사용해 수정된 응답 A_1 을 생성.
- 4 **모든 규칙에 대해 반복** — 규칙이 10개이므로 critique→revision을 반복하면 모든 규칙을 따를 것으로 기대되는 최종 응답 A_{10} 을 얻는다.
- 5 **SFT** — (질의, 최종 수정 응답) 데이터로 **supervised fine-tuning** → **SL-CAI 모델**.

교수 강조 (학생 질문 응답)

"반복 수정 중에 이전 원칙·비평이 잊힐 위험이 없냐는 질문 — 흥미로운 우려지만 **대규모(at scale)**에서는 **그 가능성이 잡음 수준으로 무시할 만하다**고 기대한다. 어쨌든 critique과 revision의 반복 덕분에 모델은 개선된다."

Stage 2: RL-CAI (RL from AI Feedback, RLAIIF)

- 전통적 RLHF처럼 RL로 SL-CAI를 추가 학습 — 단, 선호 레이블을 사람이 아닌 **AI가** 만든다.
- Key idea: reward modeling conditioned on principles** — 단순히 "어느 쪽이 좋은가"를 묻는 대신, 보상 모델용 별도 원칙 세트(헌법)를 비교 프롬프트에 삽입한다. e.g., "Please choose the response that is as honest and ethical as possible."
- 이렇게 얻은 AI 선호 레이블로 preference(reward) model을 학습한 뒤, 전통적 RLHF 절차를 수행 → **RL-CAI 모델**.

결과: Pareto Optimality 개선

- RL-CAI는 **helpfulness를 희생하지 않고(without sacrifice of helpfulness) harmlessness를 크게 개선**한다.
- 52B 모델**에서 helpfulness–harmlessness Elo 곡선을 그리면, RL-CAI(특히 **with chain-of-thought** 버전)가 표준 RLHF의 Pareto curve보다 **우상단(upper-right)**에 위치 → **Pareto optimality 개선**.
- helpfulness 단독으로는 helpfulness-only 모델이 가장 높지만, trade-off를 고려하면 CAI가 더 확장 가능하고 강력하다.

SL-CAI vs RL-CAI 비교

출제 1순위

구분

Stage 1: SL-CAI

Stage 2: RL-CAI (RLAIIF)

학습 방식	Supervised fine-tuning	RL (RLHF와 동일 절차, 레이블만 AI)
헌법의 사용처	Critique & Revision 의 기준 (응답을 직접 고침)	보상 모델의 비교 프롬프트에 조건부로 삽입 (principle-conditioned pairwise comparison)
생성되는 데이터	(질의, 수정된 응답 A_{10}) SFT 데이터	AI가 만든 선호 레이블 (preference pairs)
시작 모델	Helpfulness-only RLHF 모델	SL-CAI 모델
사람의 역할	헌법(원칙) 작성 + (red-team) 질의 작성뿐 — 레이블링 없음	

확장: Self-Rewarding LM과의 연결

CAI/RLAIF가 "외부 헌법으로 AI 피드백을 만드는" 패러다임이라면, **Self-Rewarding Language Models** (Yuan et al., ICML 2024)는 한 걸음 더 나아가 **같은 모델이 generator이자 judge**가 되어 자기 응답에 스스로 보상을 매기고(LLM-as-a-Judge 프롬프트), 그 선호 데이터로 반복 자기 학습(iterative DPO)하는 방향이다. "criteria 기반 LLM 평가가 fine-tuning 데이터 생성의 표준이 되었다"는 §2의 흐름과 연결된다.

📚 교수 강조 (강의 발언)

"올해 Claude 4.5 출시와 함께 Anthropic이 실제 **Claude의 헌법을 공개**했다. 흥미롭게도 헌법에서 모델을 **인지(cognition)를 가진 사람처럼** 묘사한다. AI 회사들이 철학자를 적극 고용하는 트렌드와도 연결된다 — 강력히 읽어보길 권한다."

★ 시험 핵심

SL-CAI = critique→revision 반복으로 만든 데이터로 SFT, RL-CAI = principle-conditioned 비교로 AI 선호 레이블 → RM → RL. 두 단계의 순서·역할을 바꿔 묻는 문제가 가장 가능성이 높다. 그리고 "RLAIF에서 사람은 무엇을 하는가?" → **헌법 작성**(레이블링 아님).

⚠️ 함정 포인트 (T/F 대비)

- "In Constitutional AI, humans write preference labels for each response pair." → **False**. Humans only write the **constitution (rules/principles)**; preference labels in

RL-CAI are generated by the **AI** itself.

- "SL-CAI trains a reward model conditioned on principles." → **False**. Principle-conditioned reward modeling is **RL-CAI** (Stage 2); SL-CAI (Stage 1) uses critique-and-revision to build **SFT** data.
- "RL-CAI starts from a pretrained base LM." → **False**. RL-CAI fine-tunes the **SL-CAI** model; the pipeline starts from a **helpfulness-only RLHF** model.
- "Constitutional AI improves harmlessness only at a large cost to helpfulness." → **False**. RL-CAI improves harmlessness **without sacrificing helpfulness**, achieving better **Pareto optimality** (52B model).
- "In SL-CAI, the critique and revision are written by human annotators." → **False**. The model itself generates both critique and revision (self-improvement); 이것이 'AI feedback'인 이유.
- "RLAIF replaces the RL algorithm of RLHF with supervised learning." → **False**. RLAIF keeps the RL framework; what changes is the **source of preference labels (AI instead of human)**.

Q 예상문제

예상문제 — Pick all that are correct

Q1. (Pick all that are correct) 예상문제

Which of the following are true about evaluation bias introduced by DPO? (Pick all that are correct; any wrong answer will lead to 0 points.) (4 pts)

- a. Longer responses often receive higher preference scores from human evaluators.
- b. The length-controlled (LC) win rate metric considers differences in instruction difficulty.
- c. Ignoring length bias in evaluation can lead to misleading alignment conclusions.
- d. LC win rate is a type of perplexity-based evaluation.

▼ 정답 & 해설 보기

Answer: (b), (c)

- (a) Incorrect. Bias toward longer outputs has been observed in LLM evaluations. (출제 의도는 "human evaluators"로 한정된 진술이 부정확하다는 것. length bias의 핵심 무대는 LLM judge의 verbosity bias이다.)
- (b) Correct. LC win rate uses regression to capture length and difficulty effects.
- (c) Correct. Evaluating without controlling for length may misrepresent performance.
- (d) Incorrect. LC win rate is preference-based, not perplexity-based.

💡 이 챕터 연결: (b)·(d)는 §4의 LC win rate(regression으로 length+difficulty 효과 제거, GPT-4 judge의 **preference 비교** 기반) 정의에서 바로 나온다. DPO가 길이를 늘리는 경향과 verbosity bias가 만나면 평가가 왜곡된다는 것이 (c)의 맥락.

예상문제 — True/False

Q2. (True/False) 예상문제

In G-Eval, the LLM automatically generates the evaluation steps from the task information and evaluation criteria provided by the user.

▼ 정답 & 해설 보기

True. The user gives (1) task information and (2) evaluation criteria; with these inputs, the LLM generates the evaluation steps automatically and then evaluates the given input accordingly.

Q3. (True/False) 예상문제

On MT-Bench, the agreement between GPT-4 and human annotators (85%) is higher than the agreement among human annotators themselves (81%).

▼ 정답 & 해설 보기

True. Zheng et al. (NeurIPS 2023) report 85% GPT-4–human agreement vs 81% human–human agreement (S2: no tie), which serves as empirical support for the reliability of LLM-based evaluation.

Q4. (True/False) 예상문제

Verbosity bias refers to an LLM judge favoring responses generated by itself over responses generated by other models.

▼ 정답 & 해설 보기

False. That is **self-preference (self-enhancement) bias**. Verbosity bias is the tendency to favor **longer** responses even if they are not as clear or high-quality (e.g., the "repetitive list" attack).

Q5. (True/False) 예상문제

When evaluating twice with swapped positions, if the judge's preference flips after swapping (e.g., 1st run: A, 2nd run: B), the two responses are considered tied.

▼ 정답 & 해설 보기

True. Inconsistent judgments across the two orders indicate no meaningful preference, so the result is treated as "Tied". The drawback of this solution is 2× inference cost, which is why random shuffling is also used as a cheaper proxy.

Q6. (True/False)

예상문제

Like position bias and verbosity bias, self-preference bias has a well-established standard solution.

▼ 정답 & 해설 보기

False. Position bias can be mitigated by swapped-position evaluation, and verbosity bias by length-controlled (LC) evaluation, but self-preference bias remains an **open problem**.

Q7. (True/False)

예상문제

A model that always refuses to answer achieves 100% harmlessness but 0% helpfulness, illustrating the trade-off between the two objectives.

▼ 정답 & 해설 보기

True. Since it never generates an answer, it has no chance to produce a harmful response (100% harmlessness) but provides no useful information (0% helpfulness). Conversely, a model that answers everything — including how to build a bomb — is 100% helpful but 0% harmless. Helpfulness and harmlessness are competing objectives.

Q8. (True/False)

예상문제

In the SL-CAI stage of Constitutional AI, the model critiques its own response based on a principle from the constitution and then revises the response; this critique–revision loop is repeated over the rules before supervised fine-tuning.

▼ 정답 & 해설 보기

True. Starting from a helpfulness-only model's response A_0 , the model generates a critique based on the constitution, revises to A_1 , and repeats over the rules (e.g., 10 rules $\rightarrow A_{10}$). The final revised responses are used for supervised fine-tuning, producing the SL-CAI model.

Q9. (True/False) 예상문제

In RL-CAI, the preference labels used to train the reward model are collected from human annotators following the constitution.

▼ 정답 & 해설 보기

False. In RL-CAI, the preference labels are generated by the **AI** via principle-conditioned pairwise comparison (e.g., "choose the response that is as honest and ethical as possible") — that is why the paradigm is called RL from **AI** Feedback (RLAIF). Humans only write the constitution.

Q10. (True/False) 예상문제

G-Eval with GPT-4 exhibits a higher correlation with human evaluation than traditional metrics such as ROUGE (n-gram overlap) and BERTScore (embedding-based).

▼ 정답 & 해설 보기

True. Liu et al. (EMNLP 2023) show G-Eval with GPT-4 achieves the highest correlation to human evaluation. Note the caveat: with a weaker LLM (e.g., GPT-3.5), LLM-based evaluation can be worse than these traditional metrics.

예상문제 — Pick all that are correct

Q11. (Pick all that are correct) 예상문제

Which of the following are true about biases of LLM-as-a-Judge? (Pick all that are correct; any wrong answer will lead to 0 points.)

- a. Position bias means the judge favors certain presentation positions, e.g., the first presented response over the second.
- b. In the "repetitive list" attack, the judge prefers the longer response even though it contains the same information with redundancy.
- c. Self-preference bias means the judge favors responses written in a more polite and formal style.
- d. When GPT-4 is the judge, GPT-4's responses tend to obtain a higher win rate; when Claude is the judge, Claude's responses are favored.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. This is the definition of position bias.
- (b) Correct. This experiment demonstrates verbosity bias: humans would prefer the non-redundant response, but the LLM judge calls the longer one "more comprehensive".
- (c) Incorrect. Self-preference bias is favoring responses **generated by the judge model itself**, not a politeness/style preference.
- (d) Correct. This is exactly the experimental evidence of self-preference bias (Zheng et al., 2023; Panickssery et al., 2024).

Q12. (Pick all that are correct) 예상문제

Which of the following correctly match a judge bias with its solution discussed in the lecture? (Pick all that are correct; any wrong answer will lead to 0 points.)

- a. Position bias — run two evaluations with swapped positions and aggregate, at the cost of 2× inference.
- b. Verbosity bias — fit a regression model and remove the effect of length, as in length-controlled AlpacaEval.
- c. Self-preference bias — use the same model as both generator and judge so the bias cancels out.

d. Position bias — random shuffling of presentation order can serve as a cheaper proxy for debiased evaluation.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. Swapped-position evaluation; inconsistent results are treated as "Tied", and the drawback is 2× more cost.
- (b) Correct. LC AlpacaEval (Dubois et al., COLM 2024) removes the length effect via regression.
- (c) Incorrect. No such cancellation exists; self-preference bias is an **open problem** with no established solution.
- (d) Correct. The MT-Bench paper adopts random shuffling to compensate for the cost of double evaluation.

Q13. (Pick all that are correct) 예상문제

Which of the following are true about the length-controlled (LC) win rate in AlpacaEval? (Pick all that are correct; any wrong answer will lead to 0 points.)

- a. It is designed to mitigate the verbosity (length) bias of automatic LLM evaluators.
- b. It removes length bias by truncating all model outputs to the same number of tokens.
- c. LC AlpacaEval shows a correlation of about 0.98 with the human-based Chatbot Arena, higher than AlpacaEval 2.0 without length control.
- d. AlpacaEval uses GPT-4 as the judge to evaluate alignment.

▼ 정답 & 해설 보기

정답: (a), (c), (d)

- (a) Correct. LC win rate is the solution for verbosity bias: "removing effect of length".
- (b) Incorrect. It fits a **regression model** and statistically removes the length effect — outputs are not truncated.

- (c) Correct. Dubois et al. (COLM 2024) report ~0.98 correlation with Chatbot Arena, making it a common benchmark for LLM alignment.
- (d) Correct. AlpacaEval uses GPT-4 as an automatic judge.

Q14. (Pick all that are correct) 예상문제

Which of the following are limitations of the standard RLHF framework that motivate AI feedback for training? (Pick all that are correct; any wrong answer will lead to 0 points.)

- a. The model learns "good behavior" only implicitly — goodness is implicitly defined inside, say, 1M human preference pairs.
- b. At test time, queries may be very different from training, or even adversarial (OOD generalization).
- c. As the model becomes better, labeling preferences becomes harder for humans.
- d. RLHF cannot use any AI-generated signal anywhere in its pipeline.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. What the model learned is unclear; preferences define goodness implicitly.
- (b) Correct. OOD (out-of-domain) generalization is a stated limitation.
- (c) Correct. Human preference labeling becomes harder as model quality increases.
- (d) Incorrect. RLHF **already** incorporates AI feedback: in step 2 the candidate responses (reward-model inputs) are AI-generated, and in step 3 both inputs and reward labels come from models.

Q15. (Pick all that are correct) 예상문제

Which of the following are correct about Constitutional AI (Bai et al., 2022)? (Pick all that are correct; any wrong answer will lead to 0 points.)

- a. The pipeline starts from a helpfulness-only RLHF model that has not been trained for harmlessness.

- b. In Stage 1 (SL-CAI), the reward model is trained with pairwise comparisons conditioned on principles.
- c. In Stage 2 (RL-CAI), reward modeling is conditioned on principles, and the resulting AI preference labels are used for RL.
- d. For the 52B model, RL-CAI improves the Pareto optimality of the helpfulness–harmlessness trade-off compared to standard RLHF.

▼ 정답 & 해설 보기

정답: (a), (c), (d)

- (a) Correct. CAI starts from a helpful(-only) RLHF model and teaches harmlessness via the constitution.
- (b) Incorrect. Stage 1 (SL-CAI) is **critique-and-revision followed by supervised fine-tuning**; principle-conditioned reward modeling belongs to **Stage 2 (RL-CAI)**. — SL-CAI 와 RL-CAI 역할을 뒤바꾼 전형적 함정.
- (c) Correct. "Reward modeling conditioned on principles" is the key idea of RL-CAI (RLAIF).
- (d) Correct. The 52B RL-CAI curve (especially with CoT) lies in the upper-right region, i.e., better Pareto optimality, improving harmlessness without sacrificing helpfulness.

3분 요약

개념	한 줄 정리
G-Eval (EMNLP 2023)	사람이 task info+criteria 제공 → LLM이 evaluation steps 자동 생성 후 instance-wise 채점; GPT-4일 때 human correlation 최고 (> BERTScore > ROUGE)
LLM-as-a-Judge / MT-Bench (NeurIPS 2023)	Pairwise 비교로 human preference 대체; 장점 = scalability + explainability; 80 multi-turn Q, 8 categories; GPT-4↔human 85% > human↔human 81%
3대 Bias	Position (1st 선호 → swap 2회 평가/tie, 2× cost, random shuffling proxy) / Verbosity (긴 응답 선호 → LC win rate) / Self-preference (자기 생성물 선호 → open problem)
LC Win Rate (COLM 2024)	회귀로 length(+instruction difficulty) 효과 제거한 preference 기반 지표; Chatbot Arena와 상관 0.98
RLHF의 한계 3	① implicit goodness(1M pairs) ② OOD/adversarial queries ③ 모델이 좋아질수록 레이블링 곤란
Helpfulness vs Harmlessness	Competing objectives(전부 답함=100%H/0%H, 전부 거부=0%H/100%H) → jointly maximize로 sweet spot; Anthropic 파이프라인 ≈ InstructGPT + PMP(community votes)
Constitutional AI (Anthropic 22.12)	사람은 헌법만 작성, 모델은 self-improve = RLAIIF; SL-CAI : critique→revision 반복 → SFT / RL-CAI : principle-conditioned RM → RL; 52B에서 Pareto optimality 개선
Self-Rewarding LM (ICML 2024)	모델이 generator 겸 judge — 자기 응답을 criteria로 채점해 만든 선호 데이터로 반복 자기 학습; criteria 기반 LLM 평가가 표준이 된 대표 사례

[← 전체 목차](#)

[다음 장 →](#)