

CAS4133 LLM · 기말 대비 · Chapter 9

Chapter 9. Retrieval-Augmented Generation (RAG)

지식 컷오프·환각을 외부 검색으로 보완 — 검색기(PageRank/BM25/DPR/Contriever)부터 REPLUG·IRCoT·RetRobust·Self-RAG·Search-R1까지, 추론 기반 → 학습 기반(SFT → RL)으로 진화하는 RAG의 전체 흐름

 강의일: 5/6 · 5/13 · 5/18 (4개 강의에 걸친 최대 분량 챕터) 예상 비중: 매우 높음 (기말 범위 첫 대형 챕터) 분량: 본문 8섹션 + 문제 17

목차

1. RAG 동기와 기본 파이프라인 (Knowledge Cutoff, Hallucination, Retrieve-and-Read)
2. 검색 방법 ①: 웹 검색(PageRank) & 텍스트 기반(BM25)
3. 검색 방법 ②: 밀집 검색 (DPR, Contriever) + 3-way 비교
4. REPLUG — 블랙박스 LM + 학습 가능한 검색기 (Ensemble, LSR)
5. IRCoT — CoT와 검색의 교차 반복 (Multi-hop QA, EM/F1/Recall@K)
6. RetRobust — 노이즈-강건 RAG (NLI 필터링 & 소규모 학습)
7. SuRe — 답 후보별 조건부 검색 요약 (교수 논문, ICLR 2024)
8. Self-RAG — Reflection 토큰으로 적응적 RAG 학습 (SFT)
9. Search-R1 — RL로 검색을 배우는 LLM (+ 3대 방법 총비교)
10. 예상문제 (T/F 10 + Pick-all 7)

11. 🎯 작년 기말 출제: RAG (Problem 4, Problem 1)

1 RAG 동기와 기본 파이프라인 (Motivation & Pipeline)

이번 챕터부터 강의는 LLM의 **기초(foundation)**(학습·해석)에서 **응용(application)**으로 전환된다. 첫 번째 킬러 애플리케이션이 바로 **검색 증강 생성(Retrieval-Augmented Generation, RAG)**이다.

1.1 LLM의 근본 한계: 정적 데이터셋

RLHF로 정렬(alignment)을 마쳐도 LLM은 완벽하지 않다. 핵심 원인은 LLM이 **고정된(fixed/static) 학습 데이터셋**으로 학습된다는 점이다.

- **환각(Hallucination)** non-factual but seemingly plausible generation — 사실이 아니지만 그럴듯해 보이는 생성. 학습 시점과 추론 시점(inference time) 사이의 불일치(mismatch)가 주요 원인 중 하나.
- **최신 지식 반영의 어려움** difficulty to incorporate up-to-date knowledge — 파라미터 속 지식은 데이터 수집 시점까지로 제한된다.

정의

지식 컷오프(Knowledge cutoff): 사전 학습 데이터가 포함하는 마지막 시점. 모델 공개 시 함께 공개된다. 예) **GPT-4o (& mini): 2023-10, LLaMA3: 2023-12**. 컷오프 이후의 사실을 물으면 높은 확률로 환각을 생성한다.

교수 강조 (강의 발언)

"2024년에 데이터를 수집해 2025년에 배포한 모델에게 2025년의 사실을 물으면 옳은 답을 줄 수 없다. 이 **학습 시점-추론 시점 mismatch**가 환각의 주요 원인이다. 예전 GPT-3가 '대통령이 누구냐'는 질문에 (정권 교체 후에도) 학습 데이터 시점의 대통령을 답한 것이 전형적인 예다."

1.2 RAG가 아닌 대안들이 실패하는 이유

대안	아이디어	한계
답변 거부 (Abstaining)	모르는 질문은 "답할 수 없다"고 거부	사용자 관점에서 효용(utility) 저하 → 도움이 안 됨

지속 학습 (Continued fine-tuning)	새 데이터로 주기적 재학습	새 지식 fine-tuning은 기존 능력 손상 위험 (Gekhman et al., arXiv:24.05 — known data 성능이 몇 epoch 후 하락하는 sweet spot 존재) + 추가 계산 비용 → 기업들이 큰 릴리스를 비동기적으로만 내는 이유
RAG	외부 지식을 입력으로 증강	현재 표준(standard) 접근 

1.3 Retrieve-and-Read 파이프라인

정의

Retrieve-and-read: 오픈 도메인 질의응답(Open-Domain QA, ODQA)의 고전적 시스템. ① **검색기(Retriever)**가 외부 지식 소스(external knowledge source)에서 질의 관련 정보를 수집 → ② **리더/생성기(Reader/Generator)**가 그 정보를 바탕으로 답변. LLM 시대에는 **생성기 부분만 LLM으로 대체**된 것이 곧 RAG다 (검색기 부분은 동일).

교수 강조 (강의 발언)

"오픈북 시험과 똑같다. 외부 소스에서 관련된 부분을 먼저 찾고(retrieve), 그 다음 질문에 답한다(read). 이 시스템은 LLM 이전부터 있었고, generator만 LLM으로 바뀐 것이 오늘날의 RAG다."

1.4 RAG의 두 가지 활용 방식

- 1 **추론 기반 (Inference-based)** — 검색된 정보를 추가 입력으로 **덧붙이기 (appending/prepending)**만 함. 사전 학습된 검색기 + 사전 학습된 LLM을 학습 없이 결합(프롬프트 최적화 정도만 가능). 가장 쉽고 상업적으로 흔한 방식 → **REPLUG, IRCOT, SuRe**가 이 계열.
- 2 **학습 기반 (Training-based)** — 검색 정보를 활용하도록 LLM을 **학습**. 추론 기반은 LLM이 검색 문서 활용을 학습한 적이 없어 최적이지 아닐 수 있으므로 등장한 최근 패러다임 → **RetRobust(일부), Self-RAG(SFT), Search-R1(RL)**이 이 계열.

시험 핵심

① Knowledge cutoff 구체값(GPT-4o 2023-10, LLaMA3 2023-12)과 "fine-tuning으로 새 지식 주입은 한계가 있다"는 논거. ② RAG = retrieve-and-read에서 **generator만 LLM으로 교체**.

③ inference-based vs training-based의 구분 — 이 챕터 전체가 이 축으로 전개된다.

⚠ 함정 포인트 (T/F 대비)

- "Fine-tuning on new knowledge is an effective and reliable way to keep LLMs up-to-date." → **False**. Fitting on new knowledge can decrease overall accuracy (known-data performance drops after several epochs); that is exactly why RAG is preferred.
- "RAG requires retraining the LLM to incorporate retrieved documents." → **False**. Inference-based RAG simply appends retrieved information to the input without any training (training-based RAG also exists, but it is not required).
- "Hallucination means the model refuses to answer." → **False**. Hallucination is a *non-factual but seemingly plausible* generation, not a refusal.

RAG의 첫 구성요소인 **검색기(retriever)**를 만드는 세 방향: ① 웹 검색(web search, PageRank), ② 텍스트 기반(text-based = **sparse retriever**, BM25), ③ 임베딩 기반(embedding-based = **dense retriever**, DPR/Contriever).

2.1 PageRank (Page, Technical Report 1997)

정의

PageRank: 웹 페이지의 **중요도(importance)**는 그 페이지로 링크된 이웃들의 중요도의 평균이라는 철학으로 페이지를 랭킹. 구글 검색 알고리즘의 토대. 수학적으로 $PR(A)$ 는 **많은 클릭 후 페이지 A에 도달할 확률**이다.

PageRank 점수

$$PR(A) = \frac{1-d}{N} + d \sum_{B_i \in \text{In}(A)} \frac{PR(B_i)}{L(B_i)}$$

d : **감쇠 인자(damping factor)** — $1-d$ 는 링크를 따르지 않고 **무작위 페이지로 점프할 확률**(좌측 항 = 직접 방문 시나리오). $L(B_i)$: 페이지 B_i 의 아웃링크 수 — 한 페이지의 중요도는 아웃링크들에게 **균등 분배**되므로 L 로 나눈다(우측 항 = 링크 타고 도달 시나리오, 일종의 message-passing).

- **계산법(power iteration)**: 각 노드를 $1/N$ (균등 분포)이나 무작위 값으로 초기화 후 위 식을 반복 적용하면 **유일한 해(unique solution)**로 수렴함이 증명되어 있다 — 이 수렴 값이 중요도 점수.
- **한계**: 링크 **연결성(connectivity)** 정보만 쓰고 **본문의 의미(semantic)** 정보를 전혀 활용하지 않음 → 텍스트 기반/임베딩 기반 검색이 등장한 동기.

2.2 BM25 (Robertson & Zaragoza, Foundations and Trends in IR 2009)

정의

BM25: 원시 텍스트 수준(raw text-level) 검색 — 질의와의 **단어 겹침(word overlap)**이 클수록 검색 점수가 높다. 학습이 전혀 없는 비지도(unsupervised) 방법이며, 이산적 단어 기반이라 **희소 검**

색기(sparse retriever)로 분류된다.

BM25 점수 (질의 Q 의 키워드 q_i , 문서 D)

$$\text{score}(D, Q) = \sum_i \text{IDF}(q_i) \cdot \frac{f(q_i, D) (k_1 + 1)}{f(q_i, D) + k_1 \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}, \quad \text{IDF}(q_i) = \ln \frac{N}{n(q_i)}$$

N : 전체 문서 수, $n(q_i)$: 키워드 q_i 를 포함하는 문서 수, $f(q_i, D)$: 문서 D 내 q_i 의 **단어빈도(term frequency)**, $|D|/\text{avgdl}$: 문서 길이/평균 문서 길이, k_1, b : **하이퍼파라미터**(보통 사전 설정).

- **IDF(역문서빈도, inverse document frequency)**: "the", "all"처럼 **말뭉치 전체에서 흔한 단어를 보장** — 대상 문서와 무관하게 전체 말뭉치의 빈도만 본다. 키워드가 corpus 전반에 흔할수록 값 ↓.
- **TF 항**: 대상 문서 안에서의 빈도. **결합 효과**: 특정 키워드가 **문서 D 에서만 자주 등장** → 높은 점수 / corpus 전체에서도 흔함 → IDF가 깎음.

📚 교수 강조 (강의 발언)

"BM25의 본질적 한계: 단어의 의미는 **맥락(context)**에 따라 변한다. 'apple'이 'company'와 함께 오면 회사, 'breakfast'와 오면 과일이다. 단어 겹침 방식은 이런 **맥락 의존성을 유사도 점수에 포착할 수 없다** → 신경망 기반 임베딩 검색이 등장한 이유."

★ 시험 핵심

① PageRank: damping factor의 의미($1-d$ = random jump 확률), power iteration의 **유일해 수렴**, "연결성만 쓰고 의미는 안 쓴다". ② BM25: IDF는 **corpus 전체** 기준 / TF는 **대상 문서** 기준, k_1, b 는 하이퍼파라미터, sparse retriever라는 명칭.

⚠ 함정 포인트 (T/F 대비)

- "In PageRank, the damping factor d is the probability of jumping to a random page." → **False**. $1 - d$ is the random-jump probability; d weights the neighbor-based (link-following) term.
- "BM25 requires training on labeled query-document pairs." → **False**. BM25 is an unsupervised, training-free method based on word overlap counting (k_1, b are preset hyperparameters, not learned).

- "The IDF term in BM25 measures how frequently a keyword appears in the target document." → **False**. IDF only considers frequency over *all documents in the corpus*; within-document frequency is the term-frequency $f(q_i, D)$ part.
- "BM25 can capture that the meaning of a word changes depending on context." → **False**. That is precisely its limitation, motivating dense (embedding-based) retrieval.

3.1 DPR — Dense Passage Retrieval (Karpukhin et al., EMNLP 2020)

정의

DPR: 두 개의 문장 인코더(예: BERT) — 질의용 인코더 E_Q 와 구절(passage)용 인코더 E_P — 를 사용해 질의·구절을 벡터 공간으로 매핑하고, 유사도를 **특징 벡터의 내적(dot-product)**으로 계산하는 밀집 검색기. "관련이면 유사도 ↑, 무관이면 유사도 ↓"라는 성질을 **대조 손실(contrastive loss)**로 직접 부과한다.

DPR 유사도 & 대조 손실

$$\text{sim}(q, p) = E_Q(q)^\top E_P(p)$$

$$\mathcal{L}(q, p^+, p_1^-, \dots, p_n^-) = -\log \frac{e^{\text{sim}(q, p^+)}}{e^{\text{sim}(q, p^+)} + \sum_{j=1}^n e^{\text{sim}(q, p_j^-)}}$$

최소화의 의미: 분자 최대화 = 질의-**긍정 구절** p^+ 유사도 ↑, 분모 최소화 = 질의-**부정 구절** p^- 유사도 ↓. 두 인코더를 **jointly** 학습.

- **긍정 p^+** : 인간이 레이블링한 데이터(labeled data).
- **부정 p^-** : 난이도를 위한 labeled negatives + **in-batch negatives**(같은 배치 내 다른 질의의 구절들을 부정으로 재활용).
- **한계**: 각 질의에 대해 긍정/부정 구절을 **수작업 수집해야 함** → 비용이 큼.

3.2 Contriever (Izacard et al., TMLR 2022)

정의

Contriever: 자기지도(self-supervised) 대조 학습 기반 밀집 검색기. 인간 레이블 긍정 쌍을 인위적으로 생성한 쌍으로 대체 — 같은 (위키피디아) 문서 내의 두 **조각(crop)**을 긍정 쌍 k^+ 으로, 다른 문서의 조각을 부정 k_i^- 로 간주. 학습 목적함수(대조 손실)는 DPR과 동일하고, **데이터 구성 방법만** 다르다.

🎤 교수 강조 (강의 발언)

"LLM 사전학습에서 본 것처럼, 자가지도 학습은 인적 비용 없이 **확장 가능(scalable)**하다. 지도 방식보다 노이즈는 많지만 규모로 보완한다. 참고로 2026년 현재 최신은 **LLM이 합성 문서를 생성하는 LLM-based retriever** 쪽이다 (슬라이드엔 없음)."

3.3 어떤 검색기가 최고인가? — 정답 없음

SuRe (Kim et al., ICLR 2024)의 비교 실험이 보여주듯 **"최선의 검색 방법"에 대한 단일 정답은 없다**. 학습 기반(DPR/Contriever)은 **테스트 분포가 학습 분포와 가까울 때** 잘 작동한다.

- DPR은 NQ·WebQ로 학습 → 해당 데이터셋에선 BM25를 크게 능가하지만, **분포 밖(out-of-distribution) 데이터셋에선 오히려 BM25가 DPR을 능가**.
- Contriever는 비지도지만 분포 변화(distribution shift)에 **더 강건(robust)** → 전반적으로 가장 무난.
- 실무 조언: 회사 전용 시스템(질의 분포를 앎) → 자체 데이터로 학습한 검색기 / 전 세계 사용자 대상 → BM25 같은 일반적·저렴한 방법.

3.4 비교표: BM25 vs DPR vs Contriever

구분	BM25	DPR	Contriever
분류	Sparse retriever (텍스트 기반)	Dense retriever (임베딩 기반)	Dense retriever (임베딩 기반)
유사도	단어 겹침 + IDF/TF 계산	내적 $E_Q(q)^T E_P(p)$	내적 (대조 학습된 인코더)
학습	학습 없음 (unsupervised)	지도 대조 학습 (labeled p^+/p^- + in-batch negatives)	자가지도 대조 학습 (같은 문서 crop = 긍정)
레이블 필요	불필요	필요 (수작업, 고비용)	불필요 (자동 구성)
맥락의 미 포착	불가	가능	가능

분포 변
화 강건
성

강함 (학습 無)

약함 (in-dist.에서만 최강)

비교적 강함 (일반화 우수)

★ 시험 핵심

① DPR의 두 인코더 + dot-product + contrastive loss + **in-batch negatives**. ②
Contriever와 DPR의 차이는 **오직 데이터 구성** (same-document crop = positive)이며 손실은 동
일. ③ "best retriever는 없다 — 학습 기반은 test distribution이 성패를 가른다"는 결론.

⚠ 함정 포인트 (T/F 대비)

- "DPR uses a single shared encoder for both queries and passages." → **False**. DPR uses *two* sentence encoders (one for queries, one for passages), trained jointly.
- "Contriever modifies the contrastive loss function of DPR to remove the need for labels." → **False**. The objective is the same contrastive loss; only the *data construction* changes (positives are crops from the same document, not human labels).
- "Dense retrievers like DPR always outperform BM25." → **False**. On out-of-distribution datasets, BM25 can significantly outperform DPR; there is no single best retrieval method.
- "In-batch negatives in DPR refer to passages retrieved from the bottom of the ranking." → **False**. They are passages paired with *other queries* in the same mini-batch, reused as negatives (bottom-K negatives는 RetRobust의 데이터 구성 이야기 — 혼동 주의).

REPLUG — 블랙박스 LM의 (Retrieve and Plug, Shi et al., NAACL 2023)

검색 증강

4.1 설정과 핵심 아이디어

정의

REPLUG: 대상 LM(reader)이 **블랙박스(black-box)** — 파라미터에 접근·업데이트 불가 — 라고 가정하고, 검색 문서를 입력 앞에 **단순 prepend**하는 RAG. 검색기는 기존 방법(예: Contriever) 사용. 두 가지 기여: ① **입력 재구성(input reformulation) + 출력 앙상블**로 컨텍스트 윈도우 한계 극복, ② 블랙박스 LM에 맞춰 **검색기를 fine-tuning**하는 LSR.

4.2 아이디어 ①: 입력 재구성과 앙상블 (Inference with Input Reformulation)

- **문제**: 컨텍스트 윈도우(context window) 제한 → 검색 문서를 전부 이어붙이면(concatenation) 한계 초과 시 성능 급락. 무한 길이 RAG는 불가능.
- **해법 (divide-and-conquer)**: 모든 문서를 한꺼번에 prepend하지 않고, **각 문서를 따로 (separately) prepend** → 독립적으로 예측 → 출력 확률 공간에서 앙상블.

REPLUG 출력 앙상블 (입력 x , top-K 문서 $\mathcal{D}'$, 다음 토큰 y)

$$p(y \mid x, \mathcal{D}') = \sum_{d \in \mathcal{D}'} p(y \mid d \circ x) \cdot \lambda(d, x), \quad \lambda(d, x) = \frac{e^{s(d, x)}}{\sum_{d' \in \mathcal{D}'} e^{s(d', x)}}$$

$d \circ x$: 문서 d 와 입력 x 의 **연결(concatenation)**. $\lambda(d, x)$: 검색기의 유사도 점수 $s(d, x)$ 에 **softmax**를 취한 가중치(합=1) — 더 관련성 높은 문서의 출력 확률에 더 큰 계수를 주는 **가중 선형 결합(weighted linear combination)**.

교수 강조 (강의 발언)

"추론 비용 증가를 걱정할 수 있지만, Transformer의 **이차적(quadratic)** 비용 때문에 K번의 짧은 추론은 한 번의 긴 추론과 비용이 거의 같거나 **오히려 더 싸다** (길이 3L 한 번 = $9L^2$, 길이 L 세 번 = $3L^2$). 즉 계산 비용을 늘리지 않으면서 컨텍스트 한계를 피한다."

4.3 아이디어 ②: LSR — LM-Supervised Retrieval

- **문제:** LM이 블랙박스라 **학습 가능한(trainable) 모듈이 없음** → 성능 제한.
- **해법:** 학습 가능한 유일한 부분인 **검색기(dense retriever)**를 **LM의 출력 확률에 정렬(align)되도록 업데이트 = LM-Supervised signal for fine-tuning Retriever (LSR)**.
- **직관:** 검색기와 LLM은 따로 사전학습되어 관점이 다르다 — 검색기는 D2가 최고라 해도, LLM의 답 확률 기준으로 D3가 가장 유용할 수 있다(**mismatch**). 이 불일치를 검색기 업데이트로 교정.

1 **검색 가능도(retrieval likelihood)** — K개 문서에 대한 K-way 범주형 분포:

$$P_R(d \mid x) = \frac{e^{s(d, x)/\gamma}}{\sum_{d' \in \mathcal{D}'} e^{s(d', x)/\gamma}}$$

2 **LM 가능도** — 정답 출력 y 에 대해 각 문서가 얼마나 도움이 되는지의 K-way 분포:

$$Q_{LM}(d \mid x, y) = \frac{e^{P_{LM}(y|d, x)/\beta}}{\sum_{d' \in \mathcal{D}'} e^{P_{LM}(y|d', x)/\beta}}$$

3 **KL 발산 최소화**로 검색기 업데이트 (두 분포의 일관성 부과):

$$\mathcal{L} = \frac{1}{|\mathcal{B}|} \sum_{x \in \mathcal{B}} KL(P_R(d \mid x) \parallel Q_{LM}(d \mid x, y))$$

→ 학습 후엔 "검색 점수가 높다 = 정답 생성 가능성이 높다"가 성립. **LM은 동결(frozen)**, 검색기만 업데이트.

4.4 실험 결과

- **언어 모델링 (Pile, 지표 BPB):** LM 능력과 무관하게 REPLUG가 성능 개선(약 5%), **LSR로 검색기까지 fine-tuning**하면 개선 폭이 유의미하게 더 커짐(+2~3%).
- **MMLU & QA (NQ, TriviaQA):** 두 과제 모두에서 REPLUG가 대상 LM을 개선(약 3%), LSR이 소폭 추가 개선.

 **교수 강조 (강의 발언) — gray-box 주의**

"핵심 가정은 블랙박스 모델의 **출력 확률에 접근할 수 있다**는 것이다. 요즘 기준으로는 이를 **gray-box**라 부르는 게 더 정확하다 — 진짜 black-box는 파라미터도 확률도 못 보는 경우(예: Anthropic API). 최신 SOTA 모델은 완전한 블랙박스라 **이 접근이 요즘은 적용 불가능할 수도 있다**."

★ 시험 핵심

① 앙상블 수식: 문서별 독립 추론 → 검색 점수 softmax 가중합, quadratic 비용 논리. ② LSR: **retrieval likelihood**와 **LM likelihood** 간 **KL**을 최소화하며 **"검색기만" 업데이트** (LM은 frozen). ③ "출력 확률 접근 가정 = 사실상 gray-box"라는 교수의 비판적 코멘트.

⚠ 함정 포인트 (T/F 대비)

- "REPLUG fine-tunes the black-box LM so that it can better use retrieved documents." → **False**. The LM is frozen (black-box); only the *retriever* is fine-tuned, using the LM's output probabilities as supervision (LSR).
- "REPLUG's ensembling significantly increases inference cost compared to concatenating all documents." → **False**. Due to the quadratic cost of Transformers, prepending each document separately costs roughly the same or even less than one long concatenated input.
- "In LSR, the retriever is updated to maximize the KL divergence between retrieval likelihood and LM likelihood." → **False**. It *minimizes* the KL divergence (consistency between the two distributions).
- "REPLUG ensembles outputs with uniform weights over the K retrieved documents." → **False**. Weights are softmax-normalized retriever similarity scores $\lambda(d, x)$ — more relevant documents get higher coefficients.
- "REPLUG can be applied to any commercial LLM API today." → **False** (함정). It assumes access to output probabilities, which recent fully black-box APIs do not provide (professor: this is really a gray-box setting).

IRCoT — CoT와 (Interleaved Retrieval guided by Chain-of-Thought, Trivedi et al., ACL 2023) 검색의 교차 반복

5.1 동기: 반복 검색 (Iterative Retrieval)

기존 RAG는 **1회 검색 → 1회 답변**의 정적(static) 구조. 그러나 (Retrieval → Generating answer) × K처럼 **반복 검색이 효과적**임이 알려졌다 (Shao et al., arXiv:23.05) — 반복할수록 **질의 관련 컨텍스트가 누적(accumulated)**되기 때문. 증거를 모으면 상태가 갱신되고, 갱신된 상태로 다시 검색하는 동적(dynamic) 과정이 더 현실적이다.

5.2 IRCoT의 두 가지 핵심 아이디어

정의

IRCoT: ① **CoT 한 스텝 확장**과 ② **새 검색 추가**를 교차(interleave) 반복하는 방법. 추론 한 스텝을 생성한 뒤 새 지식을 장착하는 것이 자연스럽다는 직관. CoT(답변 전 step-by-step reasoning, Wei et al., NeurIPS 2022)를 RAG에 결합.

- 1 Retrieval-guided reasoning** — 입력 = (1) few-shot examples + (2) 검색된 구절들 + (3) 질의 + (4) 지금까지의 CoT. 매 iteration마다 **CoT를 정확히 한 스텝만 생성**(더 생성되면 나머지는 버림 discard). 지금까지 검색된 **모든 구절은 누적**해 입력에 포함.
- 2 CoT-guided retrieval** — **마지막으로 생성된 CoT 한 스텝만을 질의로** 사용해 기존 검색기(예: BM25)로 새 구절을 검색. (누적 CoT 전체를 질의로 쓰는 것보다 마지막 스텝만 쓰는 게 더 낫다는 것을 경험적으로 입증한 휴리스틱 설계.)
- 3 종료 조건(2가지)** — (1) **"answer is"**가 생성되기 시작하거나, (2) 총 스텝 수가 **임계값(threshold)**을 초과할 때.

교수 강조 (강의 발언)

"테스트 시점에는 반복 중 누적된 CoT를 그대로 쓰지 않고, **누적된 모든 검색 구절을 가지고 CoT를 처음부터(from scratch) 다시 생성**해 답을 만든다. 이것도 누적 CoT를 그냥 쓰는 것보다 낫다고 저자들이 보인 또 하나의 휴리스틱이다."

5.3 실험 설정: Multi-hop QA와 평가지표

정의

Single-hop QA: 문서 하나(golden passage)만 검색하면 답할 수 있는 질문 (예: NQ). ↔

Multi-hop QA: 답하기 위해 **둘 이상의 문서**에 흩어진 증거를 결합해야 하는 질문 — 대표 벤치마크 **HotpotQA** (Yang et al., EMNLP 2018). 예: "Apple 발매 직전 사망한 Mother Love Bone 멤버의 이전 밴드는?" → 멤버 정보 + 발매일 정보를 각각 검색해 결합해야 함. 교차형 접근에 자연스럽게 유리.

지표	정의	비고
Exact Match (EM)	참조 문자열과 정확히 같으면 1, 아니면 0 (한 글자만 달라도 0)	의도가 맞아도 표현이 다르면 0 → 과도하게 엄격
F1 (answer F1)	파싱 후 단어 수준(word-level) precision-recall 기반	"water bodies" ⊂ 정답이면 EM=0 이어도 F1≈0.8 가능
Recall@K	K개 검색 문서 안에 포함된 정답(ground-truth) 문서의 비율	검색기 자체 의 성능 지표

5.4 결과

- **검색 성능(Recall@K):** IRCoT가 **one-step retrieval(OneR)**보다 우수 — 질의 원문 대신 내부 생성 CoT를 검색 질의로 쓰면 추가 정보가 들어가 검색이 좋아진다.
- **답변 성능(Answer F1):** IRCoT QA가 (1) 검색 없는 QA와 (2) OneR QA를 모두 능가 — 4개 벤치마크 × 2개 LLM에서 일관됨.

★ 시험 핵심

① 한 iteration = CoT **한 스텝** 생성 + **마지막 스텝**을 질의로 새 검색, 구절은 **누적**. ② 종료 조건 2가지("answer is" / step threshold). ③ single-hop vs multi-hop 구분과 HotpotQA. ④ EM vs F1 vs Recall@K의 정확한 정의 구분.

⚠ 함정 포인트 (T/F 대비)

- "In IRCoT, the entire accumulated chain-of-thought is used as the retrieval query at each step." → **False**. Only the *last generated CoT step* is used as the query (shown empirically better than using the full CoT).
- "IRCoT discards previously retrieved passages and keeps only the most recent retrieval." → **False**. All passages retrieved up to the current iteration are *accumulated*.
- "IRCoT generates multiple CoT steps per iteration to speed up reasoning." → **False**. Exactly one step per iteration; if more are generated, the rest are discarded.
- "Exact Match gives partial credit when the prediction is contained in the reference answer." → **False**. EM is all-or-nothing (1 only for exact string match); word-level partial overlap is captured by F1.
- "HotpotQA is a single-hop QA benchmark." → **False**. HotpotQA is the representative *multi-hop* QA benchmark requiring more than one document.

6.1 동기: Noisy retrieval은 성능을 해친다

노이즈 검색(noisy retrieval)은 LLM 성능에 부정적 영향을 줄 수 있다 (Petroni et al., AKBC 2020; Li et al., ACL 2023). 검색 없이 직접 답하면 맞힐 질문도, 노이즈 문서가 컨텍스트로 들어오면 틀리게 된다 — 즉 **RAG가 검색 없는 direct answering보다 오히려 나쁠 수도 있다**. 실제로 RetRobust 실험에서 RAG는 NQ·2WikiMQA에선 성능을 올렸지만 **StrategyQA·Fermi에선 성능을 떨어뜨렸다**.

정의

Retrieval-robust LLM의 목표 (2조건): ① 검색 결과가 **관련 있으면(relevant)** 모델 성능을 **향상** 시켜야 하고, ② **무관하면(irrelevant)** 성능을 **해치지 않아야** 한다 (일반 LLM 성능 회복).

6.2 방법 ①: Training-Free — NLI 모델 필터링

- **NLI(Natural Language Inference):** 전제(premise)-가설(hypothesis) 두 문장의 관계를 함의(entailment)/중립(neutral)/모순(contradiction)으로 분류하는 과제 (또는 entailment vs not-entailment 이진 분류 — not-entailment에 중립·모순 모두 포함). SOTA NLI 모델은 비교적 작은 모델로도 **>92% 강한 성능**.
- **RAG를 NLI로 해석:** 검색된 구절 → **premise**, 질문+답변 쌍 → **hypothesis**. 올바른 검색이라면 둘은 entailment여야 한다.
- **절차:** RAG 예측을 얻고 → NLI 모델에 통과 → **entailed면 RAG 답을 채택, not entailed면 검색 없는 direct answering(바닐라 LLM 답)으로 대체**.

6.3 방법 ②: Small Training — 무시하는 법을 학습

- **동기:** NLI 필터링은 **너무 엄격(too strict)**해서 **관련 있는 구절까지 버릴 수 있다** → 소량 데이터로 LLM을 직접 학습시켜 무관한 컨텍스트를 무시하게 만든다.
- **데이터 구성:** 질의별로
 - **관련(relevant) 구절** = 주어진 검색기의 **Top-1** 구절.
 - **무관(irrelevant) 구절** = (1) 같은 질의의 **Bottom-K** 구절, 또는 (2) **다른 질의의 Top-K** 구절 (두 방식 모두 사용).

- **학습:** 어떤 구절이 주어지든 **정답의 가능도(likelihood)**를 최대화하도록 fine-tuning — 무관 구절 하에서도 정답을 내야 하므로, 모델은 무관한 컨텍스트를 **무시하고 내재 지식(intrinsic knowledge)**으로 **답하는 행동**을 단 하나의 MLE 손실로 학습.

6.4 실험 설정과 결과

항목	내용
과제 (3유형 QA)	① Single-hop: NQ ② Multi-hop(explicit reasoning): 2WikiMQA, Bamboogle ③ Multi-hop(commonsense): StrategyQA, Fermi
학습 데이터	NQ 1k, 나머지 각 500 (소량!)
모델/학습법	LLaMA2-13B + QLoRA (full fine-tuning 대신; Dettmers et al., NeurIPS 2023)
NLI 모델	BART-large fine-tuned on MNLI (수십억 규모 LLM 아님)
추론	검색기 = Google search , 4~6개 few-shot 예시

- **Top-1 검색 QA:** NLI 결합만으로 성능 하락을 성공적으로 방지, **추가 학습은 개선 폭을 더 확대** — 특히 NLI가 RAG를 살리지 못했던 StrategyQA에서 학습 기반의 향상이 가장 큼.
- **저순위(low-rank) 검색 / 무작위(random) 검색**(노이즈를 의도적으로 키운 어려운 시나리오): 두 경우 모두 RetRobust가 검색 리스크를 효과적으로 완화.

📌 교수 강조 (강의 발언)

"학습이 만능은 아니다 — 항상 **in-distribution 데이터로 학습**하므로 일반화(generalization)가 문제될 수 있다. 그리고 NLI 필터링·학습·IRCoT 같은 능력들이 각각 **분리된 수동 설계**라는 게 더 근본적인 한계다. 언제 검색할지/언제 답을 기각할지를 **하나의 모델 안에 통합(holistic)**하려면 학습 기반 방법이 필요하다 → Self-RAG(SFT)와 Search-R1(RL)로 이어진다."

★ 시험 핵심

- ① NLI 매핑 방향: **passage=premise, question+answer=hypothesis** (반대로 내면 오답).
- ② not-entailed → **direct answering**으로 풀백.
- ③ irrelevant 구절 수집 2법: bottom-K(같은 질의) / top-K(다른 질의).
- ④ 세부 셋업: LLaMA2-13B+QLoRA, BART-large(MNLI), Google search, NQ 1k/기타 500.

⚠ 함정 포인트 (T/F 대비)

- "Retrieval augmentation always improves LLM performance." → **False**. With noisy retrieval, RAG can be even worse than direct answering without retrieval (e.g., StrategyQA, Fermi).
- "In RetRobust's NLI formulation, the question is the premise and the retrieved passage is the hypothesis." → **False**. The retrieved passage is the *premise*; the question-answer pair is the *hypothesis*.
- "When the NLI model predicts not-entailment, RetRobust re-runs retrieval to find better passages." → **False**. It falls back to *direct answering without retrieval* (vanilla LLM answer).
- "RetRobust's small-training method uses GPT-4 to annotate relevant and irrelevant passages." → **False**. No LLM annotation: relevant = top-1 from the retriever; irrelevant = bottom-K for the query or top-K for *other* queries. (GPT-4 annotation은 Self-RAG의 이야기.)
- "RetRobust fully fine-tunes LLaMA2-13B on millions of examples." → **False**. It uses QLoRA with only 1k (NQ) / 500 (others) training examples.
- "The NLI-based filtering can be too strict and may discard relevant passages too." → **True**. This is exactly the motivation for the additional small-training method.

SuRe — 답 후보별 (Summarizing Retrievals using Answer Candidates, Kim et al., ICLR 2024)

조건부 검색 요약

★ 교수 본인 논문 (Kim et al., ICLR 2024). 2026 슬라이드(260506)에 검색기 비교 실험 근거로 등장 — 추론 기반 (inference-based) RAG의 대표 사례로 출제 가능성 높음.

6½.1 동기와 개요

open-domain QA에서 LLM에 top-K 검색 구절을 그대로 prepend하면 ① 구절이 길고 노이즈가 많아 컨텍스트를 낭비하고, ② 여러 구절이 서로 다른 답을 지지할 때 LLM이 무엇을 골라야 할지 흔들린다. SuRe는 별도 학습 없이(=inference-based, 블랙박스 LLM 사용) 프롬프팅만으로 이 문제를 푼다.

정의

SuRe (Summarizing Retrievals): 먼저 LLM으로 답 후보(answer candidates)를 여러 개 생성한 뒤, 각 후보마다 검색된 구절들을 그 후보를 지지하는 방향으로 조건부 요약(conditional summarization)하고, 이 후보별 요약들을 근거로 가장 그럴듯한 답을 선택·검증하는 추론 기반 RAG. 검색기·LLM 모두 학습하지 않으며(frozen) 프롬프팅만 사용.

6½.2 절차 (4단계 파이프라인)

- 1 **답 후보 생성**: 질의 + top-K 검색 구절을 LLM에 주고, 가능한 답 후보 $\{c_1, \dots, c_N\}$ 를 여러 개 생성하게 한다 (예: $N=2$).
- 2 **조건부 요약 (conditional summarization)**: 각 후보 c_i 에 대해, 검색 구절들을 "이 후보 c_i 가 답이라면 그 근거는 무엇인가"라는 조건으로 후보별 요약 S_i 를 생성. → 후보마다 자기 지지 증거를 정리한 짧은 요약이 만들어진다.
- 3 **검증·점수화 (validation)**: 각 요약 S_i 가 (i) 질의에 대해 얼마나 타당(validity)한지, (ii) 다른 후보 요약들과 비교해 얼마나 상대적으로 우월(ranking)한지를 LLM이 판단.
- 4 **최종 답 선택**: 점수가 가장 높은 후보를 최종 답으로 출력. 선택된 요약은 근거(rationale)로도 활용 가능.

"검색 문서를 그대로 넣지 말고, '답이 무엇일 수 있는가'를 먼저 가정한 다음 그 가정에 맞춰 문서를 요약하게 하면 — 같은 검색 결과에서도 훨씬 깨끗한 근거가 나온다. 학습 한 줄 없이 프롬프팅만으로, 어떤 블랙박스 LLM·어떤 검색기에도 붙는다는 게 핵심이다."

6½.3 REPLUG와의 비교 (둘 다 inference-based)

구분	REPLUG	SuRe
검색 활용 방식	각 문서 개별 prepend → 출력 확률 앙상블	답 후보별 조건부 요약 → 후보 선택
LLM 접근	블랙박스(단, 출력 확률 필요)	블랙박스 (프롬프팅·텍스트 출력만)
학습	검색기 fine-tune (LSR)	학습 전혀 없음
핵심 장치	확률 앙상블 + 검색기 정렬	answer candidate → conditional summarization

★ 시험 핵심

SuRe의 순서를 정확히: ① 답 후보 생성 → ② 후보별 조건부 요약 → ③ 검증/선택. "먼저 요약하고 나서 답을 생성한다"는 순서가 **뒤바뀌면 오답**(2025 기말 P4-2 (b) 출제). 학습이 전혀 없는 순수 inference-based 방법이라는 점도 함께.

⚠ 함정 포인트 (T/F 대비)

- "SuRe summarizes the retrieved passages first and then generates a single answer from the summary." → **False**. 순서가 반대 — **답 후보를 먼저 생성**한 뒤, **각 후보별로** 조건부 요약한다.
- "SuRe fine-tunes the LLM (or retriever) to produce better summaries." → **False**. SuRe는 **학습이 전혀 없는** 프롬프팅 기반 inference-based 방법이다.
- "SuRe produces one summary over all retrieved passages jointly." → **False**. 요약은 **답 후보마다 조건부로(per-candidate)** 따로 생성된다.

7.1 동기와 개요

앞서 본 RAG의 두 가지 이슈: ① RAG는 **질의에 따라 적응적으로(adaptively)** 적용되어야 한다 (검색이 불필요한 질의도 있음), ② RAG를 써도 출력이 **검색 문서에 근거(grounded)**하지 않을 수 있다. 딥러닝에서 문제를 푸는 가장 직접적인 방법은 학습이므로, **추가 학습으로 직접 해결**하자는 것.

정의

Self-RAG: 자기 성찰(self-reflection) — 과거 생성에 기반해 미래 행동을 자동으로 조정 (cf. Reflexion, Shinn et al., NeurIPS 2023) — 을 통해 **검색하고(retrieve)**, **생성하고(generate)**, **비평하는(critique)** 법을 **SFT(supervised fine-tuning)**로 학습하는 프레임워크. 핵심 장치는 새로 도입되는 **4종의 reflection 특수 토큰**.

7.2 4가지 Reflection 특수 토큰

토큰	판단 내용	값
Retrieve	지금 검색이 필요한가? (프롬프트·직전 생성 기반)	yes / no (/ continue)
IsREL (relevance)	검색된 구절이 질의와 관련 있는가? — 외부 검색기와 LLM의 관점 mismatch를 다루는 제어 장치	relevant / irrelevant
IsSUP (support)	생성이 그 구절에 의해 뒷받침되는가? — 내재 지식 이 아닌 검색 정보를 썼는지 검증	fully supported / partially supported / no support
IsUSE (usefulness)	최종 답이 유용한가? — 최종 출력 결정에 사용	5점 척도 (예: 1~5)

교수 강조 (강의 발언)

"중요한 것은 이 특수 토큰들이 전부 **통상적인 next-token** 생성과 똑같이 **LLM이 자동으로 생성**한다는 점이다. 언제 검색할지·언제 기각할지를 모델 스스로 판단한다 — 이것이 우리가 LLM에 심고 싶은 행동이다."

7.3 추론 (Inference) 절차

출력을 문장 단위로 분해: $y = [y_1, \dots, y_T]$, y_t 는 t번째 **출력 문장(sentence)**.

- 1 문장 생성 후 **Retrieve 토큰** 생성. **no** 면 검색 없이 다음 문장 계속 생성.
 - 2 **yes** 면 외부 검색기(BM25/DPR 등)로 K개 구절 검색 → REPLUG처럼 **각 구절을 개별 prepend 하여 병렬로** 후보 생성.
 - 3 각 후보마다 생성 전에 **IsREL**, 생성 후에 **IsSUP**(+IsUSE)를 생성.
 - 4 특수 토큰 값 조합으로 후보를 채점 — 예: "relevant + fully supported"인 후보가 "irrelevant + partially supported"보다 우수 → **최고 후보만 채택**하고 다음 세그먼트로 진행.
- 검색이 불필요한 프롬프트면: **no-retrieval** 토큰 → 검색 없이 생성 → 마지막에 IsUSE=5처럼 자기 평가. **통상 RAG와 달리 무조건 검색하지 않는다(adaptive)**.

7.4 학습 (Training) — 3단계 파이프라인

- 1 **데이터 수집 (GPT-4 = 인간 주석자의 proxy)** — reflection 토큰 주석은 비용이 크므로, 강한 LLM(GPT-4)으로 토큰 유형별 **4k~20k**개의 레이블 데이터를 수집 (few-shot 프롬프트 사용). 한 프롬프트에 10~20개 이상의 개별 주석이 필요해 full scale-up은 비용상 불가.
- 2 **Critic 모델 학습** — 수집 데이터로 별도의 LLM을 fine-tuning하여 GPT-4의 레이블링 행동을 모방하는 **비평(critic) 모델**을 만듦. **GPT-4와 90% 이상 일치(agreement)**. ※ LLaMA3의 모델 기반 데이터 필터링(큰 모델 레이블 → 작은 분류기 학습 → 대규모 배치)과 매우 유사한 전략. Critic은 **특수 토큰만** 생성하도록 특화.
- 3 **Generator 모델 학습** — Critic으로 학습 데이터에 특수 토큰을 삽입(augment)한 뒤, generator LLM을 **표준 가능도 최대화(standard likelihood maximization)**로 fine-tuning → 특수 토큰과 일반 토큰을 **동시에** 생성할 수 있게 됨.

Generator 학습 손실 — 검색 체크 마스킹

$$\max_{\mathcal{M}} \mathbb{E}_{(x, y, r) \sim \mathcal{D}_{gen}} [\log p_{\mathcal{M}}(y, r \mid x)]$$

r : reflection 특수 토큰, y : 출력 토큰. 검색된 텍스트 청크(<p>...</p>로 둘러싸인 부분)는 손실 계산에서 제외 (masked) — LLM이 생성한 것이 아니라 외부 검색기에서 온 것이기 때문. 가능도는 특수 토큰 r 과 출력 y 에 대해서만 최대화.

7.5 실험

- Self-RAG 13B(LLaMA2 기반)가 더 적은 파라미터로 당시 강력한 시스템들을 능가 — 같은 검색기를 쓴 ChatGPT + RAG에도 필적/능가.
- 교수 코멘트: "완전히 공정한 비교는 아니다(한쪽만 학습). 그러나 핵심 메시지는 좋은 학습 패러다임 설계가 작은 모델의 한계를 극복하게 한다는 것."

★ 시험 핵심

① 4토큰 이름·역할·값 (Retrieve / IsREL / IsSUP[fully·partially·no support] / IsUSE[5점]) — 어떤 토큰이 무엇을 판단하는지 매칭 문제 가능. ② 학습 순서: GPT-4 주석(4k~20k) → critic(특수 토큰 전용, 90% agreement) → generator(특수+일반 토큰). ③ 검색 청크는 loss에서 제외 — Search-R1의 retrieved token masking과 같은 원리. ④ Self-RAG는 SFT 기반(RL 아님).

⚠ 함정 포인트 (T/F 대비)

- "Self-RAG always retrieves documents before generating, like conventional RAG." → **False**. The Retrieve token makes retrieval *adaptive*; if the prompt does not need external knowledge, the model generates a no-retrieval token and answers directly.
- "Self-RAG is trained with reinforcement learning using the reflection tokens as rewards." → **False**. Self-RAG uses supervised fine-tuning (standard likelihood maximization); the RL-based counterpart is Search-R1.
- "The reflection tokens are produced by an external critic model at inference time." → **False**. At inference, the *generator itself* produces special tokens just like ordinary next tokens; the critic model is only used during training-data construction.
- "All reflection-token annotations are made by human annotators." → **False**. GPT-4 is used as a proxy of the human annotator (4k~20k), then a smaller critic model imitates GPT-4 (>90% agreement).
- "During generator training, retrieved text chunks are included in the loss to teach grounding." → **False**. Retrieved chunks (surrounded by <p>...</p>) are *excluded* from loss calculation because they are not generated by the LLM.

- "IsSUP determines whether the retrieved passage is relevant to the query." → **False**. IsSUP checks whether the *generation is supported by* the passage; relevance of the passage is IsREL.

8.1 동기: SFT → RL

Self-RAG는 효과적이지만 **복잡한 레이블링 + 복잡한 학습 파이프라인**이 필요하다. RLHF처럼 **강화학습으로 적응적 RAG를 학습**할 수 있을까? → Yes. Search-R1은 **DeepSeek-R1 프레임워크 (DeepSeek-AI, arXiv:25.01)**를 따르는 **오픈소스** 구현이며, DeepSeek 같은 기업들도 유사 접근을 채택한 것으로 추정된다 (교수: "검색 컨 DeepSeek-R1이 당시 ChatGPT보다 나아서 놀랐는데, 몇 달 뒤 RL 기반 RAG 논문들이 나오며 추측이 확인됐다").

Recap (DeepSeek-R1): 추론은 `<think>`, 답변은 `<answer>` 토큰 사이에 생성하는 구조화 생성 + **accuracy reward & format reward**로 RL 사후학습.

8.2 핵심 아이디어: RAG를 특수 토큰이 있는 출력 텍스트로 통합

특수 토큰	내용	생성 주체
<code><think> ... </think></code>	내부 추론 (reasoning)	LLM
<code><search> ... </search></code>	검색 질의 (search call) — 파싱되어 검색 엔진 호출	LLM
<code><information> ... </information></code>	검색 결과 문서 삽입 (search results)	외부 검색기 R (LLM이 생성하지 않음!)
<code><answer> ... </answer></code>	최종 답변	LLM

- 1 생성 중 `<search>` 토큰 감지 → 토큰 사이의 질의 추출 → 검색기 호출.
- 2 검색된 구절을 `<information>` 토큰으로 감싸 생성열에 다시 삽입.
- 3 추론 재개; 필요하면 또 검색(반복 가능). `<answer>` 감지 시 생성 종료.

"Interleaved CoT & retrieval이 RL 중에 자동으로 창발(emerge)했다! IRCot에서 수동 설계했던 행동이, 설계 없이 보상 최대화만으로 나타난다는 것이 핵심 포인트다."

8.3 보상과 학습 목적함수

- **보상**: 정답 기반 **단순 결과 보상(simple outcome reward)**만 사용 — 예측과 정답의 **exact match**. **format reward는 없음**(원 버전) — 최근 LLM은 이미 강한 구조 준수(structural adherence)/지시 따르기 능력을 보이기 때문. (교수: 2번째 버전에서는 format reward도 도입됨.)
- **학습**: 목적함수만 정하면 **PPO든 GRPO든 기존 RL 알고리즘**을 그대로 사용 가능.

Search-R1 학습 목적함수 (+ retrieved token masking)

$$\max_{\pi_{\theta}} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot | x; R)} [r_{\phi}(x, y)] - \beta \mathbb{D}_{KL}[\pi_{\theta}(y | x; R) \| \pi_{ref}(y | x; R)]$$

π_{θ} : 학습 정책, π_{ref} : 참조 정책(과최적화 방지용 KL 정규화), R : 검색기. **출력 y 는 LLM 생성분과 검색 R 에서 온 부분의 혼합**이다. 핵심: **retrieved token masking** — `<information>` 내 검색 토큰들은 LLM이 생성한 것이 아니므로 **손실 계산(보상 최대화·KL 모두)에서 제거**하고, LLM-generated 부분만 업데이트한다.

8.4 실험

- **셋업**: 모델 = Qwen2.5 (3B·7B), LLaMA3.2 (3B) / 지식 소스 = **Wikipedia** + 검색기 **E5** / 학습 = **NQ(single-hop) + HotpotQA(multi-hop)** 학습셋 병합 / 평가 = in-domain(NQ, HotpotQA) + out-of-domain QA(TriviaQA, 2WikiMQA, Bamboogle 등).
- **베이스라인**: 검색 없는 direct inference, CoT, RAG, **IRCot**, SFT 기반 방법 등.
- **주요 결과**: 기존 RAG 시스템 대비 **약 20~30% 향상**. 더 큰 백본일수록 향상 폭이 더 큼.

Ablation ①: PPO vs GRPO

- 효과는 **모델에 따라 다름** — Qwen2.5에선 GRPO 우세, LLaMA3.2(특히 instruct)에선 **PPO가 훨씬 우세**. 어느 RL 알고리즘이 더 나은지는 **학계 미해결**(하이퍼파라미터·과제 의존). 연구자 입장에서선 GRPO가 더 단순하고 튜닝 친화적.

Ablation ②: 학습 동역학 (training dynamics)

- **응답 길이**: DeepSeek-R1(길이 단조 증가, "aha moment")과 달리, Search-R1은 **초반에 길이가 감소했다가 이후 증가**. 2단계 해석 — Stage 1: 검색 도구 사용법(언제·어떻게 호출)을 익히면 생성을 검색으

로 대체하므로 길이 ↓ / Stage 2: 도구를 이해한 후 추론 중 적응적으로 여러 번 검색하며 길이 ↑ (이때 보상 증가가 가장 가파름). **학습 보상 자체는 내내 증가.**

- **Masking ablation:** 검색 구절을 손실에 포함(standard loss) vs 제외 — **제외(masking)가 학습 보상 관점에서 훨씬 우수.**
- **Base vs Instruct:** instruct가 출발점은 높지만 **충분한 스텝 후엔 성능이 같아짐** → 선택이 결정적이지 않음.

8.5 총비교: REPLUG vs Self-RAG vs Search-R1

구분	REPLUG	Self-RAG	Search-R1
패러다임	추론 기반 (+검색기만 학습)	학습 기반 — SFT	학습 기반 — RL (PPO/GRPO)
LM 업데이트	× (black/gray-box, frozen)	○ generator fine-tuning	○ policy RL 학습
검색기 업데이트	○ LSR (KL 최소화)	× (외부 검색기 사용)	× (외부 검색 엔진 호출)
핵심 장치	문서별 독립 추론 + 출력 확률 앙상블	4종 reflection 토큰 (Retrieve/IsREL/IsSUP/IsUSE)	<think>/<search>/<information>/<answer> 토큰

감 독 신 호	LM 출력 확률 (LSR)	GPT-4 proxy 주석 → critic → SFT	outcome reward (EM)만 — 주석 불필요
적 응 적 검 색	❌ 항상 K개 검색	○ Retrieve 토큰으로 결정	○ RL로 창발 (interleaved CoT&retrieval)
검 색 분 손 실 처 리	해당 없음	... 청크 loss 제외	retrieved token masking (loss 제외)
한 계	출력 확률 접 근 필요(사실 상 gray- box)	복잡한 주석·학습 파이프라인	RL 알고리즘 선택이 모델 의존적

★ 시험 핵심

① 4개 토큰 중 **<information>만 LLM이 생성하지 않는다**. ② 보상 = outcome reward(EM)만, format reward 없음(이유: 구조 준수 능력 충분). ③ **retrieved token masking** — Self-RAG와 공통 원리, ablation에서 masking이 더 우수. ④ 길이 동역학: 감소→증가 2단계 (DeepSeek-R1과 반대 시작). ⑤ PPO vs GRPO는 모델 의존(미해결). ⑥ interleaved retrieval이 IRCot처럼 설계된 게 아니라 **RL 중 자동 창발**.

⚠ 함정 포인트 (T/F 대비)

- "In Search-R1, the tokens inside <information> are generated by the LLM conditioned on the search query." → **False**. They come from the external retriever

R and are merely inserted into the sequence; they are excluded from loss calculation.

- "Search-R1 uses both an accuracy reward and a format reward, following DeepSeek-R1." → **False** (원 버전 기준). The original Search-R1 uses only a simple outcome reward, arguing recent LLMs already show strong structural adherence (format reward는 2번째 버전에서야 도입).
- "Search-R1 requires GPT-4 annotations of when to search, similar to Self-RAG." → **False**. No annotation of search behavior is needed; adaptive, interleaved retrieval *emerges* automatically from RL with an outcome reward.
- "During Search-R1 training, response length monotonically increases as in DeepSeek-R1." → **False**. Length first *decreases* (learning to replace generation with retrieval) and then increases (multi-turn adaptive search), while training reward keeps increasing.
- "GRPO consistently outperforms PPO in Search-R1 across all models." → **False**. GRPO is better for Qwen2.5, but PPO is much better for LLaMA3.2(-instruct); the answer is model/hyperparameter-dependent and remains open.
- "Including retrieved tokens in the loss improves training because the model learns from more tokens." → **False**. The masking ablation shows that *excluding* retrieved tokens from the loss is much better in terms of training reward.
- "Search-R1 trains a custom retriever jointly with the LLM." → **False**. It uses a fixed external retriever (Wikipedia + E5); only the LLM policy is trained.

Q 예상문제

2025 기말 기출과 동일한 형식·문체로 구성. T/F: 정답 3점 / 오답 0점 / 무응답 1점. Pick-all: "any wrong answer will lead to 0 points".

Part A. True / False (10문항)

Q1. (True/False) 예상문제

Fine-tuning an LLM on data containing new knowledge is known to be an effective way to keep the model up-to-date without any side effects.

▼ 정답 & 해설 보기

False. Fitting on new (unknown) knowledge can decrease overall accuracy: performance on known data drops after several epochs while unknown data is still not fully learned. This limitation is a key motivation for RAG.

Q2. (True/False) 예상문제

In the PageRank formulation, $1 - d$ corresponds to the probability of jumping to a random page rather than following a link.

▼ 정답 & 해설 보기

True. d is the damping factor weighting the neighbor-based (link-following) term, and $1 - d$ models a random page visit. With uniform initialization, power iteration converges to a unique solution.

Q3. (True/False) 예상문제

In BM25, the inverse document frequency of a keyword is computed using only the target document, independent of the rest of the corpus.

▼ 정답 & 해설 보기

False. IDF is computed from corpus-level statistics (N total documents and $n(q_i)$ documents containing the keyword) and is not related to the target document itself; the within-document part is the term frequency.

Q4. (True/False) 예상문제

Contriever uses the same contrastive training objective as DPR, but constructs positive pairs automatically by taking two crops from the same document instead of using human-labeled data.

▼ 정답 & 해설 보기

True. The objective is unchanged; only the data construction differs — positives are crops within the same (Wikipedia) document, negatives are crops from other documents, enabling self-supervised training without human cost.

Q5. (True/False) 예상문제

REPLUG fine-tunes the retriever by minimizing the KL divergence between the retrieval likelihood and the LM likelihood, while keeping the target LM frozen.

▼ 정답 & 해설 보기

True. This is LSR (LM-Supervised Retrieval): the retriever distribution over the K documents is aligned with the LM's answer-likelihood distribution via KL minimization; the black-box LM is never updated.

Q6. (True/False) 예상문제

In IRCot, the full accumulated chain-of-thought generated so far is used as the query for the next retrieval step.

▼ 정답 & 해설 보기

False. Only the *last generated CoT step* is used as the retrieval query; the authors showed this works better than using the entire accumulated CoT. (Note: retrieved *passages* are accumulated, but the query is not.)

Q7. (True/False) 예상문제

In RetRobust's training-free method, the retrieved passage is treated as the premise and the question-answer pair as the hypothesis of an NLI task; if entailment is not predicted, the system falls back to direct answering without retrieval.

▼ 정답 & 해설 보기

True. Correct retrieval should entail the question-answer pair. When the NLI model (BART-large fine-tuned on MNLI) predicts not-entailment, the vanilla LLM answer without retrieval is used instead.

Q8. (True/False) 예상문제

Self-RAG's reflection tokens are generated by a separate critic model at inference time, since the generator can only produce ordinary tokens.

▼ 정답 & 해설 보기

False. After training, the generator itself produces both special (reflection) tokens and ordinary tokens via standard next-token generation. The critic model is only used during training to annotate data (imitating GPT-4 with >90% agreement).

Q9. (True/False) 예상문제

In both Self-RAG and Search-R1, tokens that come from the external retriever are excluded from the loss calculation because they are not generated by the LLM.

▼ 정답 & 해설 보기

True. Self-RAG masks retrieved text chunks (surrounded by <p> and </p>), and Search-R1 applies retrieved token masking to the <information> spans for both reward maximization

and KL terms. The Search-R1 ablation shows masking is clearly better.

Q10. (True/False) 예상문제

During Search-R1 training, the response length increases monotonically from the beginning, similar to the behavior observed in DeepSeek-R1.

▼ 정답 & 해설 보기

False. Unlike DeepSeek-R1, the response length first *decreases* (Stage 1: the model learns to use the search tool and replaces generation with retrieval) and then increases (Stage 2: adaptive multi-step search during reasoning), while the training reward increases throughout.

Part B. Pick all that are correct (7문항)

Pick all the correct answers; any wrong answer will lead to 0 points.

Q11. (Pick all that are correct) 예상문제

Which of the following are correct about the motivation and basic structure of RAG?

- a. The knowledge cutoff of an LLM refers to the time point up to which its pre-training data covers, e.g., 2023-10 for GPT-4o.
- b. Abstaining from answering is preferred over RAG because it preserves user utility.
- c. RAG replaces only the generator part of the classical retrieve-and-read system with an LLM, while the retriever part remains the same.
- d. Inference-based RAG appends retrieved information as additional input without training the LLM.

▼ 정답 & 해설 보기

정답: (a), (c), (d)

- (a) Correct. Knowledge cutoffs are released with the models (GPT-4o & mini: 2023-10, LLaMA3: 2023-12).

- (b) Incorrect. Abstaining *decreases* utility from the user's perspective, which is why it is not a helpful solution.
- (c) Correct. The retriever is unchanged; only the reader/generator became an LLM.
- (d) Correct. That is the definition of inference-based RAG (vs. training-based).

Q12. (Pick all that are correct) 예상문제

Which of the following are correct about retrieval methods (BM25, DPR, Contriever)?

- a. BM25 is called a sparse retriever because it is based on discrete word-level matching.
- b. DPR computes the similarity between a query and a passage as the dot product of features from two separate encoders.
- c. DPR uses in-batch negatives, i.e., passages paired with other queries in the same batch, as negative passages.
- d. Since dense retrievers are trained, DPR consistently outperforms BM25 even on out-of-distribution datasets.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. Text-based retrieval = sparse; embedding-based = dense.
- (b) Correct. $\text{sim}(q, p) = E_Q(q)^\top E_P(p)$ with separate query/passage encoders.
- (c) Correct. Negatives = labeled hard negatives + in-batch negatives.
- (d) Incorrect. On out-of-distribution datasets, BM25 can significantly outperform DPR; test distribution is critical for training-based retrievers, and there is no single best method.

Q13. (Pick all that are correct) 예상문제

Which of the following are correct about REPLUG?

- a. It assumes the target LM is black-box, i.e., its parameters cannot be accessed or updated.

- b. To overcome the limited context window, it prepends each retrieved document separately and ensembles the output probabilities with weights proportional to retriever similarity scores.
- c. The separate-prepend strategy does not substantially increase computational cost due to the quadratic nature of Transformers.
- d. LSR updates both the retriever and the LM jointly to minimize the KL divergence between their distributions.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. That is REPLUG's core assumption (though the professor noted it is really a gray-box setting since output probabilities are still needed).
- (b) Correct. $p(y|x, \mathcal{D}') = \sum_d p(y|d \circ x) \lambda(d, x)$ with softmax-normalized similarity scores.
- (c) Correct. K short forward passes cost about the same as (or less than) one long concatenated pass.
- (d) Incorrect. Only the *retriever* is updated; the LM is frozen (black-box). LSR = LM-Supervised signal for fine-tuning the Retriever.

Q14. (Pick all that are correct) 예상문제

Which of the following are correct about IRCoT and multi-hop QA?

- a. IRCoT alternates between extending the CoT by exactly one step and retrieving new passages using that step as the query.
- b. Multi-hop QA, e.g., HotpotQA, requires combining evidence from more than one document to answer a question.
- c. The iteration terminates when the model starts generating "answer is" or when the number of steps exceeds a threshold.
- d. Recall@K measures the word-level overlap between the predicted answer and the reference answer.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. One CoT step per iteration (extra steps are discarded), and the last step is used as the new retrieval query.
- (b) Correct. That is the definition of multi-hop QA; single-hop QA can be answered with one (golden) passage.
- (c) Correct. These are the two stopping conditions.
- (d) Incorrect. Recall@K is a *retrieval* metric: the proportion of ground-truth documents included among the K retrieved ones. Word-level overlap of answers is the F1 score.

Q15. (Pick all that are correct) 예상문제

Which of the following are correct about RetRobust?

- a. The goal is that relevant retrieved context should improve performance while irrelevant context should not hurt performance.
- b. For the small-training method, irrelevant passages are collected as bottom-K passages for the given query or top-K passages for other queries.
- c. The LLM is trained to output a special "irrelevant" token when noisy passages are given, instead of answering.
- d. LLaMA2-13B is fine-tuned with QLoRA on a small dataset (1k for NQ and 500 for the others).

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. These are the two conditions of retrieval-robust LLMs.
- (b) Correct. Relevant = top-1 of the retriever; irrelevant = bottom-K (same query) or top-K (other queries).
- (c) Incorrect. No special token is involved (that is Self-RAG). RetRobust simply maximizes the likelihood of the correct answer even under irrelevant passages, so the model learns to ignore them and answer from intrinsic knowledge.

- (d) Correct. Plus BART-large (MNLI) as the NLI model and Google search as the retriever at inference.

Q16. (Pick all that are correct) 예상문제

Which of the following are correct about Self-RAG?

- a. Four types of reflection tokens are introduced: Retrieve, IsREL, IsSUP, and IsUSE.
- b. IsREL judges whether the retrieved passage is relevant, while IsSUP judges whether the generation is supported by the passage.
- c. Training data for reflection tokens is collected using GPT-4 as a proxy of the human annotator, and a critic model is trained to imitate it with higher than 90% agreement.
- d. Self-RAG is trained with PPO using the IsUSE token value as the reward.

▼ 정답 & 해설 보기

정답: (a), (b), (c)

- (a) Correct. Retrieve (when to retrieve), IsREL (relevance), IsSUP (support: fully/partially/no support), IsUSE (usefulness).
- (b) Correct. This distinction is a classic trap — do not swap them.
- (c) Correct. 4k–20k annotations from GPT-4 → critic model → generator training (a strategy also similar to LLaMA3's data filtering).
- (d) Incorrect. Self-RAG uses *supervised fine-tuning* (standard likelihood maximization), not RL. RL-based adaptive RAG is Search-R1.

Q17. (Pick all that are correct) 예상문제

Which of the following are correct about Search-R1?

- a. It incorporates RAG into the output text using special tokens: <think>, <search>, <information>, and <answer>.
- b. The original version uses only a simple outcome reward based on the ground-truth answer, without a format reward.

- c. Interleaved chain-of-thought and retrieval is manually designed into the inference algorithm, following IRCot.
- d. The choice between PPO and GRPO matters differently per model: GRPO is better for Qwen2.5 while PPO is better for LLaMA3.2.

▼ 정답 & 해설 보기

정답: (a), (b), (d)

- (a) Correct. The query inside <search> is parsed and sent to the search engine; results are inserted inside <information>.
- (b) Correct. The rationale is that recent LLMs already demonstrate strong structural adherence (a format reward was only added in a later version).
- (c) Incorrect. Interleaved CoT & retrieval *automatically emerges* during RL training — it is not manually designed, which is a key selling point over IRCot.
- (d) Correct. The effectiveness of RL algorithms is model- and hyperparameter-dependent; this question remains open in academia.

3분 요약

개념	한 줄 정리
RAG 동기	정적 데이터셋 → knowledge cutoff·hallucination; fine-tuning은 새 지식 주입에 한계 → retrieve-and-read의 generator만 LLM으로
PageRank	중요도 = 이웃 중요도의 평균; $1 - d$ =random jump 확률; power iteration이 유일해로 수렴; 의미 정보는 안 씀
BM25	Sparse retriever; IDF(corpus 전체) × TF(대상 문서); 학습 無; 맥락 의미 포착 불가
DPR	두 인코더 + dot-product + contrastive loss; labeled p^+/p^- + in-batch negatives; OOD에 약함
Contriever	같은 문서 crop = positive인 자기지도 대조 학습; 손실은 DPR과 동일; 분포 변화에 강건
REPLUG	블랙박스 LM에 문서별 독립 prepend → 출력 확률 가중 앙상블; LSR = retrieval↔LM likelihood KL 최소화로 검색기만 학습
IRCoT	CoT 1스텝 ↔ 검색 교차 반복(마지막 스텝=질의, 구절 누적); multi-hop QA(HotpotQA)에서 OneR보다 Recall@K·F1 모두 우수
RetRobust	① NLI 필터(passage=premise, Q+A=hypothesis; not-entailed→direct answering) ② 소량 학습(top-1 vs bottom-K/타 질의 top-K)으로 무관 컨텍스트 무시 학습
Self-RAG	SFT로 4 reflection 토큰(Retrieve/IsREL/IsSUP/IsUSE) 학습; GPT-4 주석→critic(90% agreement)→generator; 검색 청크는 loss 제외
Search-R1	RL(outcome reward만)로 <think>/<search>/<information>/<answer> 학습; retrieved token masking; interleaved 검색이 자동 창발; 길이 감소→증가 2단계
평가지표	EM(완전 일치 0/1) / F1(단어 수준) / Recall@K(K개 중 정답 문서 비율 — 검색기 지표)



작년 기말 출제: RAG (2025 Final — Problem 4, Problem 1)

2025.06.17 기말 원문 그대로 + 정답·해설. **기출** = 실제 출제. Pick-all은 "any wrong answer → 0 points". 일부 항목은 **올해(2026) 슬라이드에 없어 범위 밖(참고용)**으로 표시했다.

⚠️ 작년 기말 핵심 — inference-based vs training-based 구분

Problem 4가 이 축으로 3문항(general / inference / training) 연속 출제. 반드시 외울 분류:

- **Inference-based** (학습 없이 prepend/프롬프팅): **REPLUG**(black-box LM, 검색기만 LSR로 fine-tune — LM 파라미터 접근 X), **SuRe**(답 후보 먼저 → 후보별 조건부 요약), **IRCoT**(CoT ↔ 검색 interleave), **RetRobust**의 **NLI 필터**.
- **Training-based** (LLM/검색기를 학습): **REALM**(retriever+reader *joint* 학습), **Self-RAG**(SFT — RL 아님!), **Search-R1**(RL로 학습하되 **외부 retriever는 frozen**).

함정 단골: ① "REPLUG가 LM을 full access로 학습" → False(black-box). ② "Self-RAG가 RL로 학습" → False(SFT). ③ "Search-R1의 retriever도 supervised로 fine-tune" → False(frozen). ④ "SuRe가 요약 먼저 → 답 생성" → False(답 후보 먼저).

Problem 4-1. RAG (general) **기출**

Which of the statements about RAG are correct? (Pick all; any wrong answer → 0 points) (3 pts)

- Dense retrieval methods often rely on contrastive loss during training.
- Fine-tuning LLMs with new knowledge is a scalable and safe solution.
- Retrieval-based input augmentation can help LLMs access more up-to-date information.
- Knowledge cutoff in pretraining dataset can cause trained LLMs to miss recent events.

▼ 정답 & 해설 보기

정답: (a), (c), (d)

- (a) Correct. Contrastive learning is the standard training paradigm in dense retrieval (DPR, Contriever).
- (b) Incorrect. Fine-tuning with new knowledge can degrade accuracy and has scalability/safety issues — this is a core motivation for RAG.
- (c) Correct. Retrieval augments the input with up-to-date external documents.
- (d) Correct. LLMs are trained on fixed datasets and lack recent info due to knowledge cutoff.

Problem 4-2. Inference-based RAG 기출

Which correctly describe the inference-based RAG methods? (Pick all; any wrong → 0 points) (3 pts)

- a. REPLUG assumes a full access to LLM parameters for end-to-end training.
- b. SuRe first generates answer candidates and then summarizes retrievals conditionally.
- c. IRCot simultaneously conduct retrieval and reasoning using Chain-of-Thought prompting.
- d. RetRobust improves RAG by using natural language inference (NLI) models for filtering.

▼ 정답 & 해설 보기

정답: (b), (d)

- (a) Incorrect. REPLUG assumes **black-box** access — LM parameters are NOT updated (only the retriever is fine-tuned via LSR).
- (b) Correct. **SuRe**: 답 후보를 먼저 생성한 뒤, 각 후보별로 검색을 조건부 요약. (순서가 핵심 — 위 §6½ 참조, 교수 논문.)
- (c) Correct. IRCot interleaves retrieval and reasoning using CoT steps. (원문 "simultaneously" 표현이지만 정답 처리됨.)
- (d) Correct. RetRobust uses an existing NLI model to assess whether a retrieved passage supports the QA pair.

Problem 4-3. Training-based RAG 기출

Which correctly describe the training-based RAG methods? (Pick all; any wrong → 0 points) (3 pts) REALM은 올해 범위 밖(참고용)

- a. REALM jointly trains both the retriever and the reader components. (REALM = 작년 출제 · 2026 슬라이드 없음)
- b. Self-RAG trains LLM to critique and refine its own generations via RL training.
- c. Training-based RAG can learn to ignore irrelevant documents through supervision.
- d. The retriever, target LLM, and query generator in Search-R1 are all fine-tuned using standard supervised learning.

▼ 정답 & 해설 보기

정답: (a), (c)

- (a) Correct. REALM trains retriever and reader **jointly (end-to-end)**. 단, REALM은 2026 슬라이드에 없음 — 작년 출제 개념이니 정의(joint training)만 기억.
- (b) Incorrect. Self-RAG uses **supervised fine-tuning** with GPT-4-generated reflection data, *not RL*. (RL은 Search-R1.)
- (c) Correct. With supervision, training-based RAG can downweight/ignore unhelpful documents.
- (d) Incorrect. The external retriever in Search-R1 is **frozen (not fine-tuned)**; only the policy LLM is trained via RL.

Problem 1 — True/False (RAG 관련 항목) 기출

T/F: 정답 3점 / 오답 0점 / 무응답 1점.

(ii) BM25 is supervised dense retrieval method.

기출

▼ 정답 & 해설 보기

False. BM25 is an **unsupervised sparse** retrieval method (단어 겹침 + TF-IDF, 학습 없음).

"supervised dense"가 두 군데 다 틀림 — sparse·unsupervised가 정답.

(iii) HyDE synthesizes the query-relevant document by prompting LLM, and then use this to retrieve document using contriever. 기출 올해 범위 밖(참고용)

▼ 정답 & 해설 보기

True. HyDE(Hypothetical Document Embeddings): LLM이 질의에 대한 **가상의 답 문서를 생성한** 뒤, 그 합성 문서를 임베딩해 Contriever로 실제 문서를 검색. **HyDE는 2026 슬라이드에 없음 — 작년 출제 개념(참고용).**

(iv) ATLAS uses FiD (Fusion-in-Decoder) to mitigate context length limitations.

기출 올해 범위 밖(참고용)

▼ 정답 & 해설 보기

True. FiD는 각 문서를 인코더에서 **개별 인코딩**한 뒤 디코더에서 **융합(fuse)** → 긴 컨텍스트를 분할 처리해 길이 한계를 완화. ATLAS가 이를 사용. **ATLAS/FiD는 2026 슬라이드에 없음(참고용).**

★ 정리 — 올해 범위 표시

범위 O (2026 슬라이드 있음): SuRe · REPLUG · IRCot · RetRobust · Self-RAG · Search-R1.

범위 밖·참고용 (2026 슬라이드 없음, 작년만): REALM · HyDE · ATLAS/FiD. — 정의 한 줄씩만 기억하면 충분.

← 전체 목차

다음 장 →