

CAS4133 LLM · 기말 대비 · 기출 & 출제 예측

기출문제 모음 & 기말 출제 예측

2025 봄 기말고사 전체 원문(Problem 1~5) 신규 수록 — Problem 2(계산)·Problem 3(수식) 단계별 풀이 포함 + 작년 기말 실제 구조 기반 출제 청사진

★ 작년 기말: 2025-06-17 (Jaehyung Kim)

📊 100점 / 100분

🕒 TF30 · Inference계산20 · Training수식15 · RAG15 · Safety20

📄 목차

1. 시험 형식 분석 & 풀이 전략 (함정 패턴 유형화)
2. ★ 2025 봄 기말고사 (작년 실제 기출 — 가장 중요)
3. 기말 출제 청사진 — 작년 기말 실제 구조 기반
4. 기말 범위 챕터별 디테일 (#7~#14) + 특강 통합형 예상 문제

1 시험 형식 분석 & 풀이 전략

1.1 시험 구조 (2025 기말 기준)

Problem	형식	문항 수	배점	채점 규칙
Problem 1	True / False	10문항	30점 (각 3점)	정답 3점 / 오답 0점 / 무응답 1점
Problem 2	Inference 계산 (서술)	4문항	20점	행렬 곱·hamming·top-K 손계산 — 객관식 아님
Problem 3	Training 수식 작성 (서술)	3문항	15점	CE / instruction / RLHF 목적함수 직접 작성
Problem 4	Pick all that are correct	5문항	15점 (각 3점)	"any wrong answer will lead to 0 points " — 보기 (a)~(d) 중 정답 조합을 완벽히 골라야 득점. 부분점수 없음
Problem 5	Pick all that are correct	5문항	20점 (각 4점)	
합계		—	100점	시험시간 100분 (4:10~5:50 PM — 시간은 충분)



마지막 수업 공지 반영

확정

- **객관식(Pick-all/multiple choice) Problem은 3~4개** — 교수 직접 발언: "I will make three or four multiple choice question problems". **확정**
- **그중 1개 = 특강 통합 Problem**: "one of them will be about the jailbreaking and AI-generated detection, all in one part" — #13 Jailbreak + #14 AI Text Detection이 **한 Problem에** 혼합 출제. **확정**

- 작년 기말 패턴상 **T/F Problem(10문항)**은 별도로 있을 가능성이 큼 — 교수는 객관식 개수만 언급했으므로 이는 추정. 추정
- **성적: 기말 30%** / 과제 20% / 프로젝트 20% / 출석 10% (나머지는 기말 외 평가). **절대평가** — A-A-는 후하게, A+는 엄격하게. 확정

★ 구조에서 읽히는 출제 패턴

- **챕터당 1개의 Problem**(5문항 내외) + T/F는 전 범위에서 골고루 10문항. 기말도 같은 틀일 가능성이 높다 — 기말 범위 8개 챕터 중 **4개 내외가 Problem으로 승격**되고, 나머지는 T/F에서 소화 될 것.
- Pick-all 보기 4개 중 정답 수는 1~4개 모두 등장 (작년 기말 Problem 4.5 기준: 2개·3개가 다수, 전부 정답도 1회). **"정답이 보통 2개"라는 가정은 위험** — 전부 정답(P5-1 Jailbroken)이나 2개만 (P4-2, P5-2~5)도 나온다.
- 해설 문체가 정형화: "Correct. ..." / "Incorrect. ..." — 각 보기가 독립적인 T/F 명제다. 즉 **Pick-all = 미니 T/F 4연발**로 풀면 된다.

1.2 점수 전략

- 1 **T/F 무응답 전략 (기대값 계산)** — 무응답은 확정 1점. 찍기의 기대값은 $0.5 \times 3 = 1.5$ 점이므로 **50:50이라도 찍는 게 기대값상 유리**하다. 단, "확신이 40% 미만"(상대가 더 그럴듯해 보일 때)이면 기대값이 1.2점 이하로 떨어져 무응답(확정 1점)과 차이가 미미 — 이때는 **리스크 없는 1점 확보**가 합리적. 결론: *완전히 모르는 문제만 비우고, 조금이라도 기울면 답하라.*
- 2 **Pick-all은 보기별 독립 판정** — 각 보기를 True/False로 따로 채점한 뒤 True만 모은다. "이 중 2개가 답이겠지" 식의 조합 추론 금지. 한 보기라도 틀리면 0점이므로, **확신 없는 보기는 '강한 근거가 없으면 제외'**가 아니라, **해당 보기의 명제가 참인지 자체를 판정**해야 한다. 애매한 보기 처리: ①절대어 (always/only/never/all)가 들어 있으면 False 쪽으로 기울인다(아래 함정 유형 ②). ②수치·고유명사는 강의 슬라이드의 정확한 값과 대조한다. ③"일반적으로 맞지만 예외가 있는" 서술은 출제자가 Correct 처리하는 경향(예: 작년 기말 P4-1(a) "dense retrieval often relies on contrastive loss").
- 3 **시간 배분** — 100분. T/F + Pick-all 객관식 1회독(40분) → 계산·수식 서술(Problem 2·3, 30분) → 애매 문항 재검토(15분) → T/F 무응답 최종 결정·검산(15분). 서술형(P2·3, 35점)에 충분한 시간을 남겨라.

1.3 함정 패턴 유형화 — 작년 기말 해설의 "Incorrect" 전수 분석

작년 기말 Pick-all(Problem 4 RAG+Tool, Problem 5 Safety)의 모든 오답 보기("Incorrect. ...")를 유형별로 분류하면 출제자의 함정 제조법이 보인다. **올해 기말에도 같은 틀로 함정이 만들어진다.**

유형	함정 제조법	작년 기말 실례	기말 예상 적용
① 주체 바꿔치기 swap	A의 속성/역할을 B에 붙인다 (user↔automated, attacker↔defender)	P4-4(c) "user manually executes the function" → 자동 실행. P5-2(c) AutoDAN "requires human feedback" → 자동 평가 (keyword/LLM-judge)	retriever↔reader(RAG), actor↔critic, attacker↔defender(jailbreak), generator↔verifier
② 절대어 함정 always/only/all	대체로 맞는 명제에 always·only·all·fully·no를 박아 False로 만든다	P4-3(d) Search-R1 "all fine-tuned" → retriever는 frozen. P4-5(d) ToolLLM "only single-tool" → multi-tool 포함. P5-4(d) watermarking "fully robust to paraphrasing" → 깨질 수 있음. P5-5(b) hallucination "only in low-resource settings"	"RAG always improves factuality", "Tool use eliminates hallucination", "RL requires no reward model" 류
③ 수치 함정 number	유명한 수치를 다른 모델의 수치로 치환	(작년 기말 Pick-all엔 직접 수치 함정은 없었으나, T/F-계산 Problem에서 등장 가능)	파라미터 수, top-k의 k, 벤치마크 수치, 논문 연도, ToolLLM API 수

④ 방법 귀속 오류 attribution	방법 X의 주장/기법을 방법 Y의 것으로 서술	P4-2(a) REPLUG "full access to params" → black-box. P4-3(b) Self-RAG "via RL" → SFT(reflection data). P5-3(c) DetectGPT "fine-tuned supervised classifier" → zero-shot	DPR↔BM25, Toolformer↔ToolLLM, ReAct↔Reflexion, PPO↔GRPO, GCG↔Gradient Cuff, DetectGPT↔watermarking
⑤ 처리 순서/위치 함정 order	연산·검색이 적용되는 단계를 뒤바꾼다	P4-2(c) IRCoT "simultaneously" → interleave(번갈아). watermarking은 생성 중 개입(생성 후 ×)	"retrieval happens after generation", "KL penalty applied after reward" 류
⑥ 범주 혼동 category	inference 기법 ↔ training 기법, online↔offline, fluent↔factual를 섞는다	P4-2(a)/(c) inference-level RAG vs training-level RAG 귀속 (REPLUG·IRCoT vs Self-RAG·REALM·Search-R1). hallucination = fluent-but-false(품질 ↔ 사실 혼동)	"RAG는 학습 기법", "speculative decoding은 학습 가속", "DPO·GRPO online/offline" 구분
⑦ 목적/동기·방향 왜곡 motivation	방법의 진짜 동기·방향을 그럴듯한 반대로 바꾼다	P5-2(a) AutoDAN "minimize the likelihood of proxy label" → maximize(생성 모멘텀 활용). P5-3(a) DetectGPT "high positive curvature"	"RAG의 동기는 속도", "watermark의 동기는 품질 향상" 류

→ negative
curvature

⚠ 실전 체크리스트 (보기 읽을 때마다)

- 절대어(always / only / all / never / eliminates / requires / cannot / any)가 보이면 → 반례 1개를 떠올려본다. 반례가 있으면 False.
- 주어(모델/방법 이름)와 술어(속성)가 정말 그 조합이 맞는지 — "이 속성은 원래 누구 것?"을 자문한다.
- 수치는 외운 값과 정확히 대조 (175B, 110M, top-k의 k, Chinchilla 20 tokens/param 등).
- 이 기법이 **training-time인지 inference-time인지**, online인지 offline인지 분류부터 한다.
- 단, 함정 같아 보여도 전부 맞는 문제(작년 기말 P5-1 Jailbroken: 정답 a,b,c,d)도 있다 — 패턴 매칭이 아니라 명제 자체를 판정하라.

★ 2025 봄 기말고사 (작년 실제 기출 — 가장 중요)

아래는 2025년 6월 17일에 실제로 출제된 기말고사 전체 원문(Problem 1~5)이다. 올해 기말도 동일 청사진(아래 표)으로 출제될 가능성이 매우 높다. **작년 실제 기출** 뱃지가 붙은 문항은 전부 원문 그대로다.

작년 기말 청사진

Problem	주제	형식	배점	주의
Problem 1	True / False	T/F 10문항	30점	정답 3점 / 오답 0점 / 무응답 1점
Problem 2	Inference with LLM	계산 문제 (서술)	20점	행렬 곱·hamming·top-K 손계산 — 객관식 아님!
Problem 3	Training of LLM	수식 작성 (서술)	15점	CE / instruction / RLHF 목적함수 직접 작성
Problem 4	RAG and Tool-use	Pick-all 5문항	15점	any wrong → 0점
Problem 5	LLM Safety	Pick-all 5문항	20점	any wrong → 0점
합계			100 점	100분 (4:10~5:50 PM)

⚠ 절대 놓치면 안 되는 점 — Problem 2·3은 손계산/수식 (합 35점)

Problem 2(20점)·Problem 3(15점)은 객관식이 아니라 손으로 푸는 계산·수식 문제다.

T/F·Pick-all만 공부하면 **35점(=전체의 35%)**을 통째로 날린다. 행렬 곱셈, hamming distance, top-K 샘플링, autoregressive 생성, 그리고 cross-entropy·instruction tuning·RLHF 목적함수 수식을 **직접 쓸 수 있을 때까지** 연습하라.

⚠ 올해(2026) 범위 밖 토픽 — 참고만, 출제 가능성 낮음

아래는 작년 기말엔 나왔으나 **올해 2026 슬라이드엔 없는** 토픽이다. 이름만 참고하고 깊이 파지 말 것.

- **HyDE** (P1-iii) — 가설 문서 생성 후 contriever로 검색하는 RAG 기법.
- **ATLAS / FiD (Fusion-in-Decoder)** (P1-iv) — 문서를 따로 인코딩 후 디코더에서 융합.
- **REALM** (P4-3a) — retriever와 reader를 end-to-end 공동 학습.
- **DoLa** (P1-viii) — 레이어 간 contrastive decoding(JSD 최대 레이어 선택).
- **Inference-Time Intervention (ITI)** (P5-5) — truthful 방향으로 activation을 이동.

단, **SuRe(P4-2b)**는 **올해 범위에 포함**되므로 정상적으로 공부할 것.

Problem 1: True / False (30 Points) **작년 실제 기출**

"You will get 3 points for each correct answer, 0 points for each wrong answer, and 1 point for each unanswered question."

(i) True/False **작년 기말**

RLHF provides an interpretable rule set defining what "good behavior" is.

▼ 정답 & 해설 보기

False. RLHF defines "goodness" implicitly via large human preference datasets, not interpretable rule sets.

(ii) True/False **작년 기말** **#9 RAG**

BM25 is supervised dense retrieval method.

▼ 정답 & 해설 보기

False. BM25 is unsupervised sparse retrieval method.

(iii) True/False **작년 기말** **올해 범위 밖**

HyDE synthesizes the query-relevant document by prompting LLM, and then use this to retrieve document using contriever.

▼ 정답 & 해설 보기

True. (HyDE는 올해 2026 슬라이드엔 없음 — 참고만.)

(iv) True/False

작년 기말

올해 범위 밖

ATLAS uses FiD (Fusion-in-Decoder) to mitigate context length limitations.

▼ 정답 & 해설 보기

True. FiD encodes documents separately and fuses them in the decoder. (ATLAS/FiD는 올해 범위 밖.)

(v) True/False

작년 기말

#10 Tool Use

Toolformer filters API calls based on whether their inclusion improves next-token prediction.

▼ 정답 & 해설 보기

True.

(vi) True/False

작년 기말

#13 Jailbreak

Jailbreaking mainly occurs because LLMs are fine-tuned with malicious data.

▼ 정답 & 해설 보기

False. Even LLMs are not fine-tuned with malicious data, it can occur due to competing objective and mismatched generalization.

(vii) True/False

작년 기말

#14 AI Text Detection

Fast-DetectGPT removes the need to compute log-probabilities from the source model unlike DetectGPT.

▼ 정답 & 해설 보기

False. While the cost is significantly reduced by using conditional probability, log-probabilities are still needed for curvature computation.

(viii) True/False

작년 기말

올해 범위 밖

DoLa selects the intermediate layer that achieves the minimum JSD compared to output probability at last layer, and then apply contrastive decoding.

▼ 정답 & 해설 보기

False. Choose the layer that **maximizes** JSD. (DoLa는 올해 범위 밖.)

(ix) True/False

작년 기말

#12 RL (PPO)

The motivation of PPO is to take biggest possible improvement step on policy, without stepping so far from current policy to prevent collapse.

▼ 정답 & 해설 보기

True.

(x) True/False

작년 기말

#12 RL (GRPO)

GRPO estimates advantage function by generating multiple responses per query and calculating the statistics of their rewards.

▼ 정답 & 해설 보기

True.

Problem 2: Inference with LLM (20 Points) 작년 실제 기출 계산 문제

단일 행렬로만 구성된 아주 단순한 LLM M 이 주어진다. M 은 입력 시퀀스 $\tilde{x} \in \mathbb{R}^{L \times 3}$ 를 $\tilde{x} \mapsto \tilde{x} \circ M$ 로 매핑한다 (곱 순서 주의):

$$M = \begin{bmatrix} 1 & 1 & 0 \\ -1 & 0 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

Word embeddings (vocabulary):

#	단어	embedding	#	단어	embedding
1	한	[1, 0, 0]	8	고맙습니다	[3, 0, 1]
2	학기	[1, 1, 0]	9	했습니다	[0, 2, 3]
3	동안	[0, 1, 1]	10	많았습니다	[1, 2, 3]
4	매우	[-1, 1, 0]	11	감사합니다	[3, 1, 2]
5	수고	[0, 1, 2]	12	하셨습니다	[0, 2, 2]
6	고생	[1, 1, 2]	13	많았어요	[1, 2, 2]
7	정말	[0, 0, 2]			

2-1 (5 pts) 작년 기말

입력 시퀀스 $x = \text{"한 학기 동안"}$ 을 임베딩을 행 방향으로 concat하여 단일 행렬로 표현하라.

▼ 정답 & 단계별 풀이

정답:

$$\tilde{x} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}$$

각 단어("한"=[1,0,0], "학기"=[1,1,0], "동안"=[0,1,1])의 임베딩을 위에서 아래로 쌓은 것.

2-2 (5 pts)

작년 기말

next-word prediction을 위한 output logit **o**를 구하라. 단, 내적 대신 hamming distance $H(u, v) = \sum_{i=1}^d \mathbf{1}[u_i = v_i]$ 를 사용한다.

▼ 정답 & 단계별 풀이

정답: $o = [0, 1, 2, 1, 3, 2, 2, 0, 1, 0, 2, 2, 1]$

단계별 풀이. 먼저 마지막 위치의 hidden state를 구한다. $\tilde{x} \circ M$ 의 **마지막 행**이 다음 단어 예측에 쓰인다. $\tilde{x}$ 의 마지막 행은 "동안"=[0,1,1]:

$$h = [0, 1, 1] \circ M = [0 \cdot 1 + 1 \cdot (-1) + 1 \cdot 1, 0 \cdot 1 + 1 \cdot 0 + 1 \cdot 1, 0 \cdot 0 + 1 \cdot 1 +$$

이제 각 vocabulary 임베딩 v 와 $h = [0, 1, 2]$ 사이 hamming distance(= 같은 자리 성분 개수)를 센다:

- 한[1,0,0]: ($0 \neq 1, 1 \neq 0, 2 \neq 0$) → **0**
- 학기[1,1,0]: ($0 \neq 1, 1 = 1, 2 \neq 0$) → **1**
- 동안[0,1,1]: ($0 = 0, 1 = 1, 2 \neq 1$) → **2**
- 매우[-1,1,0]: ($0 \neq -1, 1 = 1, 2 \neq 0$) → **1**
- 수고[0,1,2]: ($0 = 0, 1 = 1, 2 = 2$) → **3**
- 고생[1,1,2]: ($0 \neq 1, 1 = 1, 2 = 2$) → **2**
- 정말[0,0,2]: ($0 = 0, 1 \neq 0, 2 = 2$) → **2**
- 고맙습니다[3,0,1]: (모두 불일치) → **0**
- 했습니다[0,2,3]: ($0 = 0, 1 \neq 2, 2 \neq 3$) → **1**
- 많았습니다[1,2,3]: (모두 불일치) → **0**

- 감사합니다[3,1,2]: ($0 \neq 3, 1=1, 2=2$) → **2**
- 하셨습니다[0,2,2]: ($0=0, 1 \neq 2, 2=2$) → **2**
- 많았어요[1,2,2]: ($0 \neq 1, 1 \neq 2, 2=2$) → **1**

$\Rightarrow o = [0, 1, 2, 1, 3, 2, 2, 0, 1, 0, 2, 2, 1]$.

2-3 (5 pts)

작년 기말

위 logit o 에 top-K ($K=1$) random sampling을 적용하면 다음 단어 y_1 은?

▼ 정답 & 단계별 풀이

정답: "수고"

top-K with $K=1$ 은 logit이 가장 큰 단어 하나만 남기므로 사실상 greedy(argmax). o 의 최댓값은 5번째 성분 **3** = "수고". 따라서 $y_1 = \text{"수고"}$.

2-4 (5 pts)

작년 기말

같은 디코딩으로 한 토큰 더 autoregressive하게 생성하면 y_2 는?

▼ 정답 & 단계별 풀이

정답: "많았습니다"

단계별 풀이. 생성된 $y_1 = \text{"수고"} = [0, 1, 2]$ 를 시퀀스에 붙이고, 새 마지막 토큰 "수고"의 hidden state를 구한다:

$$h_2 = [0, 1, 2] \circ M = [0 - 1 + 2, 0 + 0 + 2, 0 + 1 + 2] = [1, 2, 3]$$

각 vocab 임베딩과 $h_2 = [1, 2, 3]$ 의 hamming distance를 센다. 정확히 일치하는 임베딩은 "많았습니
다" **[1,2,3]**로 hamming=3(최댓값). top-K($K=1$) argmax $\Rightarrow y_2 = \text{"많았습니다"}$.

Problem 3: Training of LLM (15 Points)

작년 실제 기출

수식 작성

LLM M을 from scratch로 학습한다. M은 토큰열 $x = [x_1, \dots, x_L]$ (각 $1 \leq x_i \leq |V|$)을 받아 확률 $p = [p_1, \dots, p_L] \in \mathbb{R}^{L \times |V|}$ ($\sum_{k=1}^{|V|} p_i(k) = 1, p_i(k) \geq 0$)를 출력한다.

3-1 (5 pts) — next-token prediction loss

작년 기말

#사전학습

well-curated corpus $D_{\text{next}} = \{x^{(i)}\}_{i=1}^N$ 로 next token을 예측하도록 학습. (1) loss 이름과 (2) $\min_{x \sim D_{\text{next}}} \mathbb{E}[f]$ 형태의 수식(f를 작성)을 쓰라. (x 길이는 항상 L)

▼ 정답 & 해설

정답: (1) Cross-entropy loss

(2) Next-token CE loss

$$\mathcal{L}_{\text{next}} := \sum_{i=1}^{L-1} -\log p_i(x_{i+1})$$

각 위치 i 에서 모델이 출력한 분포 p_i 가 실제 다음 토큰 x_{i+1} 에 부여한 확률의 negative log를 더한 것. 이 것이 표준 언어모델 사전학습 목적함수다.

3-2 (5 pts) — instruction tuning loss

작년 기말

#instruction tuning

지시를 잘 따르도록 $D_{\text{inst}} = \{(\tilde{x}^{(i)}, \tilde{y}^{(i)})\}_{i=1}^{N'}$ 로 추가 학습. $\tilde{x}$ (길이 L)와 $\tilde{y}$ (길이 M)가 $x := \tilde{x} \oplus \tilde{y}$ 로 concat될 때, (1) loss 이름과 (2) $\min_{(\tilde{x}, \tilde{y}) \sim D_{\text{inst}}} \mathbb{E}[g]$ 형태 수식(g)을 쓰라.

▼ 정답 & 해설

정답: (1) Cross-entropy loss

(2) Instruction tuning loss (응답 부분만 학습)

$$\mathcal{L}_{\text{inst}} := \sum_{i=L+1}^{L+M-1} -\log p_i(x_{i+1})$$

next-token CE와 형태는 같지만 **합 범위가 $i = L + 1$ 부터**다 — 즉 입력 instruction $\hat{x}$ 부분은 loss에서 빼고 **응답 $\hat{y}$ 토큰에 대해서만** 다음 토큰 예측 loss를 건다. (prompt masking)

3-3 (5 pts) — RLHF objective

작년 기말

#12 RL (RLHF)

안전성을 위해 RLHF로 추가 finetune. reward model $r_\phi : x \rightarrow [0, 1]$ ($x := \hat{x} \oplus \hat{y}$)가 주어질 때, $\max_{M_\theta} \mathbb{E}_{\hat{x} \sim D_{\text{RLHF}}, \hat{y} \sim M_\theta(\hat{x})} [h - \beta h']$ 형태로 목적함수를 쓰라. (h는 x, r_ϕ 의 함수, h'는 x, p, p' 의 함수이며 p'는 M_{inst} 의 출력확률)

▼ 정답 & 해설

정답:

RLHF objective = reward - β ·KL

$$h = r_\phi(x), \quad h' = \sum_{i=L+1}^{L+M-1} p_i \log \frac{p_i}{p'_i} \quad \left(= \sum_{i=L+1}^{L+M-1} \text{KL}(p_i \| p'_i) \right)$$

목적함수 전체: $\max_{M_\theta} \mathbb{E} [r_\phi(x) - \beta \text{KL}(p \| p')]$. 즉 **reward를 최대화**하되, 현재 정책 p 가 instruction-tuned 기준모델 p' 에서 너무 멀어지지 않도록 **KL penalty(β 가중)**로 규제한다. PPO 류 RLHF의 핵심 형태.

Problem 4: RAG and Tool-use (15 Points) 작년 실제 기출

All sub-questions: Pick all that are correct; any wrong answer will lead to 0 points.

4-1 (3 pts)

작년 기말

#9 RAG

Which of the statements about RAG are correct?

- a. Dense retrieval methods often rely on contrastive loss during training.
- b. Fine-tuning LLMs with new knowledge is a scalable and safe solution.
- c. Retrieval-based input augmentation can help LLMs access more up-to-date information.

d. Knowledge cutoff in pretraining dataset can cause trained LLMs to miss recent events.

▼ 정답 & 해설

정답: (a), (c), (d)

- (a) Correct. Contrastive learning is standard in dense retrieval (DPR, Contriever).
- (b) Incorrect. Fine-tuning with new knowledge degrades accuracy and has scalability/safety issues.
- (c) Correct. Retrieval augments input with up-to-date external documents.
- (d) Correct. Fixed training data → knowledge cutoff → missing recent info.

4-2 (3 pts)

작년 기말

#9 RAG (inference-level)

Which correctly describe the inference-based RAG methods?

- a. REPLUG assumes a full access to LLM parameters for end-to-end training.
- b. SuRe first generates answer candidates and then summarizes retrievals conditionally.
- c. IRCot simultaneously conduct retrieval and reasoning using Chain-of-Thought prompting.
- d. RetRobust improves RAG by using natural language inference (NLI) models for filtering.

▼ 정답 & 해설

정답: (b), (d)

- (a) Incorrect. REPLUG assumes black-box access; no parameter updates. ⓐ 귀속
- (b) Correct. SuRe generates candidate answers, then summarizes retrievals for each. 올해 범위 ○
- (c) Incorrect. IRCot *interleaves* retrieval and reasoning (not simultaneous). ⓐ 순서
- (d) Correct. RetRobust uses NLI models to check passage support.

4-3 (3 pts)

작년 기말

#9 RAG (training-level)

Which correctly describe the training-based RAG methods?

- a. REALM jointly trains both the retriever and the reader components.
- b. Self-RAG trains LLM to critique and refine its own generations via RL training.
- c. Training-based RAG can learn to ignore irrelevant documents through supervision.
- d. The retriever, target LLM, and query generator in Search-R1 are all fine-tuned using standard supervised learning.

▼ 정답 & 해설

정답: (a), (c)

- (a) Correct. REALM trains retriever and reader jointly end-to-end. 올해 범위 밖(참고)
- (b) Incorrect. Self-RAG uses SFT with GPT-4-generated reflection data, not RL. ㉠/㉡
- (c) Correct. With supervision it learns to downweight unhelpful documents.
- (d) Incorrect. Search-R1 uses a **frozen** external retriever (not fine-tuned). ㉢ 절대어(all)

4-4 (3 pts)

작년 기말

#10 Tool Use

Which steps are included in the prompting-based tool-use approach?

- a. LLM is given tool APIs via system message and responds with API call.
- b. LLM directly calls the API and gets results from external execution.
- c. The user manually executes the function based on LLM response.
- d. LLM incorporates the returned function result in its final answer.

▼ 정답 & 해설

정답: (a), (b), (d)

- (a) Correct. LLM receives tool descriptions via system messages.
- (b) Correct. Function calls are decided by LLM and executed externally.
- (c) Incorrect. This is automated, not user-operated. ㉠ 주체

- (d) Correct. The result is passed back to form the final response.

4-5 (3 pts)

작년 기말

#10 Tool Use (ToolLLM)

Which are true about the ToolLLM framework?

- a. ToolLLM collects APIs from RapidAPI and uses ChatGPT to generate tool-use instructions.
- b. ToolLLM uses human annotators to label solution paths for each instruction.
- c. ToolLLM trains a dense retriever based on BERT to retrieve relevant APIs for a given instruction.
- d. ToolLLM only consider single-tool usage scenario in both instruction generation and solution annotation.

▼ 정답 & 해설

정답: (a), (c)

- (a) Correct. 3,451 tools / 16,000+ APIs from RapidAPI; ChatGPT generates instructions.
- (b) Incorrect. ChatGPT auto-annotates solution paths (no human). ① 주체
- (c) Correct. A BERT-based dense retriever retrieves relevant APIs.
- (d) Incorrect. It includes both single-tool and multi-tool usage. ② 절대어(only)

Problem 5: LLM Safety (20 Points) 작년 실제 기출

All sub-questions: Pick all that are correct; any wrong answer will lead to 0 points (4 pts each).

5-1 (4 pts) — Jailbroken

작년 기말

#13 Jailbreak

Which are true about Jailbroken?

- a. Jailbroken identifies two reasons — competing objective and mismatched generalization — why jailbreaking is possible even after RLHF.
- b. Prefix injection is jailbreaking method that utilize competing objective.
- c. Refusal suppression is based on competing between instruction tuning and RLHF.

d. Jailbreaking with Base64 encoding is an example of mismatched generalization.

▼ 정답 & 해설

정답: (a), (b), (c), (d) — 전부 정답!

- (a)~(d) 모두 Correct. Jailbroken의 두 실패 모드(competing objective / mismatched generalization)와 각 공격 예시가 정확히 매칭.

교훈: 작년 기말에도 4개 전부 정답인 Pick-all이 나왔다.

5-2 (4 pts) — AutoDAN & SafeDecoding

작년 기말

#13 Jailbreak

Which are true about AutoDAN and SafeDecoding?

- a. AutoDAN search prompt candidates that minimize the likelihood of proxy label (e.g., "Absolutely, here's") via genetic algorithm.
- b. SafeDecoding modifies the decoding process to block unsafe outputs token-by-token.
- c. AutoDAN requires human feedback to evaluate the jailbreak success.
- d. SafeDecoding requires fine-tuning of the target LLM with adversarial prompts.

▼ 정답 & 해설

정답: (b), (d)

- (a) Incorrect. **Maximize** the likelihood to leverage generation momentum. ⓧ 방향
- (b) Correct. SafeDecoding adjusts generation probs via contrastive decoding.
- (c) Incorrect. **Evaluation is automatic** (keyword or LLM-as-judge). ⓧ 주체
- (d) Correct. To get the expert model in contrastive decoding, SafeDecoding fine-tunes on adversarial prompts (GPT-4 labeled).

5-3 (4 pts) — DetectGPT

작년 기말

#14 AI Text Detection

Which statements are correct about DetectGPT?

- a. DetectGPT assumes LLM-generated texts reside in regions of high positive curvature in log-likelihood space.
- b. DetectGPT requires the ability to evaluate the log probability from the source model.
- c. DetectGPT uses a fine-tuned supervised classifier trained on AI-generated and human-written text.
- d. DetectGPT involves generating and evaluating a large number of perturbations for each input.

▼ 정답 & 해설

정답: (b), (d)

- (a) Incorrect. DetectGPT assumes **negative** curvature. Ⓣ 방향
- (b) Correct. It needs log-likelihood scores from the source LLM.
- (c) Incorrect. DetectGPT is zero-shot, no trained classifier. Ⓣ 귀속
- (d) Correct. It generates/evaluates many perturbations per input.

5-4 (4 pts) — Watermarking

작년 기말

#14 AI Text Detection

Which correctly describes watermarking LLM outputs?

- a. It inserts visible markers into output texts to note the origin.
- b. Watermarked texts can be detected using a one-proportion z-test.
- c. Soft watermarking alters logits to subtly bias generation toward green-list tokens.
- d. Watermarking is fully robust to paraphrasing attacks.

▼ 정답 & 해설

정답: (b), (c)

- (a) Incorrect. Watermarks are imperceptible to humans. 정의 왜곡
- (b) Correct. Detection uses a one-proportion z-test on token patterns.
- (c) Correct. Soft watermarking modifies logits to bias toward green-list tokens.
- (d) Incorrect. Can be broken by paraphrasing/span replacement. Ⓣ 절대어(fully)

5-5 (4 pts) — Hallucination & ITI

작년 기말

ITI는 올해 범위 밖

Which statements relevant to LLM hallucination are true?

- a. Hallucination occurs when an LLM generates text that is factually incorrect but presented fluently.
- b. Hallucination only happens in low-resource or out-of-domain settings.
- c. Inference-Time Intervention (ITI) uses trained probes to identify latent directions associated with factuality.
- d. ITI modifies LLM activations during inference by shifting them in truthful directions.

▼ 정답 & 해설

정답: (a), (c), (d)

- (a) Correct. Hallucinations are fluent-but-false responses.
- (b) Incorrect. They can happen in any context, not only difficult settings. Ⓣ 절대어(only)
- (c) Correct. ITI trains per-head probes for truthfulness directions. 올해 범위 밖
- (d) Correct. ITI shifts activations along truthful directions at inference.

(ITI 자체는 올해 2026 슬라이드엔 없음 — 메커니즘만 참고.)



기말 출제 청사진 — 작년 기말 실제 구조 기반

이 섹션은 추측이 아니다. **작년 기말(2025-06-17)**이 실제로 어떻게 나왔는지를 기준으로, 올해도 같은 틀로 나온다는 전제하에 작성한 청사진이다.

📌 **작년 기말 = 거의 확정된 올해 청사진**

Problem	주제	형식	배점
1	True / False	T/F 10문항 (무응답 1점)	30점
2	Inference with LLM	계산 (서술)	20점
3	Training of LLM	수식 작성 (서술)	15점
4	RAG and Tool-use	Pick-all 5문항	15점
5	LLM Safety	Pick-all 5문항	20점

여기에 **마지막 수업 공지**(객관식 Problem 3~4개 중 1개가 #13 Jailbreak + #14 Detection 특강 통합)를 결합하면 — 작년 Problem 5(Safety)가 그 통합 Problem에 대응한다. 구조는 사실상 고정으로 봐도 된다.

📌 **가장 중요한 경고 — Problem 2·3(합 35점)은 손계산·수식이다**

작년 기말에서 **Problem 2(Inference, 20점)와 Problem 3(Training, 15점)**, 합 35점은 객관식이 아니라 손으로 푸는 계산·수식 문제였다. T/F와 Pick-all(객관식)만 공부하면 **전체의 35%**를 통째로 날린다.

- **Problem 2:** 행렬 곱($\tilde{x} \circ M$), word embedding concat, hamming distance logit, top-K(K=1) 샘플링, autoregressive 2-step 생성 — 직접 계산해서 답을 써야 한다.
- **Problem 3:** next-token CE loss, instruction tuning loss(prompt masking), RLHF objective(reward - $\beta \cdot \text{KL}$) — 수식을 직접 작성해야 한다.
- 위 sf2·sf3의 단계별 풀이를 **보지 않고 재현**할 수 있을 때까지 연습할 것.

챕터별 예상 매핑

작년 Problem	올해 예상 챕터 매핑	핵심 키워드
P2 Inference (계산)	#7 Decoding (+ 기본 디코딩)	greedy/top-K/top-p, temperature, autoregressive, 행렬 연산
P3 Training (수식)	#8 AI Feedback / #12 RL	CE loss, instruction tuning, RLHF objective(reward- β ·KL), DPO
P4 RAG+Tool	#9 RAG / #10 Tool Use	BM25·DPR, REPLUG·IRCoT·RetRobust·SuRe(inference) vs Self-RAG·Search-R1(training), Toolformer·ToolLLM
P5 Safety	#13 Jailbreak / #14 AI Text Detection	Jailbroken, AutoDAN·SafeDecoding·Gradient Cuff, DetectGPT·Fast-DetectGPT·watermarking
P1 True/False	#7~#14 전 챕터	챕터마다 1~2문항씩 골고루

참고

#8 AI Feedback 단독 비중은 작년 기말 기준 낮았다 — Training 수식 Problem(P3) 안에 RLHF objective 형태로 일부 흡수됐을 뿐, AI Feedback만의 단독 Problem은 없었다. G-Eval·judge bias 등은 T/F 수준으로 대비.

★ 우선순위 (작년 기말 기준)

- Problem 2·3 계산·수식(35점)** — 손으로 푸는 연습. 여기서 갈린다.
- Problem 5 Safety(20점)** — 공격/방어/탐지 귀속(Jailbroken·AutoDAN·SafeDecoding / DetectGPT·watermarking).
- Problem 4 RAG+Tool(15점)** — inference-level vs training-level 이분법, Toolformer vs ToolLLM.
- Problem 1 T/F(30점)** — 전 챕터 골고루, 무응답 1점 규칙 활용.

7 기말 범위 챗터별 디테일 (#7~#14)

보조 — 청사진은 위 ⚡ 섹션 참고

i 읽는 순서

출제 구조는 위 "⚡ 기말 출제 청사진"(작년 실제 기출 기반)이 우선이다. 이 섹션은 그 청사진을 **챗터별 세부 암기 포인트**로 보강하는 보조 자료다.

7.1 예상 시험 구성

마지막 수업 공지 반영

마지막 수업에서 교수가 직접 공지: 객관식 Problem은 3~4개이고, 그중 1개는 #13 Jailbreak + #14 AI Text Detection 통합 문제("I will make three or four multiple choice question problems, and one of them will be about the jailbreaking and AI-generated detection, all in one part"). 작년 기말 구조(T/F 30점 + 서술 Problem 2개 + Pick-all Problem)를 여기에 결합하면 아래 구성이 가장 유력하다.

예상 Problem	예상 주제 (묶음)	예상 배 점	근거
Problem 1	True/False 10문항 — #7~#14 전 챗터에서 1~2개씩	30점	추정 교수는 "객관식 3~4개"만 언급 — 작년 기말 패턴상 T/F는 별도 Problem로 유지될 가능성 큼 (무응답 1점 규칙 포함)
객관식 ①	#9 RAG — retriever 기초 + inference-level vs training-level	15~20 점	추정 강의 3회분으로 분량 최대 + 교수 recap에서 이분법(아래 7.2) 명시적 강조
객관식 ②	#10 Tool Use + #11 LLM Agents	15~20 점	추정 recap에서 "agents의 tool use는 이전 강의에서 다룸" — 연속 주제로 한 Problem 묶음이 자연스러움
객관식 ③	#12 RL with LLMs (+#8 AI Feedback 연계)	15~20 점	추정 작년 기말 Problem 3(Training 수식: RLHF objective)의 연장선 — recap에서 RLHF + PPO·GRPO 명시

객관식 ④

#13 Jailbreak + #14 AI Text

15점

Detection 통합 (한 Problem

안에 두 주제 혼합)

확정

교수 직접 공지 — 두 특강(녹화 강의)을 "all in one part"로 출제. 객관식이 3개면 ①~③ 중 둘이 합쳐질 수 있음

⚠ 남은 불확실성

- 객관식이 3개일 경우 — 특강 통합 1개는 고정이므로, 본 범위(#7~#12)가 2개 Problem로 압축된다(예: RAG+Tool Use / Agents+RL). 어느 쪽이든 특강 Problem은 확정.
- #7 Decoding은 작년 기말 Problem 2(Inference 계산: top-K·autoregressive)에서 손계산으로 출제됐고 **교수의 마지막 recap에서도 별도 언급 없음** — 올해도 계산 Problem이나 T/F로 소화될 가능성이 높다. Problem 2 손계산 풀이를 반드시 재현 연습.
- T/F Problem의 존재·배점은 추정 — 시험 당일 표지의 채점 규칙(무응답 1점 여부)을 반드시 먼저 확인.

7.2 챕터별 "여기서 나온다" 포인트

아래 각 챕터의 **recap 언급** 표시는 **마지막 수업에서 교수가 범위 recap으로 직접 짚은 항목** — 출제 신호로 우선 암기.

#7 Decoding / Controllability

기출 직격: Problem 5 + P1(x)

recap 미언급 — 우선순위 하향

- 기출에서 autoregressive·temperature·top-p·speculative·test-time compute가 **전부** 나옴 → 기말은 남은 조각: **greedy vs beam vs DBS 비교, top-k vs top-p 차이, contrastive/constrained decoding, controllability 기법**.
- T/F 단골: "Beam search *always* finds the global optimum" → False. "Temperature $T \rightarrow 0$ reduces sampling to greedy decoding" → True.
- 함정 재료: temperature 적용 위치(㉔), speculative의 draft↔target 역할 교환(㉑), "eliminates sequential generation"(㉓).

#8 AI Feedback

기출 직격: P4-5 (LC win rate)

recap 언급

- **recap 언급** 교수가 짚은 키워드: **G-Eval**(평가) · **Anthropic HHH**(학습 개념) · **RLAIF = Constitutional AI** — 이 셋의 역할 구분(평가용 vs 정렬용)이 출제 신호.
- LLM-as-a-Judge의 bias 목록(**length/verbosity bias, position bias, self-enhancement bias**)은 P4-5의 직접 연장 — 각 bias의 정의와 완화법(swap positions, LC regression)이 Pick-all

로 나오기 좋다.

- RLAIIF vs RLHF: "무엇이 human을 대체하는가"(preference labeling 단계) — 주체 바꿔치기(①) 함정 1순위.
- Constitutional AI: critique→revision은 **SL 단계**, AI 비교는 **RL 단계** — 단계 귀속(④⑥) 함정.

#9 RAG

분량 최대 — 단독 Problem 유력

recap 언급

- **recap 언급** 교수가 recap에서 강조한 구조: retriever 기초 → **inference-level(REPLUG, IRCot, RetRobust) vs training-level(Self-RAG, Search-R1)** 이분법. 이 분류 자체가 ⑥(training↔inference) 함정 제조기 — "**REPLUG는 training-level이다**" → **False** 류의 귀속 판정 1순위.
- Sparse vs Dense retrieval: **BM25 vs DPR vs Contriever** 비교(학습 필요 여부, lexical↔semantic matching) — 방법 귀속(④) 함정 공장.
- "RAG *always* improves factuality / *eliminates* hallucination" → False(②). "Retrieval happens after generation" → False(⑤).
- RAG 파이프라인 단계(retriever→reader), end-to-end 학습 여부(RAG/REALM vs frozen retriever), retrieval 시점(when-to-retrieve, Self-RAG 류)이 Pick-all 소재.
- 수치 함정 후보: DPR negative sampling 방식, in-batch negatives, top-k passages 수.

#10 Tool Use

recap 언급

- **recap 언급** 교수의 recap 구조: prompting 기초 + training-level 방법 2개 — **Toolformer = self-supervised, ToolLLM = SFT(supervised fine-tuning)**. 이 한 줄 구분이 recap에서 명시된 만큼 ④(방법 귀속) 함정의 최우선 재료.
- **Toolformer vs ToolLLM**: 누가 self-supervised로 API call을 삽입·필터링하나(Toolformer), 누가 대규모 실제 API + DFSDT인가(ToolLLM) — ④ 함정 1순위.
- Toolformer 필터링 기준: API call이 **future token loss를 줄이는가** — 목적 왜곡(⑦) 주의.
- "Tool use requires fine-tuning the LLM" → 모델별로 다름(prompting-only도 있음) — 절대어(②) 주의.

#11 LLM Agents

recap 언급

- **recap 언급** 교수: agent = planning&action + tool use + memory인데 "**tool use는 이전 강의에서 다뤘으므로 두 개념 중심**" — 즉 **planning&action(ReAct, Reflexion, ToT)**과 **memory(MemGPT, A-Mem)**이 출제 축. MemGPT(OS식 메모리 계층) vs A-Mem(동적 메모리 조직)도 귀속 판정 후보.

- **ReAct vs Reflexion vs Tree-of-Thoughts** 3자 비교표가 출제 1순위: interleaved reasoning+acting(ReAct), verbal self-reflection을 episodic memory에 저장(Reflexion, *파라미터 업데이트 없음!*), search over thoughts + backtracking(ToT).
- "Reflexion updates model weights through reflection" → **False** (© training↔in-context) — 가장 나올 법한 T/F.
- Agent 구성요소(planning, memory, tool use, action)와 multi-agent 협업 패턴.

#12 RL with LLMs

기출 직격: P4-2~4 + P1(ix)

recap 언급

- **recap 언급** 교수 recap: **RLHF + 최신 알고리즘 PPO-GRPO** — 두 알고리즘이 recap에서 이름으로 호명된 유익한 RL 방법.
- **PPO vs GRPO**: GRPO는 **value/critic model 제거**, group 내 상대 보상으로 advantage 추정 $\hat{A}_i = \frac{r_i - \text{mean}(r)}{\text{std}(r)}$ — "GRPO requires a critic" → False(④).
- RLVR(verifiable rewards): rule-based reward(정답 일치·형식)로 reward model 불필요 — "RLVR trains a reward model" → False.
- online(PPO/GRPO) vs offline(DPO/SimPO) 구분(©)은 기출 P4-4(d)의 재탕이 유력.
- KL penalty의 역할(reference model에서 멀어지는 것 방지)과 적용 위치(⑤).

#13 Jailbreak (Special Lecture)

통합 Problem 확정 — #14와 한 문제

- **recap 언급** 교수가 recap에서 호명한 3축: **Jailbroken**(NeurIPS'23, jailbreak 개념을 정식화한 **베이스라인**) · 공격 **AutoDAN**(jailbreak prompt 자동 생성) · 방어 **SafeDecoding + Gradient Cuff**. 이 4개 이름의 **공격/방어 귀속 판정**이 통합 Problem의 핵심 재료.
- **우선순위 힌트** recap에서 **GCG-COLD-Attack은 언급되지 않음**(AutoDAN·Jailbroken 중심) — 출제된다면 보조 보기 수준일 가능성. 단 Jailbroken의 실패 원인 2축(competing objectives, mismatched generalization)은 베이스라인이므로 필수.
- 함정 재료: "AutoDAN is a defense method" → False(④), "SafeDecoding modifies the attack prompt" → False(방어는 디코딩 단계 개입 — ⑤), white-box↔black-box 혼동(①).

#14 AI Text Detection (Special Lecture)

통합 Problem 확정 — #13과 한 문제

- **recap 언급** 교수가 recap에서 호명한 계보: **DetectGPT → Fast-DetectGPT**(계산 시간 단축) → **ReMoDetect**(다른 방식의 구별) + **watermarking**(생성 텍스트에 숨은 패턴 삽입, 회사 측만 검출 가능 — "이미 실제 배포됨").

- 교수 재강조 직관 "AI 생성 텍스트는 모든 토큰에서 높은 확률을 받지만, 인간 텍스트는 모델 분포에서 나온 게 아니므로 확률이 출렁인다(fluctuate)" — 이 직관을 묻는 보기(T/F든 Pick-all이든)가 나올 확률 최상.
- 함정 재료: "Watermarking can be applied to text after it is generated" → False(생성 중 개입 — ㉔), "Fast-DetectGPT improves accuracy, not speed" → False(동기 왜곡 ㉔), "Anyone can detect the watermark by reading the text" → False(회사 측 검출).

7.3 특강 통합형 예상 문제 — Pick all that are correct

한 Problem에 #13+#14 혼합 확정

교수 공지대로 **jailbreak**와 **detection** 보기가 한 문제 안에 섞여 나올 수 있는 통합형 대비 문제. 기출 문제 (각 보기 = 독립 T/F)로 작성.

Pred-1 · Pick all that are correct

예상 문제 (#13+#14 통합)

Pick all the correct statements about LLM safety attacks and defenses, and AI-generated text detection.

- (a) AutoDAN is an attack method whose goal is to automatically craft jailbreak prompts.
- (b) SafeDecoding defends against jailbreak attacks by intervening at the decoding stage rather than by retraining the model from scratch.
- (c) DetectGPT requires training a separate supervised classifier on labeled human/AI text pairs.
- (d) Watermarking detects AI-generated text by analyzing the probability curvature of the text after it is generated.

▼ 정답 & 해설 보기

정답: (a), (b)

- (a) **Correct.** AutoDAN automatically generates stealthy jailbreak prompts (attack side).
- (b) **Correct.** SafeDecoding is a decoding-time defense — it contrasts token probabilities to amplify safety-aligned behavior, with no full retraining.
- (c) **Incorrect.** DetectGPT is zero-shot — it uses probability curvature under perturbations, not a trained classifier. ㉔ 방법 귀속
- (d) **Incorrect.** Watermarking intervenes *during generation* (hidden pattern in token selection); probability curvature is DetectGPT's mechanism. ㉔ 귀속 + ㉔ 시점

Pred-2 · Pick all that are correct

예상 문제 (#13+#14 통합)

Pick all the correct statements regarding jailbreaking and AI-generated text detection methods covered in the special lectures.

- (a) The work "Jailbroken" (NeurIPS 2023) attributes jailbreak success to two failure modes of safety training: competing objectives and mismatched generalization.
- (b) Gradient Cuff is an attack method that uses gradient information to optimize adversarial suffixes.
- (c) AI-generated text tends to receive consistently high probabilities across all tokens under the generating model, whereas human-written text shows fluctuating probabilities.
- (d) Fast-DetectGPT improves over DetectGPT mainly by reducing computational cost.

▼ 정답 & 해설 보기

정답: (a), (c), (d)

- (a) **Correct.** Jailbroken is the baseline work formalizing why safety training fails (competing objectives / mismatched generalization).
- (b) **Incorrect.** Gradient Cuff is a *defense* (detects jailbreak prompts via the refusal-loss landscape); gradient-optimized adversarial suffixes describe GCG.
Ⓢ attacker↔defender + Ⓢ 귀속
- (c) **Correct.** 교수가 마지막 수업에서 재강조한 핵심 직관 — decoding methods sample high-probability tokens, so AI text is uniformly high-probability while human text fluctuates.
- (d) **Correct.** DetectGPT's perturbation-based curvature estimation is expensive; Fast-DetectGPT's main contribution is efficiency.

Pred-3 · Pick all that are correct

예상 문제 (#13+#14 통합)

Pick all the correct statements about watermarking and detection-based approaches for identifying AI-generated text.

- (a) Watermarking imposes hidden patterns during text generation that are invisible to ordinary readers but detectable by the model provider.
- (b) Watermarking can be applied retroactively to any text after it has been generated.
- (c) DetectGPT identifies AI-generated text in a zero-shot manner by measuring how the log-probability drops when the text is perturbed.

- (d) ReMoDetect follows exactly the same probability-curvature mechanism as DetectGPT, only with a faster implementation.

▼ 정답 & 해설 보기

정답: (a), (c)

- (a) **Correct.** 교수 recap 그대로 — hidden pattern은 사람 눈에는 안 보이고, 회사(provider) 측 검출 방법으로만 확인 가능. 이미 실제 배포됨.
- (b) **Incorrect.** Watermarking must intervene *during* generation (biasing token selection); it cannot be added after the fact. ㉔ 시점
- (c) **Correct.** AI text sits at a local maximum of the model's log-probability (negative curvature) — perturbation drops its probability sharply; zero-shot, no classifier training.
- (d) **Incorrect.** Faster implementation of the same curvature idea is *Fast-DetectGPT*; ReMoDetect takes a different route (reward-model-based detection exploiting LLMs' alignment preference). ㉔ 귀속

Pred-4 · Pick all that are correct 예상 문제 (#13+#14 통합)

Pick all the correct attributions of the following methods to their roles (attack / defense / detection).

- (a) AutoDAN — attack; SafeDecoding — defense; DetectGPT — detection.
- (b) Jailbreaking attacks succeed only against open-source models whose gradients are accessible.
- (c) Both SafeDecoding and Gradient Cuff are defense methods against jailbreak attacks.
- (d) Detection methods such as DetectGPT and watermarking both require access to the model side (the generating model's probabilities or the provider's key) rather than working from the raw text alone.

▼ 정답 & 해설 보기

정답: (a), (c), (d)

- (a) **Correct.** 정확한 3분류 — recap에서 교수가 호명한 그대로(공격 AutoDAN / 방어 SafeDecoding-Gradient Cuff / 탐지 DetectGPT 계열).
- (b) **Incorrect.** "only"가 함정 — Jailbroken/AutoDAN 류 prompt-level 공격은 black-box(API-only) 모델에도 통한다. gradient 접근이 필요한 것은 GCG 류뿐. ㉔ 절대어

- (c) **Correct.** 둘 다 방어 — SafeDecoding은 decoding 개입, Gradient Cuff는 refusal loss 기반 jailbreak prompt 탐지.
- (d) **Correct.** DetectGPT needs the model's token probabilities; watermark detection needs the provider's secret method — neither works from surface text inspection by an arbitrary reader.

★ 최종 우선순위 (시간 없을 때) — 마지막 수업 공지 반영

1. **#13+#14 특강 통합 Problem** 출제 확정 — 유일하게 출제가 확정된 Problem. 공격/방어/탐지 귀속표(AutoDAN↔SafeDecoding·Gradient Cuff, DetectGPT 계보, watermarking 시점) + "AI 텍스트는 전 토큰 고확률, 인간 텍스트는 출렁임" 직관. 위 7.3 예상 문제 4개 풀기.
2. **#12 RL(RLHF + PPO vs GRPO) + #8(G-Eval·HHH·RLAIF, judge bias)** — 작년 기말 Problem 3(RLHF objective 수식)의 연장선 + recap 호명.
3. **#9 RAG(inference-level REPLUG·IRCoT·RetRobust vs training-level Self-RAG·Search-R1)** — recap에서 이분법 명시 + 분량 최대.
4. **#10+#11(Toolformer self-supervised vs ToolLLM SFT, ReAct/Reflexion/ToT + MemGPT/A-Mem)** — recap 호명 키워드.
5. **기출 Problem 5 재독(#7)** — recap 미언급으로 우선순위는 내려갔지만 T/F 1~2문항 대비.

3분 요약

항목	한 줄 정리
형식	T/F 10×3점(무응답 1점!) + Pick-all 20문항(부분점수 0) = 100점/100분
T/F 전략	50:50이면 찍기(기대값 $1.5 > 1$), 완전히 모르면 비워서 1점 확보
Pick-all 전략	보기 4개를 독립 T/F로 판정 — 정답 수는 1~4개 전부 가능
합정 7유형	①주체 바꿔치기 ②절대어 ③수치 ④방법 귀속 ⑤처리 순서 ⑥training/inference-online/offline 범주 ⑦목적 왜곡
확정 공지	객관식 Problem 3~4개, 그중 1개 = #13 Jailbreak + #14 Detection 통합 (마지막 수업 교수 발언). 기말 30%·절대평가·A+ 엄격
기출 직결 챕터	#7(Problem 5 전체+DBS), #8(P4-5 LC win rate), #12(P4-2~4 RLHF/DPO+SimPO)
기말 1순 위	특강 통합(공격/방어/탐지 귀속 + 토큰 확률 직관), RL(PPO vs GRPO), RAG(inference vs training-level), Agents(ReAct vs Reflexion vs ToT + MemGPT/A-Mem)

[← 전체 목차](#)

[전체 목차로 →](#)